Alineamiento de DNASeq

Mario Solís López
27/03/2025

Objetivos

- ✓ Conocer la diferencia entre los algoritmos BLAST y los algoritmos empleados en análisis de DNASeq
  - Conocer fuentes de datos de secuencias
  - Aprender a manejar los diferentes recursos y bases de datos
- ✓ Conocer la base del algoritmo de Burrows-Wheeler
- ✓ Conocer las principales herramientas de análisis empleadas en el alineamiento de DNASeq
- ✓ Entender las diferencias entre dichas herramientas de análisis
- ✓ Conocer las principales genomas de referencia

Introducción

El alineamiento de secuencias de DNA es clave en bioinformática.

La secuenciación masiva de DNASeq produce **millones de reads**.

Para comprender la información genética, se deben mapear a un **genoma de referencia**.

Encontrar la mejor localización en el genoma con el menor número de discordancias.

Introducción

El alineamiento de lecturas cortas es un cuello de botella en el análisis bioinformático:

- Grandes volúmenes de datos, repeticiones y variaciones.

Métodos clásicos como *Needleman-Wunsch* o *Smith-Waterman* son precisos pero demasiado **lentos y costosos** para genomas grandes.

Se requieren de otro tipo de algoritmos.

Algoritmo Burrows-Wheeler

El Algoritmo de Burrows-Wheeler (BWA) permite una indexación eficiente de secuencias, facilitando búsquedas rápidas.

Se basa en la **Transformada de Burrows-Wheeler** (BWT) y el **Índice FM**.

La BWT es una transformación que **reorganiza** una secuencia de texto para mejorar la compresión y la búsqueda.

Se basa en tres estructuras fundamentales:

1) Array de Sufijos (SA): Lista ordenada de los sufijos de una secuencia.
2) Transformada de Burrows-Wheeler (BWT): Reorganiza la secuencia para mejorar la búsqueda.
3) Índice FM: Una estructura basada en BWT que permite búsquedas rápidas.

Transformada de Burrows-Wheeler

La compresión de *Burrows-Wheeler* es una permutación reversible de una cadena de caracteres. Con ello una cadena de caracteres que, en un contexto biológico será una cadena de nucleótidos o de aminoácidos, será transformará en otra cadena distinta más fácil de comprimir ya que contendrá múltiples posiciones con caracteres repetidos.

La transformación se realiza de la siguiente manera:

A) Dada una cadena de caracteres (T), se calculan todas las posibles rotaciones posibles de la cada. A la cadena original se incorpora al final el símbolo $.
B) Se ordenan todas las cadenas calculadas, junto con la original, alfabéticamente. El símbolo $ se considera el primero en un orden alfabético. La matriz resultante de este paso es la matriz de *Burrows-Wheeler* (BWM)
C) La última columna de la matriz es la transformada de *Burrows-Wheeler*: BWM(T).

Transformada de Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Se toma una secuencia y se generan todas sus rotaciones cíclicas.

Matriz de rotaciones
acgtcg$
cgtcg$a
gtcg$ac
tcg$acg
cg$acgt
g$acgtc
$acgtcg

Transformada de Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Se toma una secuencia y se generan todas sus rotaciones cíclicas.
- Se ordenan las rotaciones en orden lexicográfico.

Matriz de rotaciones
acgtcg$
cgtcg$a
gtcg$ac
tcg$acg
cg$acgt
g$acgtc
$acgtcg

Matriz ordenada
$acgtcg
acgtcg$
cg$acgt
cgtcg$a
g$acgtc
gtcg$ac
tcg$acg

Transformada de Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Se toma una secuencia y se generan todas sus rotaciones cíclicas.
- Se ordenan las rotaciones en orden lexicográfico.
- Se extrae la última columna de la tabla, que es la secuencia transformada.

Matriz de rotaciones	Matriz ordenada	Transformada
acgtcg$	$acgtcg	g
cgtcg$a	acgtcg$	$
gtcg$ac	cg$acgt	t
tcg$acg	cgtcg$a	a
cg$acgt	g$acgtc	c
g$acgtc	gtcg$ac	c
$acgtcg	tcg$acg	g

Transformada de Burrows-Wheeler

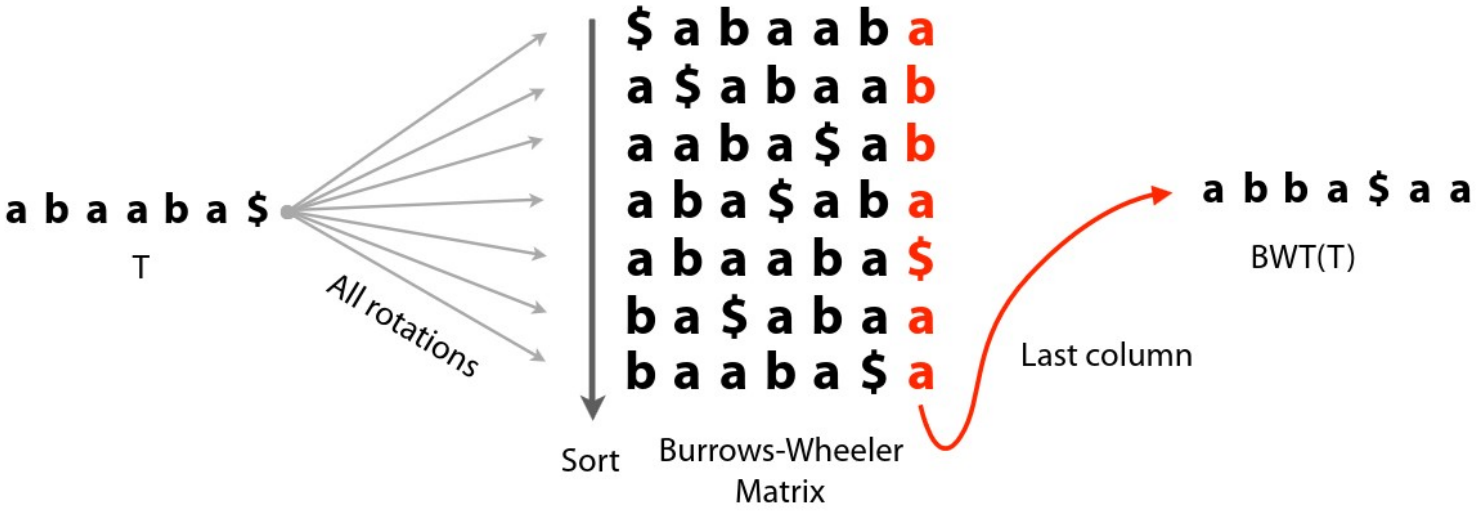

Burrows M, Wheeler DJ: A block sorting lossless data compression algorithm. *Digital Equipment Corporation, Palo Alto, CA* 1994, Technical Report 124; 1994

Transformada de Burrows-Wheeler

Agrupa caracteres similares, facilitando la compresión:

- Base para algoritmos de compresión como bzip2

Es reversible, lo que permite reconstruir la secuencia original.

Permite búsquedas rápidas usando el Índice FM.

Empleado por herramienta de alineamiento BWA

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- De la matriz ordenada, sacamos la primera columna (F)
- La transformada es la columna L

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g
a	acgtcg$	$
c	cg$acgt	t
c	cgtcg$a	a
g	g$acgtc	c
g	gtcg$ac	c
t	tcg$acg	g

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Rankeamos los nucleótidos en la columna F

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g
a_1	acgtcg$	$
c_1	cg$acgt	t
c_2	cgtcg$a	a
g_1	g$acgtc	c
g_2	gtcg$ac	c
t_1	tcg$acg	g

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Rankeamos los nucleótidos en la columna F
- Ponemos el mismo valor en la columna L

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g
a_1	acgtcg$	$
c_1	cg$acgt	t
c_2	cgtcg$a	a
g_1	g$acgtc	c
g_2	gtcg$ac	c
t_1	tcg$acg	g

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Rankeamos los nucleótidos en la columna F
- **Ponemos el mismo valor en la columna L**

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g
a_1	acgtcg**$**	$
c_1	cg$acgt	t
c_2	cgtcg**$**a	**a_1**
g_1	g$acgtc	c
g_2	gtcg$ac	c
t_1	tcg$acg	g

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Rankeamos los nucleótidos en la columna F
- Ponemos el mismo valor en la columna L

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g_1
a_1	acgtcg$	$
c_1	cg$acgt	t_1
c_2	cgtcg$a	a_1
g_1	g$acgtc	c_1
g_2	gtcg$ac	c_2
t_1	tcg$acg	g_2

Columnas FL en Burrows-Wheeler

Ejemplo con la palabra acgtcg**$**:

- Transformada de BW: $g_1\$t_1a_1c_1c_2g_2$
- String original: $a_1c_2g_2t_1c_2g_1$**$**

F	Matriz ordenada	Transformada (L)
$	$acgtcg	g_1
a_1	acgtcg$	$
c_1	cg$acgt	t_1
c_2	cgtcg$a	a_1
g_1	g$acgtc	c_1
g_2	gtcg$ac	c_2
t_1	tcg$acg	g_2

BWA

Alineador de secuencias cortas que emplea de base el algoritmo de búsqueda de Burrows-Wheeler

Desarrollado por Heng Li

Alineador más extendido y considerado como referencia y estándar en el área clínica

Recomendado en las Best Practices de Illumina

Altamente eficiente y siempre teniendo un alto rendimiento

Hay versiones que mejoran el rendimiento computacional (bwa-mem2)

https://github.com/lh3/bwa

https://github.com/bwa-mem2/bwa-mem2

BWA

Flujo de trabajo:

- Preprocesamiento e indexación del genoma de referencia.
- Alineamiento de las lecturas (FASTQs) frente al genoma indexado
- Post-procesamiento de lecturas (reordenación, marcado de duplicados, comprimir a BAM...)

DRAGMAP

DRAGMAP (Dynamic Read Alignment for Genomics with Multi-platform Acceleration) es un alineador de secuencias desarrollado por **Illumina**.

Está diseñado para aprovechar aceleración por hardware (CPU, GPU, FPGA) y mejorar la precisión del alineamiento.

Ofrecer una alternativa optimizada a BWA para datos de secuenciación en plataformas Illumina.

DRAGMAP

Características:

- Diseñado y optimizado para manejar datos generados por las plataformas de secuenciación de Illumina con alta precisión.

- Genera alineamientos compatibles con GATK para análisis de variantes.
- Uso de aceleración por hardware:
  - Mejora el rendimiento al aprovechar CPU, GPU y FPGA.

- Mayor precisión en regiones difíciles del genoma
- Mejor manejo de indels y regiones con alta repetitividad.

DRAGMAP

Flujo de trabajo:

- Preprocesamiento e indexación del genoma de referencia (similar a BWA).
- Alineamiento de las lecturas (FASTQs) frente al genoma indexado
- Post-procesamiento de lecturas (reordenación, marcado de duplicados, comprimir a BAM...)

DRAGMAP

Features	BWA	DRAGMAP
Desarrollador	Heng Li	Illumina
Target Data	DNASeq general (short read)	Illumina (short read)
Precisión	Alta	Mejora en regiones difíciles
Velocidad	Media/Alta	Acelerada
Código libre	Sí	Versiones antiguas

DRAGMAP

DRAGMAP es un alineador diseñado específicamente para secuenciación Illumina.

Supera a BWA en precisión en regiones difíciles del genoma.

Su rendimiento es superior si se dispone de hardware adecuado.

- Usar DRAGMAP si:
  - Se usan datos de secuenciación de Illumina.
  - Se requiere alta precisión en variantes.
  - Se tiene acceso a hardware acelerado (GPU, FPGA).

Para estudios generales, BWA sigue siendo una excelente opción.

Minimap2

Es un alineador rápido para lecturas largas (Oxford Nanopore, PacBio) y lecturas cortas.

Detección eficiente de variantes puntuales y estructurales

Desarrollado por Heng Li

Mapear lecturas a un genoma de referencia con alta eficiencia y precisión.

Soporta alineamientos de secuencias cortas y largas, así como ensamblajes completos.

Minimap2

Flujo de trabajo:

- Usa una técnica basada en minimizadores para representar secuencias de forma compacta: indexación de la referencia.

- Encuentra regiones similares en la referencia utilizando estructuras de datos eficientes.

- Refinamiento del alineamiento con penalizaciones para indels y errores en secuenciación.

Minimap2

Features	BWA	Minimap2
Desarrollador	Heng Li	Heng Li
Target Data	DNASeq general (short read)	DNASeq general (long-read y short read)
Precisión	Alta	Alta
Velocidad	Media/Alta	Acelerada (BWA optimizado para sr)
Código libre	Sí	Sí

Minigraph

Es un alineador diseñado para comparar y analizar múltiples genomas en forma de grafos.

Desarrollado también por Heng Li

Crear y analizar datos de secuenciación frente a genomas de referencia pan-genómicos en lugar de usar una única referencia lineal:

- Una única referencia no captura toda la diversidad genética.
- Empleando grafos, se consiguen representar múltiples variantes genómicas de una población en una estructura compacta
- Facilita análisis comparativos más precisos

Identificación rápida de variantes estructurales y repeticiones complejas.

Compatible con ensamblajes de novo y datos de lecturas cortas y largas.

Genomas de referencia

Es una secuencia de ADN representativa de una especie, utilizada como estándar para estudios genéticos.

Se usa en alineamientos, análisis de variantes y estudios evolutivos.

Desde GRCh37 hasta el pangenoma, se han mejorado la precisión, la continuidad y la inclusión de variantes estructurales:

- hg18
- GRCh37 (b37, hg19, 1KGRCh37…)
- GRCh38
- T2T
- Pan-genoma

GRCh37

Publicado en 2009 por el Genome Reference Consortium (GRC).

Primera versión ampliamente adoptada para análisis clínicos y genómicos.

Estructura basada en un ensamblaje de múltiples individuos, con h**uecos en regiones repetitivas**:

- Problemas en la determinación de variantes en ciertas regiones
- Gaps de conocimiento

GRCh37

Múltiples versiones del GRCh37:

- Diferentes contigs/Cromosomas
- Cromosomas con diferencias:
  - Maskeado de region PAR (chrY)
  - Nucleotidos maskeados (chr3)

Resumen del Broad Institute:
https://gatk.broadinstitute.org/hc/en-us/articles/360035890711-GRCh37-hg19-b37-humanG1Kv37-Human-Reference-Discrepancies

GRCh38

Publicado en 2013, reemplazando a GRCh37.

Principales mejoras:

Inclusión de secuencias alternativas para regiones altamente variables.

Reducción de gaps en el genoma.

Mayor precisión en la representación de centromeros y regiones repetitivas.

Al estar implantado el GRCh37 en Clínica:

- Gran challenge: migración de herramientas y bases de datos de GRCh37 a GRCh38.
- Por ejemplo, gnomad liberó la primera versión de resultados alineados frente al 38 en el 2021 (v3, la v2 presentaba un lift-over)

T2T-CHM13

Publicado en 2022

Telomere-to-Telomere:

- Primera secuencia completa del genoma humano

Sin gaps, con telómeros, centrómeros y regiones de baja complejidad resueltas

Basado en una línea celular haploide en lugar de una mezcla de individuos

Secuenciación de larga cadena fue clave para la resolución de este genoma

La referencia más precisa para estudios evolutivos

No está completamente anotado, por lo que para clínica sigue siendo mejor GRCh37

Pangenoma

Draft en 2023

Representa la diversidad genética sin bias

Ensamblaje de 47 genomas completos:

- Resolución mediante múltiples técnicas experimentales
- PacBio (long read), pashing mediante short-read de Illumina
- Generación de grafos

Pangenoma

Draft en 2023

Representa la d

Ensamblaje de

- Resolución
- PacBio (long
- Generación

Article | Open access | Published: 10 May 2023

A draft human pangenome reference

Wen-Wei Liao, Mobin Asri, Jana Ebler, Daniel Doerr, Marina Haukness, Glenn Hickey, Shuangjia Lu, Julian K. Lucas, Jean Monlong, Haley J. Abel, Silvia Buonaiuto, Xian H. Chang, Haoyu Cheng, Justin Chu, Vincenza Colonna, Jordan M. Eizenga, Xiaowen Feng, Christian Fischer, Robert S. Fulton, Shilpa Garg, Cristian Groza, Andrea Guarracino, William T. Harvey, Simon Heumos, … Benedict Paten + Show authors

Nature **617**, 312–324 (2023) | Cite this article

263k Accesses | **369** Citations | **3147** Altmetric | Metrics

Abstract

Here the Human Pangenome Reference Consortium presents a first draft of the human pangenome reference. The pangenome contains 47 phased, diploid assemblies from a cohort of genetically diverse individuals[1]. These assemblies cover more than 99% of the expected sequence in each genome and are more than 99% accurate at the structural and base pair levels. Based on alignments of the assemblies, we generate a draft pangenome that captures known variants and haplotypes and reveals new alleles at structurally complex loci. We also add 119 million base pairs of euchromatic polymorphic sequences and 1,115 gene duplications relative to the existing reference GRCh38. Roughly 90 million of the additional base pairs are derived from structural variation. Using our draft pangenome to analyse short-read data reduced small variant discovery errors by 34% and increased the number of structural variants detected per haplotype by 104% compared with GRCh38-based workflows, which enabled the typing of the vast majority of structural variant alleles per sample.

https://www.nature.com/articles/s41586-023-05896-x

Formatos de ficheros de alineamiento

Formatos de almacenamiento de secuencias:

FASTA

FASTQ

uBAM

Formatos de intervalos

GTF

GFF

BED

Formatos de alineamiento

SAM

BAM

CRAM