Anotación funcional de variantes

Mario Solís López
08/04/2025

Anotación funcional de variantes

Sesión 6:

- Fuentes de anotación
- Objetivo de la anotación en el diagnóstico de enfermedades raras
- Herramientas de anotación
- Agregadores web de datos

Anotación

- Secuenciación masiva → ↑ variantes
- Necesidad → Identificación de variantes funcionalmente importantes
- Anotación → Integración de información funcional y genómica
  - Facilitar el filtrado y priorización de variantes
  - Determinación de la variante causal

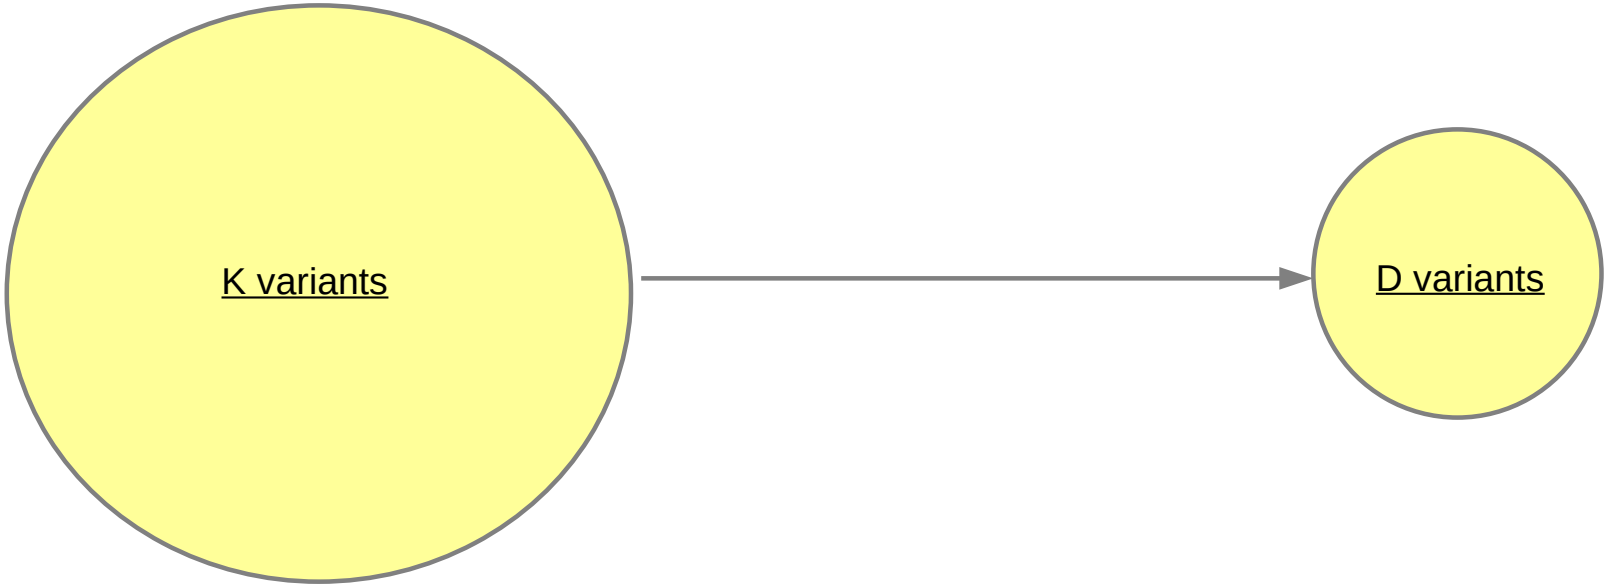

Anotación

- Anotación de las variantes determinadas:
  - Localización genómica
  - Consecuencia funcional
  - Frecuencia poblacional
  - Identificador en bases de datos
  - Información clínica
  - Predictores de patogenicidad
  - Conservación filogenética
  - Controles
- Errores en la anotación → falsos negativos

Anotación

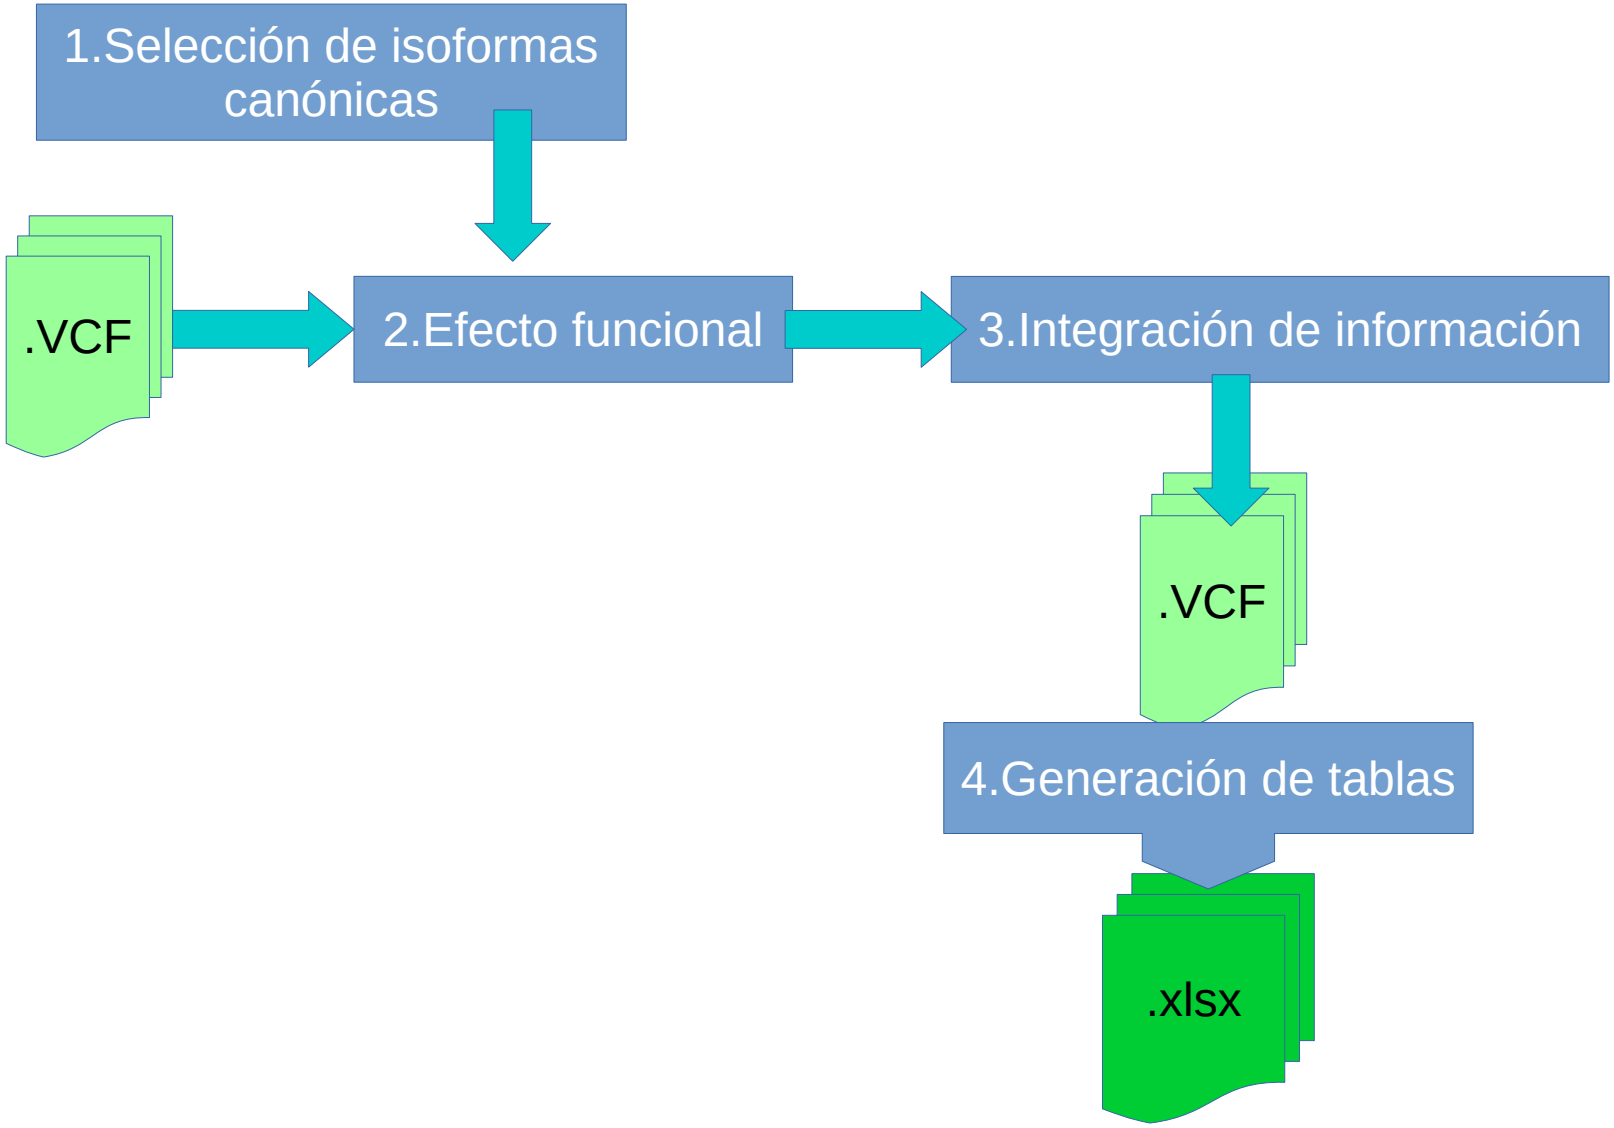
1.Selección de isoformas canónicas
.VCF
2.Efecto funcional
3.Integración de información
.VCF
4.Generación de tablas
.xlsx

Selección de isoforma canónica

- Cimientos → Consecuencia funcional
- La selección del tránscrito es vital para el análisis de variantes genómicas
  - Consecuencias distintas para distintos tránscritos del mismo gen
- Base de datos de tránscritos
  - *RefSeq*
  - *UCSC* → Anotación de los tránscritos provista por *NCBI RefSeq*
- Múltiples isoformas
  - Isoforma canónica → *APPRIS*

HGNC
HUGO Gene Nomenclature Committee

RefSeq: NCBI Reference Sequence Database

A comprehensive, integrated, non-redundant, well-annotated set of reference sequences including genomic, transcript, and protein.

{A}

Selección de isoforma canónica

- HGNC
  - *HUGO* Gene Nomenclature Committee
  - Aprobar símbolos y nombres únicos para los genes humanos
  - *HGNC Database → www.genenames.org*

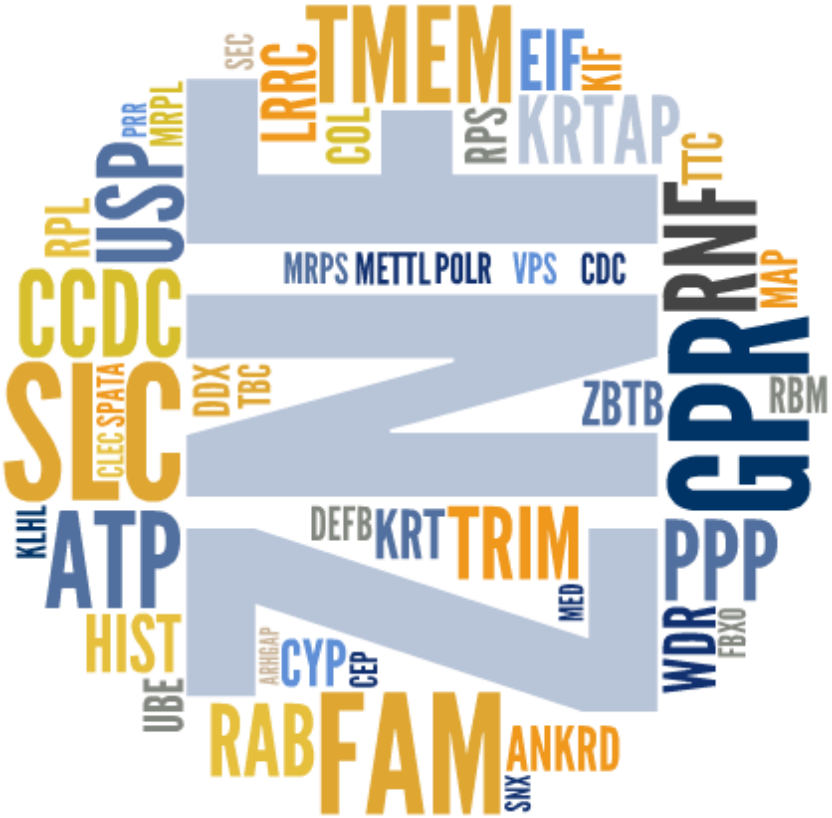

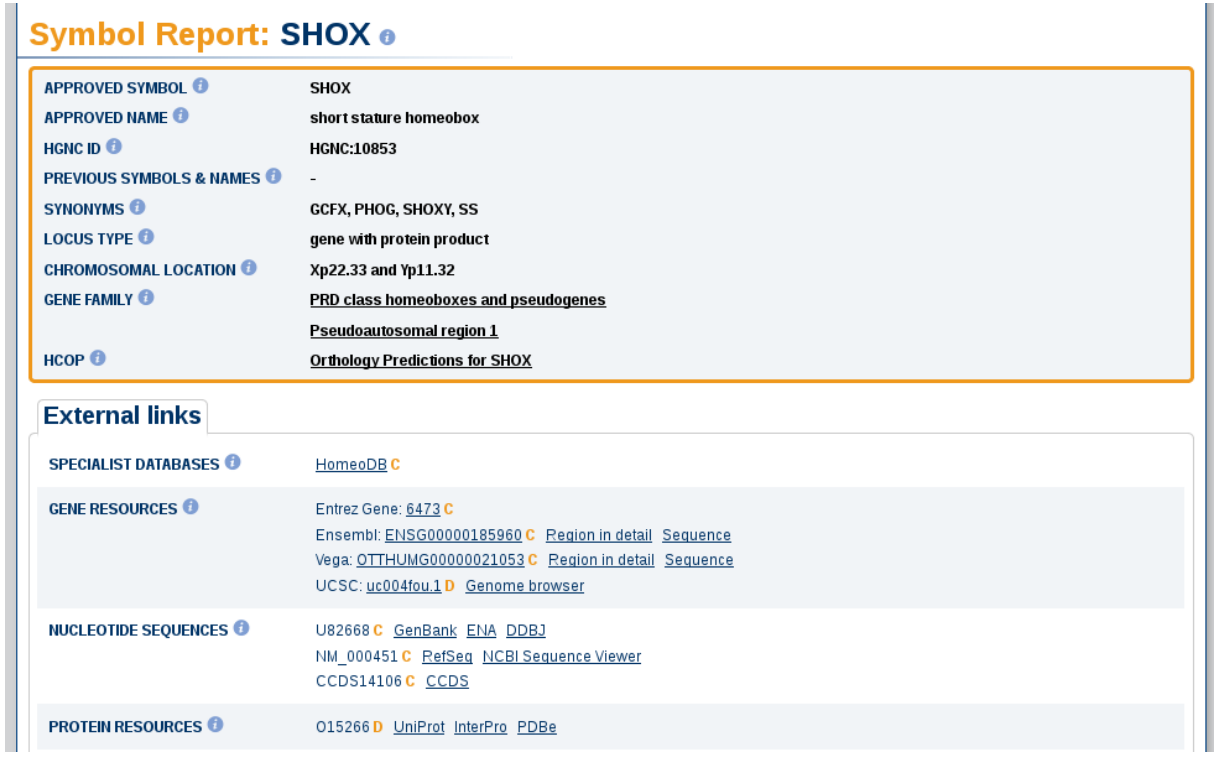

Symbol Report: SHOX

APPROVED SYMBOL	SHOX
APPROVED NAME	short stature homeobox
HGNC ID	HGNC:10853
PREVIOUS SYMBOLS & NAMES	-
SYNONYMS	GCFX, PHOG, SHOXY, SS
LOCUS TYPE	gene with protein product
CHROMOSOMAL LOCATION	Xp22.33 and Yp11.32
GENE FAMILY	PRD class homeoboxes and pseudogenes Pseudoautosomal region 1
HCOP	Orthology Predictions for SHOX

External links

SPECIALIST DATABASES	HomeoDB C
GENE RESOURCES	Entrez Gene: 6473 C Ensembl: ENSG00000185960 C Region in detail Sequence Vega: OTTHUMG00000021053 C Region in detail Sequence UCSC: uc004fou.1 D Genome browser
NUCLEOTIDE SEQUENCES	U82668 C GenBank ENA DDBJ NM_000451 C RefSeq NCBI Sequence Viewer CCDS14106 C CCDS
PROTEIN RESOURCES	O15266 D UniProt InterPro PDBe

Selección de isoforma canónica

- RefSeq
  - Base de datos **curada**
  - Conjunto de secuencias completa, integrada y no redundante, que incluye *DNA, RNA* y proteínas
  - *UCSC* → proporciona las coordenadas de los tránscritos de *RefSeq*

RefSeq: NCBI Reference Sequence Database

A comprehensive, integrated, non-redundant, well-annotated set of reference sequences including genomic, transcript, and protein.

UCSC

Selección de isoforma canónica

- APPRIS
  - Desarrollado dentro del consorcio de *ENCODE*
  - Información funcional, estructural y de conservación para anotar isoformas
  - 5 clases principales (+ 2 Alternativas)

{APPRIS}

Annotating principal splice isoforms

Principal Isoform flags

APPRIS selects a single CDS variant for each gene as the 'PRINCIPAL' isoform based on the range of protein features. Principal isoforms are tagged with the numbers 1 to 5, with 1 being the most reliable. The definition of the flags are as follows:

- **PRINCIPAL:1**
  Transcript(s) expected to code for the main functional isoform based solely on the core modules in the APPRIS database. The APPRIS core modules map protein structural and functional information and cross-species conservation to the annotated variants.
- **PRINCIPAL:2**
  Where the APPRIS core modules are unable to choose a clear principal variant (approximately 25% of human protein coding genes), the database chooses two or more of the CDS variants as "candidates" to be the principal variant.

  If one of these candidates has a distinct CCDS identifier it is selected as the principal variant for that gene. A CCDS identifier shows that there is consensus between RefSeq and GENCODE/Ensembl for that variant, guaranteeing that the variant has cDNA support.
- **PRINCIPAL:3**
  Where the APPRIS core modules are unable to choose a clear principal variant and there more than one of the variants have distinct CCDS identifiers, APPRIS selects the variant with lowest CCDS identifier as the principal variant. The lower the CCDS identifier, the earlier it was annotated.

  Consensus CDS annotated earlier are likely to have more cDNA evidence. Consecutive CCDS identifiers are not included in this flag, since they will have been annotated in the same release of CCDS. These are distinguished with the next flag.

  In addition, there is more than one variant with a distinct (but consecutive) CCDS identifiers, APPRIS choose the variant when all splice junctions are supported by at least one non-suspect mRNA. This information is reported by the method Transcript Support Level (TSL), which is a method to highlight the well-supported and poorly-supported transcript models for users. The method relies on the primary data that can support full-length transcript structure: mRNA and EST alignments supplied by UCSC and Ensembl.
- **PRINCIPAL:4**
  Where the APPRIS core modules are unable to choose a clear principal CDS and there is more than one variant with a distinct (but consecutive) CCDS identifiers and all the splice junctions are not well-supported, APPRIS selects the longest CCDS isoform as the principal variant.
- **PRINCIPAL:5**
  Where the APPRIS core modules are unable to choose a clear principal variant and none of the candidate variants are annotated by CCDS, APPRIS selects the longest of the candidate isoforms as the principal variant.

For genes in which the APPRIS core modules are unable to choose a clear principal variant (approximately 25% of human protein coding genes) the "candidate" variants not chosen as principal are labeled in the following way:

Predicción de consecuencia funcional

- Una vez seleccionadas las isoformas…
  - Predicción de la consecuencia funcional
    - **SnpEff, VEP, ANNOVAR**
- Efecto (o consecuencia) funcional
  - cómo afecta un cambio en la secuencia codificante en el producto de un gen
- Múltiples efectos
- Se emplean términos de Sequence Ontology (SO) → **<u>¡normalización!</u>**
- Cada término SO tiene asociado un impacto putativo:
  - HIGH → La variante tiene un impacto disruptivo en la proteína (truncamiento...)
  - MODERATE → No disruptivo, pero afecta a la efectividad de la proteína
  - LOW → Poco probable que afecte a la proteína
  - MODIFIER → variantes no codificantes

Predicción de consecuencia funcional

Putative Impact	Sequence Ontology term
HIGH	chromosome_number_variation
HIGH	exon_loss_variant
HIGH	frameshift_variant
HIGH	rare_amino_acid_variant
HIGH	splice_acceptor_variant
HIGH	splice_donor_variant
HIGH	start_lost
HIGH	stop_gained
HIGH	stop_lost
HIGH	transcript_ablation
MODERATE	3_prime_UTR_truncation & exon_loss
MODERATE	5_prime_UTR_truncation & exon_loss_variant
MODERATE	coding_sequence_variant
MODERATE	conservative_inframe_deletion
MODERATE	conservative_inframe_insertion
MODERATE	disruptive_inframe_deletion
MODERATE	disruptive_inframe_insertion
MODERATE	missense_variant
MODERATE	regulatory_region_ablation
MODERATE	splice_region_variant
MODERATE	TFBS_ablation
LOW	5_prime_UTR_premature_start_codon_gain_variant
LOW	initiator_codon_variant
LOW	splice_region_variant
LOW	start_retained
LOW	stop_retained_variant
LOW	synonymous_variant
MODIFIER	3_prime_UTR_variant
MODIFIER	5_prime_UTR_variant
MODIFIER	coding_sequence_variant
MODIFIER	conserved_intergenic_variant
MODIFIER	conserved_intron_variant
MODIFIER	downstream_gene_variant
MODIFIER	exon_variant
MODIFIER	feature_elongation
MODIFIER	feature_truncation
MODIFIER	gene_variant
MODIFIER	intergenic_region
MODIFIER	intragenic_variant
MODIFIER	intron_variant
MODIFIER	mature_miRNA_variant
MODIFIER	miRNA
MODIFIER	NMD_transcript_variant
MODIFIER	non_coding_transcript_exon_variant
MODIFIER	non_coding_transcript_variant
MODIFIER	regulatory_region_amplification
MODIFIER	regulatory_region_variant
MODIFIER	TF_binding_site_variant
MODIFIER	TFBS_amplification
MODIFIER	transcript_amplification
MODIFIER	transcript_variant
MODIFIER	upstream_gene_variant

Integración de fuentes de información

- En función de:
  - Cota genómica
  - Cambio

- Incorporación de información procedente de:
  - Bases de datos clínicas
  - Predictores
  - Estudios poblacionales
  - Análisis de genoma
- Protocolos de filtrado y priorización

Integración de fuentes de información

- En función de:
  - Cota genómica
  - Cambio

- Incorporación de información procedente de:
  - Bases de datos clínicas
  - Predictores
  - Estudios poblacionales
  - Análisis de genoma
- Protocolos de filtrado y priorización

Bases de datos clínicas

- dbSNP
- ClinVar
- ClinGen

dbSNP

- The Single Nucleotide Polymorphism Database
- Archivo de dominio público de:
  - Polimorfismos (SNP)
  - Indels pequeños
  - Tandem repeats...
- Identificador rs (refSNP) o ss (submitted SNPs)
  - Conjunto de varios polimorfismos o repeats

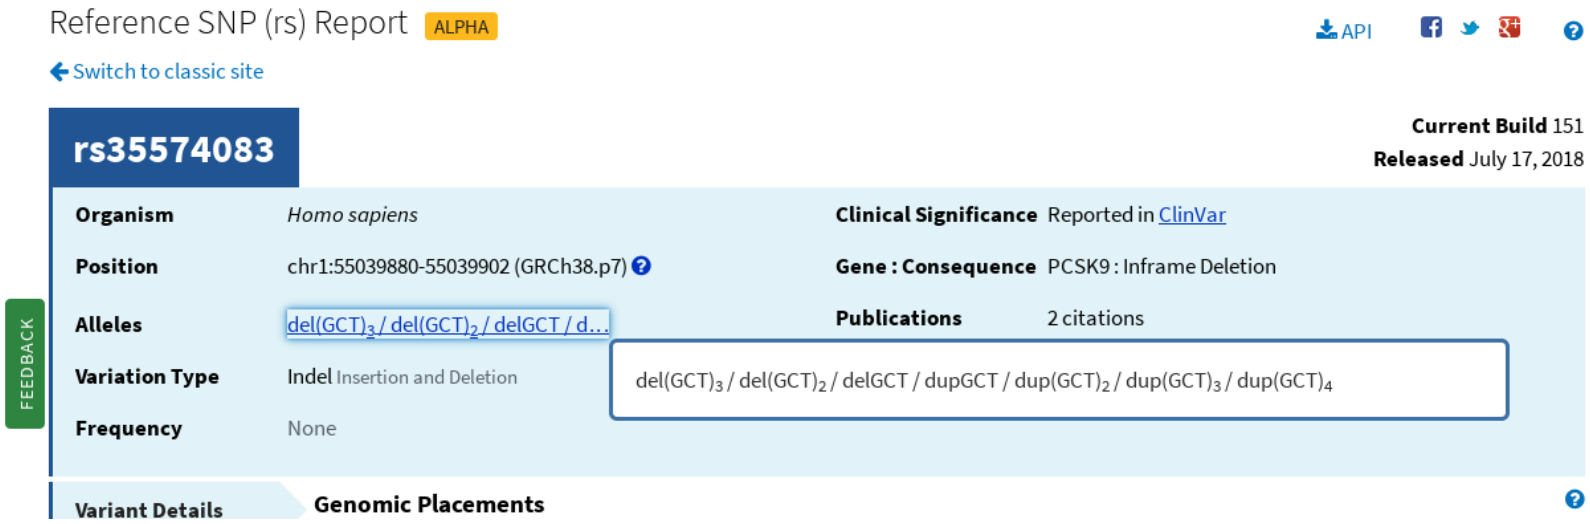

ClinVar

- Archivo de interpretación de la significancia clínica de variantes
  - Acepta entrega de diversa complejidad
  - Interpretación → análisis (estrellas 0-4)
    - 0 → no hay interpretación, o no se proporcionan pruebas
    - 1 → se interpreta con pruebas; 1 o varias con conflicto
    - 2 → varios reportes sin conflicto
    - 3 → panel de expertos → ~0,02%
    - 4 → guías prácticas

Integración de fuentes de información

- En función de:
  - Cota genómica
  - Cambio

- Incorporación de información procedente de:
  - Bases de datos clínicas
  - Predictores
  - Estudios poblacionales
  - Análisis de genoma
- Protocolos de filtrado y priorización

Predictores de Patogenicidad

- Patogenicidad
  - CADD
  - SIFT
  - PolyPhen2
  - Mutation Assesor
  - FATHMM
  - VEST3
- Conservación
  - GERP++
  - PhyloP
  - PhastCons
- Splicing
  - ADA
  - RF
  - SpliceAI

Predictores de Patogenicidad

- **<u>Patogenicidad</u>**
  - **CADD**
  - **SIFT**
  - **PolyPhen2**
  - **Mutation Assesor**
  - **FATHMM**
  - **VEST3**
- Conservación
  - GERP++
  - PhyloP
  - PhastCons
- Splicing
  - ADA
  - RF
  - SpliceAI

CADD

- **Combined Annotation- Dependent Depletion**
- 2014
- Modelo de entrenamiento:
  - Variantes proxy-neutral
  - Variantes proxy-deletéreas
  - Se anotan con conservación, modificaciones epigenéticas, contexto genético
- **SNVs e InDels**

- Score en escala Phred → probabilidad de que el cambio sea patogénico
- Priorización de variantes

CADD

- **Combined Annotation- Dependent Depletion**
- 2014
- Modelo de entrenamiento:
  - Variantes pr
  - Variantes pr
  - Se anotan c ntexto genético
- **SNVs e InDels**
- Score en escala génico
- Priorización de v

Clase	Intervalo
Bening	S < 11
Possibly Damaging	S c [11,14)
Damaging	S >= 14

SIFT

- Basado en homología de secuencia
- Tolerancia funcional

Clase	Intervalo
Bening	S > 0.23
Possibly Damaging	S c (0.06,0.23]
Damaging	S <= 0.06

PolyPhen2

- SNVs no sinónimas
- Información estructural y de secuencia
- Umbrales in-house

Clase	Intervalo
Bening	S < 0.03
Possibly Damaging	S c [0.03,0.3)
Damaging	S >= 0.3

MutationAssesor

- Conservación de aminoácidos en proteínas homólogas → MSA
- Entrenamiento → COSMIC
- Validación → polimorfismos y variantes asociadas a enfermedades genéticas
- Umbrales in-house

Clase	Intervalo
Bening	S >= 1.8
Possibly Damaging	S c [1.12,1.8)
Damaging	S < 1.12

FATHMM

- Cadenas ocultas de Markov (HMM)
- Pesos de patogenicidad → toleracia de dominios a las mutaciones
- Umbrales in-house

Clase	Intervalo
Bening	S > 0.8
Possibly Damaging	S c (-1,0.8]
Damaging	S <= -1

VEST3

- Clasificador supervisado → Validado con HGMD y EVS
- Entre 0 y 1

Clase	Intervalo
Bening	S < 0.17
Possibly Damaging	S c [0.17, 0.65)
Damaging	S >= 0.65

Predictores de Patogenicidad

- Patogenicidad
  - CADD
  - SIFT
  - PolyPhen2
  - Mutation Assesor
  - FATHMM
  - VEST3
- **Conservación**
  - **GERP++**
  - **PhyloP**
  - **PhastCons**
- Splicing
  - ADA
  - RF
  - SpliceAI

GERP++

- MSA → elementos genómicos con alta constricción evolutiva
- RS → rejected substitutions

Clase	Intervalo
Conserved	RS > 2.45
Non conserved	RS <= 2.45

PhyloP

- MSA → múltiples especies (vertebrados, placentarios)
- P-values vs modelo neutro → s= -log(p):
  - Más conservado → s > 0
  - Menos conservado → s < 0

PhastCons

- MSA → múltiples especies (vertebrados, placentarios)
- Regiones conservadas → HMM
- Scores de probabilidad de selección negativa

Predictores de Patogenicidad

- Patogenicidad
  - CADD
  - SIFT
  - PolyPhen2
  - Mutation Assesor
  - FATHMM
  - VEST3
- Conservación
  - GERP++
  - PhyloP
  - PhastCons
- **Splicing**
  - **ADA**
  - **RF**
  - **SpliceAI**

ADA

- Clasificador ensemble → Ada (Adaptative Boosting)

Clase	Intervalo
Bening	s<=0.612
Possibly damaging splicing site	s>0.612

RF

- Clasificador ensemble → Random Forests

Clase	Intervalo
Bening	s<=0.598
Possibly damaging splicing site	s>0.598

SpliceAI

- 2019
- Algoritmo Deep Learning → Illumina
- Modela spliceosoma
- Utiliza 10k nt flanqueantes → contexto es vital en el entrenamiento del modelo
- Mejora sustancialmente frente a otros predictores de splicing

	Top-*k* accuracy	PR-AUC
SpliceAI-80nt	0.57	0.60
SpliceAI-400nt	0.90	0.95
SpliceAI-2k	0.93	0.97
SpliceAI-10k	**0.95**	**0.98**
GeneSplicer	0.30	0.23
MaxEntScan	0.22	0.15
NNSplice	0.22	0.15

SpliceAI

- 2019
- Algoritmo Deep Learning → Illumina
- Modela spliceosoma
- Utiliza 10k nt flanqueantes → contexto es vital en el entrenamiento del modelo
- Mejora sustancialmente frente a otros predictores de splicing

- Rangos
  - 0.2 – 0.5 → Likely Pathogenic
  - 0.5 – 0.8 → recommended/pathogenic
  - 0.8 – 1.0 → high precision/pathogenic

Integración de fuentes de información

- En función de:
  - Cota genómica
  - Cambio

- Incorporación de información procedente de:
  - Bases de datos clínicas
  - Predictores
  - Estudios poblacionales
  - Análisis de genoma
- Protocolos de filtrado y priorización

Estudios poblacionales

- The 1000 Genomes Project
- ESP6500
- ExAC
- gnomAD

- Términos comunes:
  - AC → Allele Count
  - AN → Allele Number
  - AF → Allele Frequency (AC/AN)
  - Hom → Count of Homozygous
  - Hem → Count of Hemizygous

The 1000 Genomes Project

- Análisis de 2504 individuos de 26 poblaciones
- Se engloban en 5 poblaciones generales: AMR, EAS, SAS, AFR, EUR
- Phase 3 → GRCh37 (+decoy)

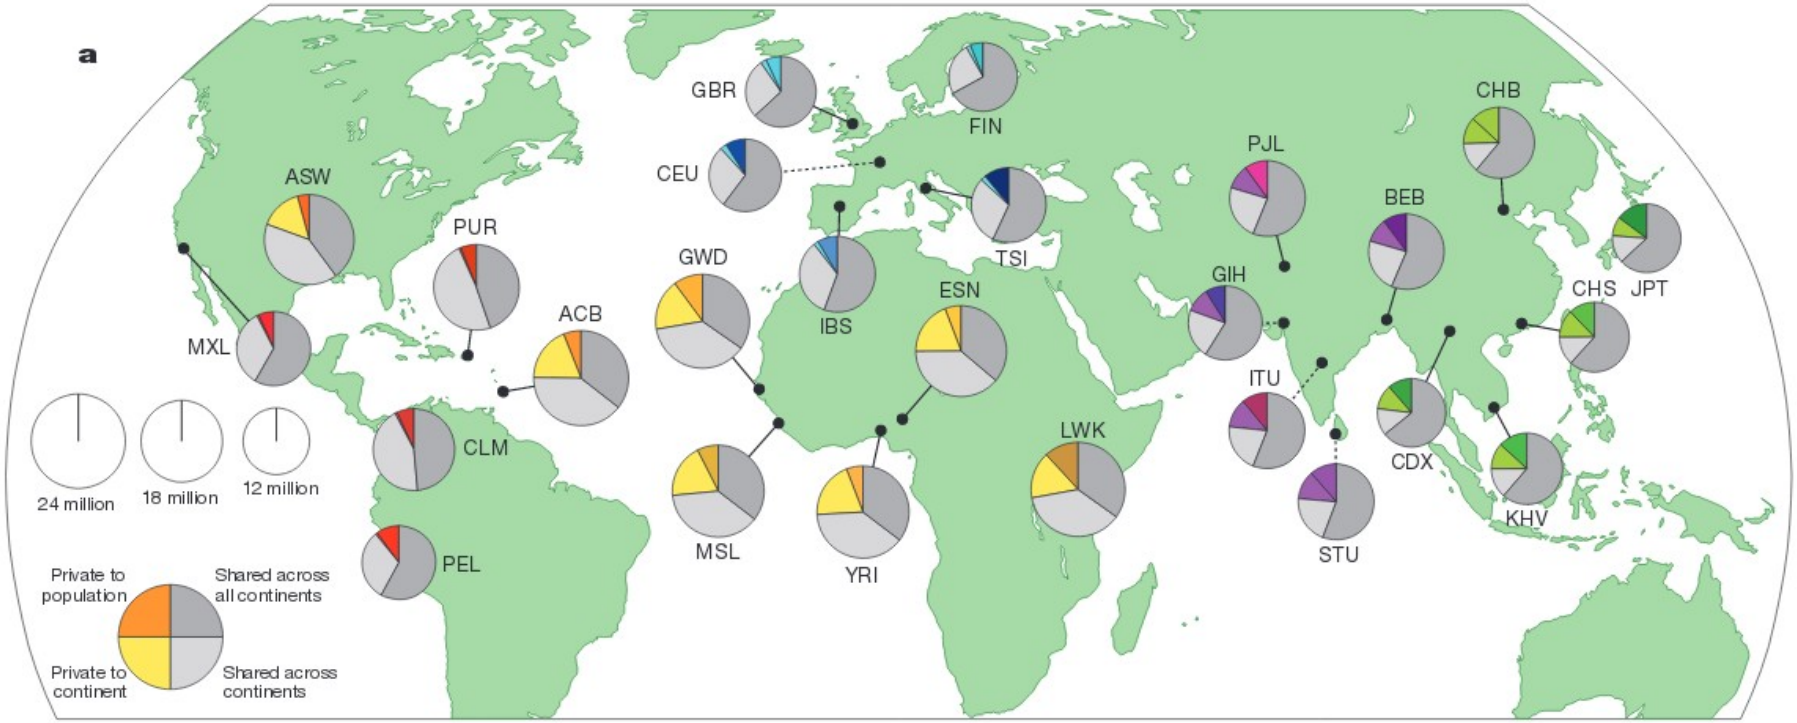

EVS - ESP6500

- Análisis de 6503 exomas de individuos no relacionados, con clínica
  - 2203 African-Americans
  - 4300 European-Americans
- GRCh37
- Release ESP6500SI-V2

ExAC

- Análisis de datos de alta calidad de secuenciación masiva de exomas de ~ 60K individuos
  - 91K individuos de partida → filtrado
  - Ancestralidad conocida → predicción
    - AFR
    - AMR
    - EAS
    - FIN
    - NFE
    - SAS
    - OTH
- GRCh37/hg19

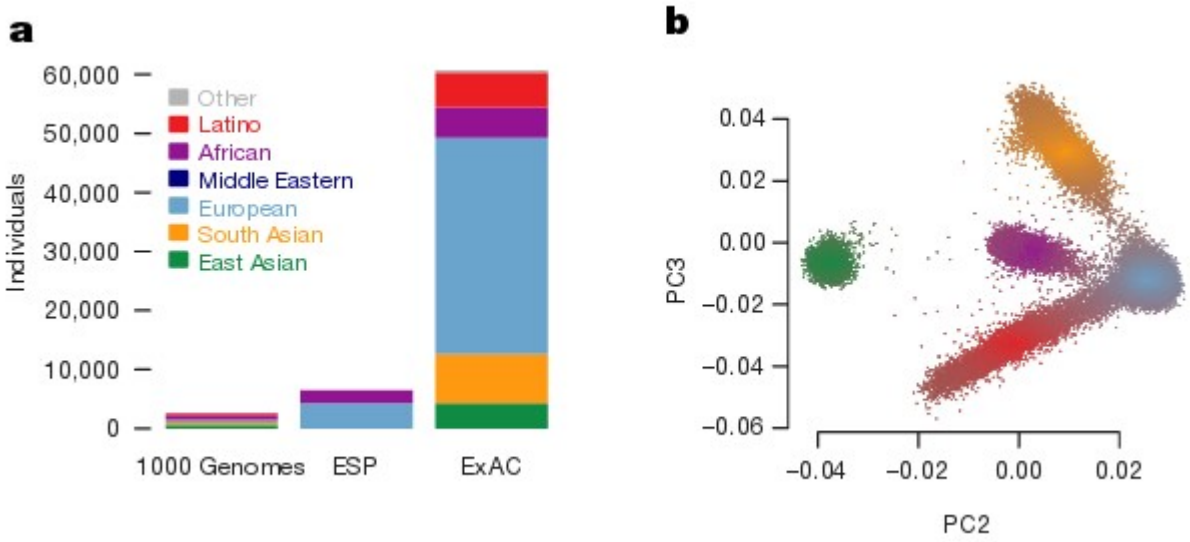

gnomAD

- Análisis de datos de alta calidad de secuenciación masiva de exomas y genomas
  - 15.5K genomas
  - 123K exomas
- Filtros
- GRCh37/hg19

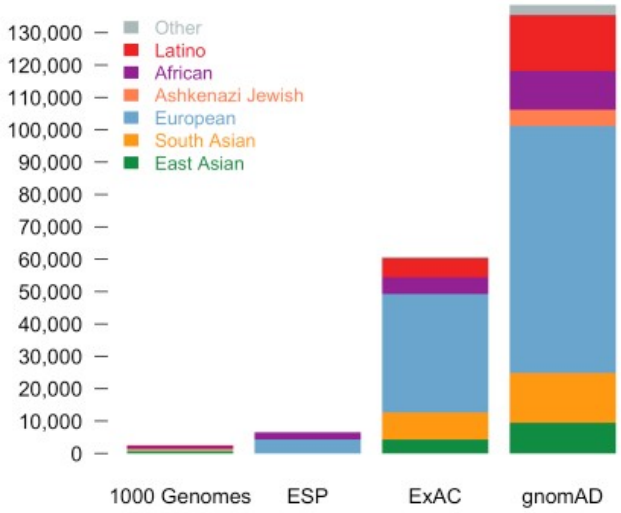

POPULATION	DESCRIPTION	GENOMES	EXOMES	TOTAL
AFR	African/African American	4,368	7,652	12,020
AMR	Admixed American	419	16,791	17,210
ASJ	Ashkenazi Jewish	151	4,925	5,076
EAS	East Asian	811	8,624	9,435
FIN	Finnish	1,747	11,150	12,897
NFE	Non-Finnish European	7,509	55,860	63,369
SAS	South Asian	0	15,391	15,391
OTH	Other (population not assigned)	491	2,743	3,234
	Total	15,496	123,136	138,632

gnomAD

- Segregación de los datos en múltiples *subsets*:
  - Controls-only
  - Non-neuro
  - Non-cancer
  - Non-TOPMed (*Trans-Omics for Precision Medicine*)

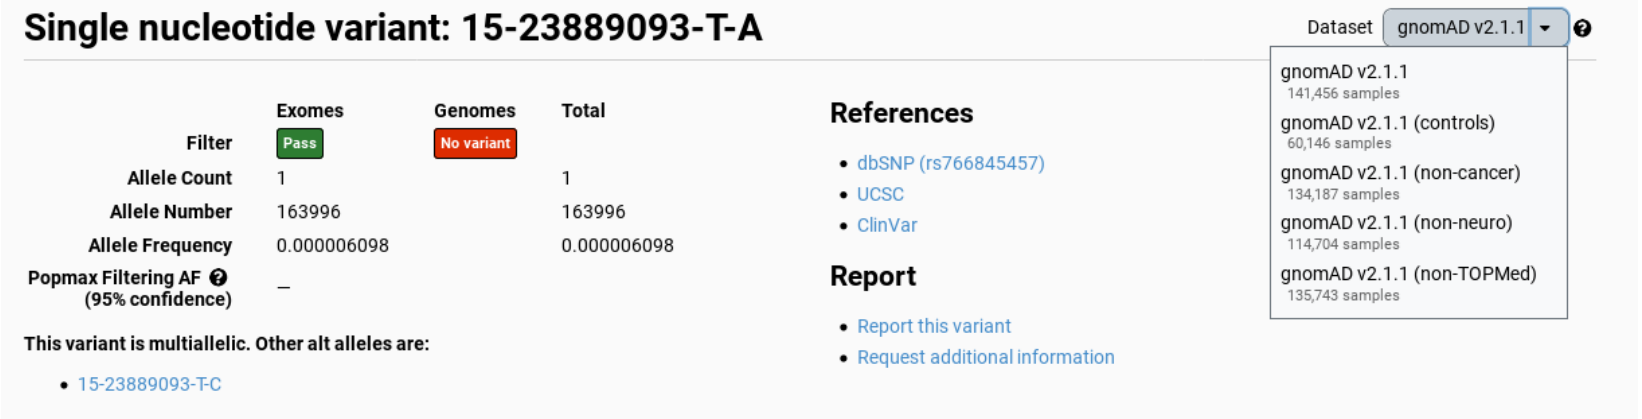

Single nucleotide variant: 15-23889093-T-A

Dataset gnomAD v2.1.1

- gnomAD v2.1.1 — 141,456 samples
- gnomAD v2.1.1 (controls) — 60,146 samples
- gnomAD v2.1.1 (non-cancer) — 134,187 samples
- gnomAD v2.1.1 (non-neuro) — 114,704 samples
- gnomAD v2.1.1 (non-TOPMed) — 135,743 samples

	Exomes	Genomes	Total
Filter	Pass	No variant	
Allele Count	1		1
Allele Number	163996		163996
Allele Frequency	0.000006098		0.000006098
Popmax Filtering AF (95% confidence)	–		

This variant is multiallelic. Other alt alleles are:

- 15-23889093-T-C

References

- dbSNP (rs766845457)
- UCSC
- ClinVar

Report

- Report this variant
- Request additional information

Pérdida de función – ExAC | gnomAD

- Catálogo de variantes alta calidad
  - Sensibilidad de los genes a la disrupción
  - Identificar genes intolerantes a la pérdida de función (*LOF*)
- ExAC
  - pLI : probabilidad de la intoleracia a la pérdida de función
  - Variantes raras por gen
  - Desviación frente a lo esperado
  - pLI > 0.9 → Genes intolerantes a la pérdida de función

Pérdida de función – ExAC | gnomAD

- Catálogo de variantes alta calidad
  - Sensibilidad de los genes a la disrupción
  - Identificar genes intolerantes a la pérdida de función (*LOF*)
- gnomAD
  - Mayor número de muestras
  - Evaluar el ratio observado/esperado a lo largo de un modelo continuo
  - Intervalo de confianza
  - Mediana de 48% → mayor parte de los genes presentan selección moderada frente a las variantes de pérdida de función
  - Intervalo superior → LOEUF (loss-of-function observed/expected upper bound fraction)
  - PLI > 0.9 → ~ 0.36 LOEUF

MAGEL2 MAGE-like 2

Ensembl gene ID	ENSG00000254585
Ensembl transcript ID	ENST00000532292 (canonical)
UCSC Browser	15:23888692-23891176
GeneCards	MAGEL2
OMIM	605283

Gene Constraint

Category	Exp. SNVs	Obs. SNVs	Constraint metrics
Synonymous	157.6	185	Z = -1.72 o/e = 1.17 (1.04 - 1.33)
Missense	368.6	399	Z = -0.56 o/e = 1.08 (1 - 1.18)
LoF	20.2	2	pLI = 0.98 o/e = 0.1 (0.04 - 0.31)

exome genome Save plot

Pérdida de función – ExAC | gnomAD

- *gnomAD* → visión panorámica de los cambios en el genoma humano

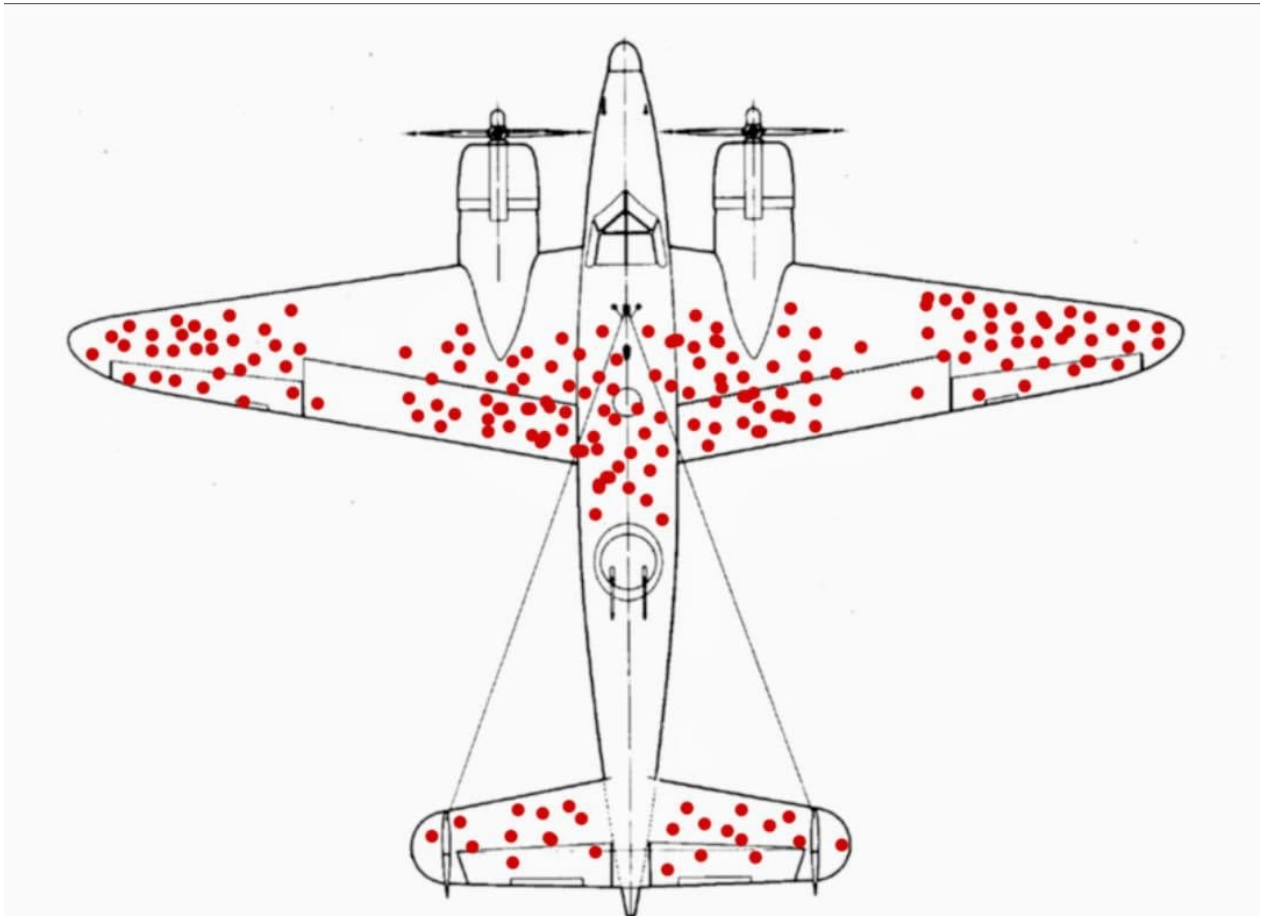

Pérdida de función – CCR

- *gnomAD* → visión panorámica de los cambios en el genoma humano
- Regiones codificantes bajo selección extrema
- Identifica segmentos codificantes que no presentan variantes que alteran proteína en *gnomAD* (v2.0.2)
- Ventanas genómicas con un percentil *CCR*:
  - A mayor score *CCR* → mayor grado de restricción
  - Percentiles
- Priorización de variantes / interpretación de variantes *de novo*
- Suele correlar con el pLI... a veces...

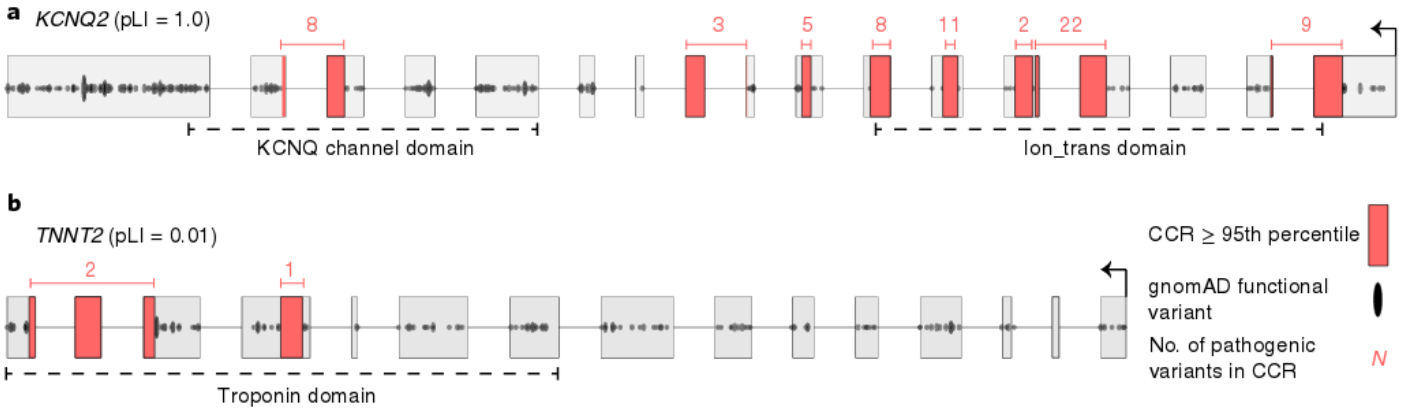

Pérdida de función – CCR

- *gnomAD* → visión panorámica de los cambios en el genoma humano
- Regiones codificantes bajo selección extrema
- Ider
  (v2.
- Ven
  -
  -
- Prio
- Sue

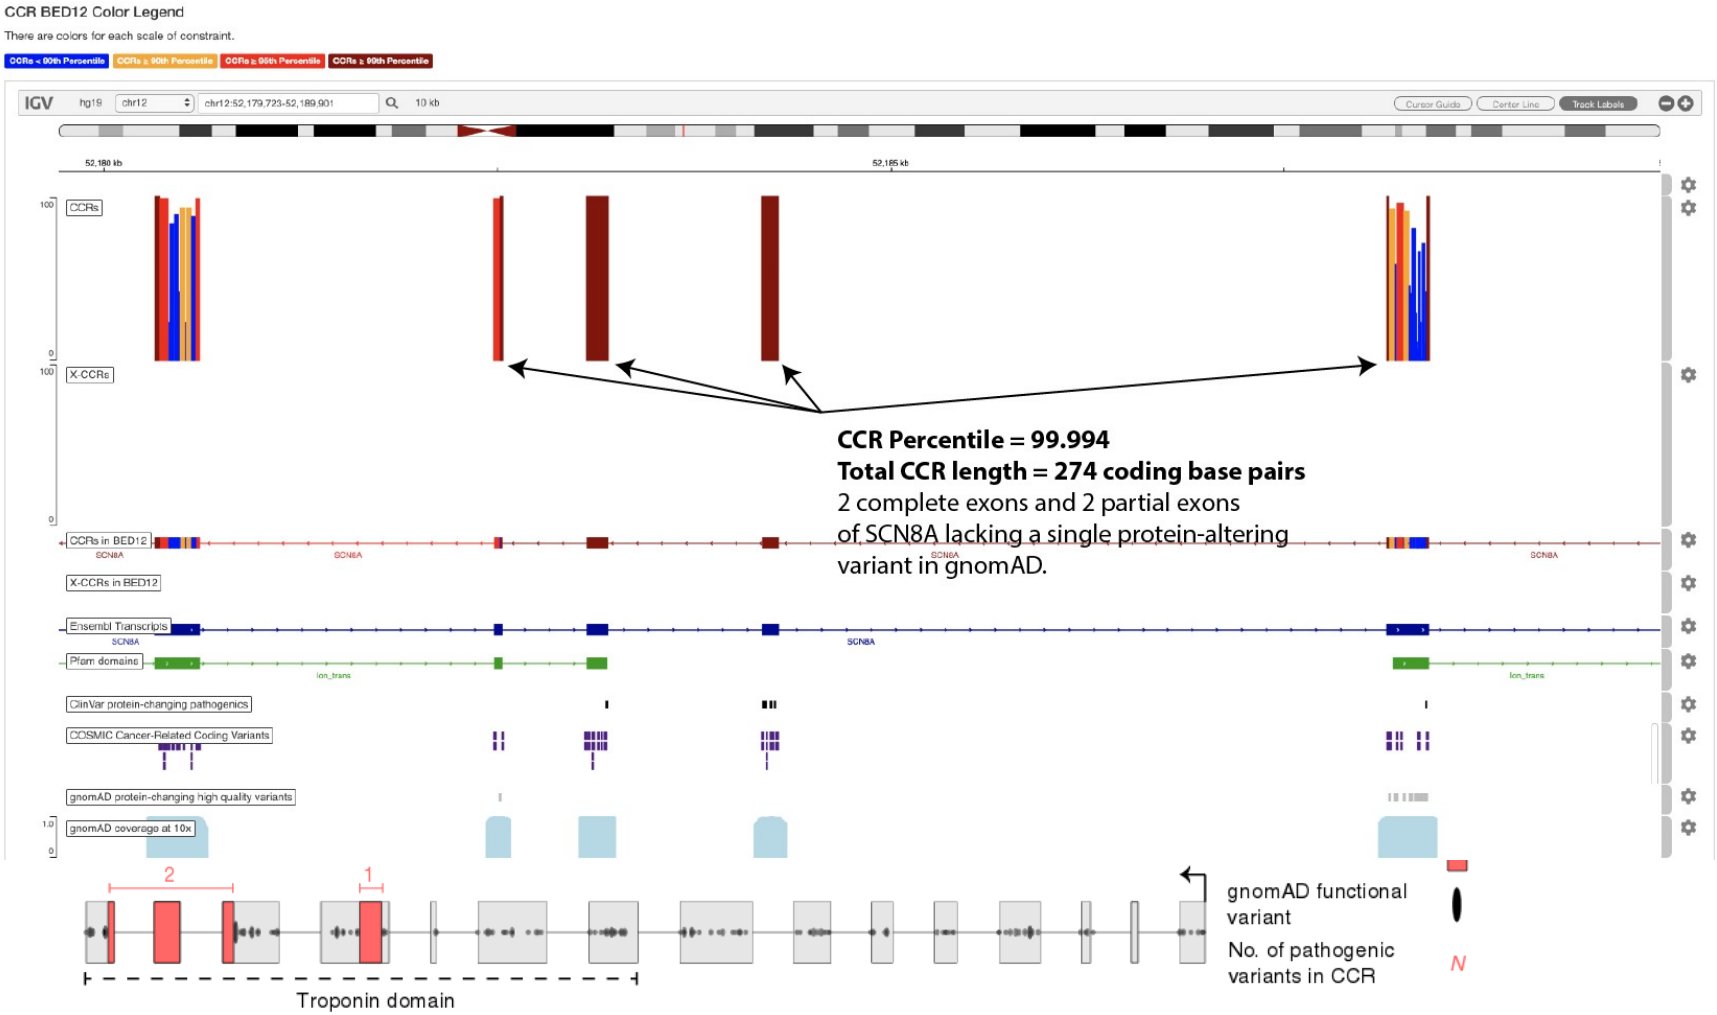

Integración de fuentes de información

- En función de:
  - Cota genómica
  - Cambio

- Incorporación de información procedente de:
  - Bases de datos clínicas
  - Predictores
  - Estudios poblacionales
  - Análisis de genoma
- Protocolos de filtrado y priorización

RepeatMasker (RMSK)

- Criba secuencias de DNA
  - Repeticiones intercaladas
  - Regiones de baja complejidad
- Repbase Update → librería de repeticiones
- Clases

RepeatMasker (RMSK)

- Criba secuencias de DNA
  - Repeticiones intercaladas

DNAtr	DNA repeat elements
LCR	Low complexity repeats
LINE (L1,L2)	Long interspersed nuclear elements
LTR	Long terminal repeat elements (LTR), which include retroposons
RC_Helitron	Rolling Circle
RNA repeats	RNA, tRNA, rRNA, snRNA, scRNA, srpRNA
satellite	Satellite repeats
simple	Simple repeats (micro-satellites)
SINE (Alu)	Short interspersed nuclear elements, which include ALUs
unknown	Desconocidos

Segmental Duplications

- Bloques duplicados → entre 1-200 kb
- Papel fundamental
  - Evolución de genes
  - Desarrollo de enfermedades genéticas
- Coordenadas cromosómicas de la duplicación segmental
- Versión → 2011-10-25 (UCSC)

Conclusiones

- Correcta anotación es fundamental
  - filtrar adecuadamente → determinar mutación causal
- Constante evolución
  - Adaptar los protocolos de análisis con los nuevos estudios
  - Casos no resueltos → reanálisis no sólo primario → también anotación
- Nuevas bases de datos, estudios y predicciones
  - 2018 ~ 2025
- Futuro
  - Nuevas técnicas experimentales
  - Nuevos estudios
  - Nuevos genomas de referencia