Bioinformática Clínica
y
Técnicas de secuenciación

Mario Solís López
24/03/2025

Bioinformática Clínica - Técnicas de secuenciación

Sesión 1 – 24/03/2025:

- Laboratorios de Bioinformática Clínica
- Técnicas de secuenciación empleadas en rutina diagnóstica
- Datos crudos generados
- Revisión de los datos generados
- Tipo de eventos genómicos y genéticos a determinar
- Limitaciones de las técnicas

- Revisión de intereses
- Revisión de datos y herramientas

Bioinformática Clínica - Técnicas de secuenciación

Sesión 1 – 24/03/2025:

- **Laboratorios de Bioinformática Clínica**
- **Técnicas de secuenciación empleadas en rutina diagnóstica**
- **Datos crudos generados**
- **Revisión de los datos generados**
- **Tipo de eventos genómicos y genéticos a determinar**
- **Limitaciones de las técnicas**

- Revisión de intereses
- Revisión de datos y herramientas

Pruebas diagnósticas en un servicio de genética

El paciente acude a la consulta de geńetica o el especialista pide un prueba.

El genetista clínico evalúa el caso y puede solicitar alguna prueba genética en función de la sospecha diagnóstica.

?

Dependiendo de la sospecha así se inspecciona el genoma, dependiendo del grado de detalle que se quiera

Cariotipo
~ 5-10 Mpb
(cromosoma)

FISH
~ 100,000 pb
(regiones cromosómicas)

aCGH
~ 25,000- 400,000 pb
(genoma completo)

Sec. Sanger
1 pb
(gen a gen)

Sec. Masiva (NGS)
1 pb
(genoma completo)

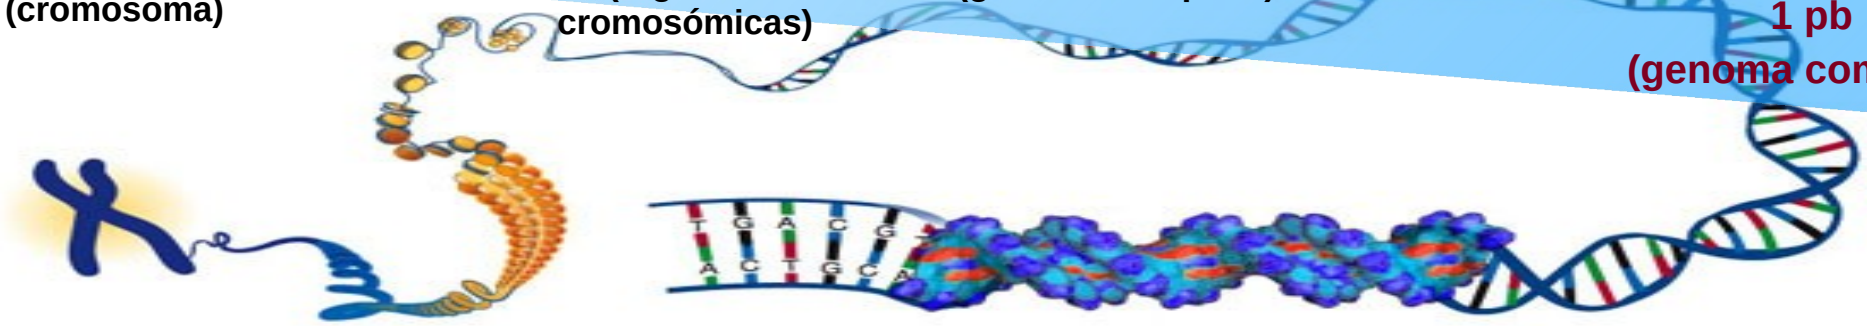

DNA-Seq: prueba diagnóstica

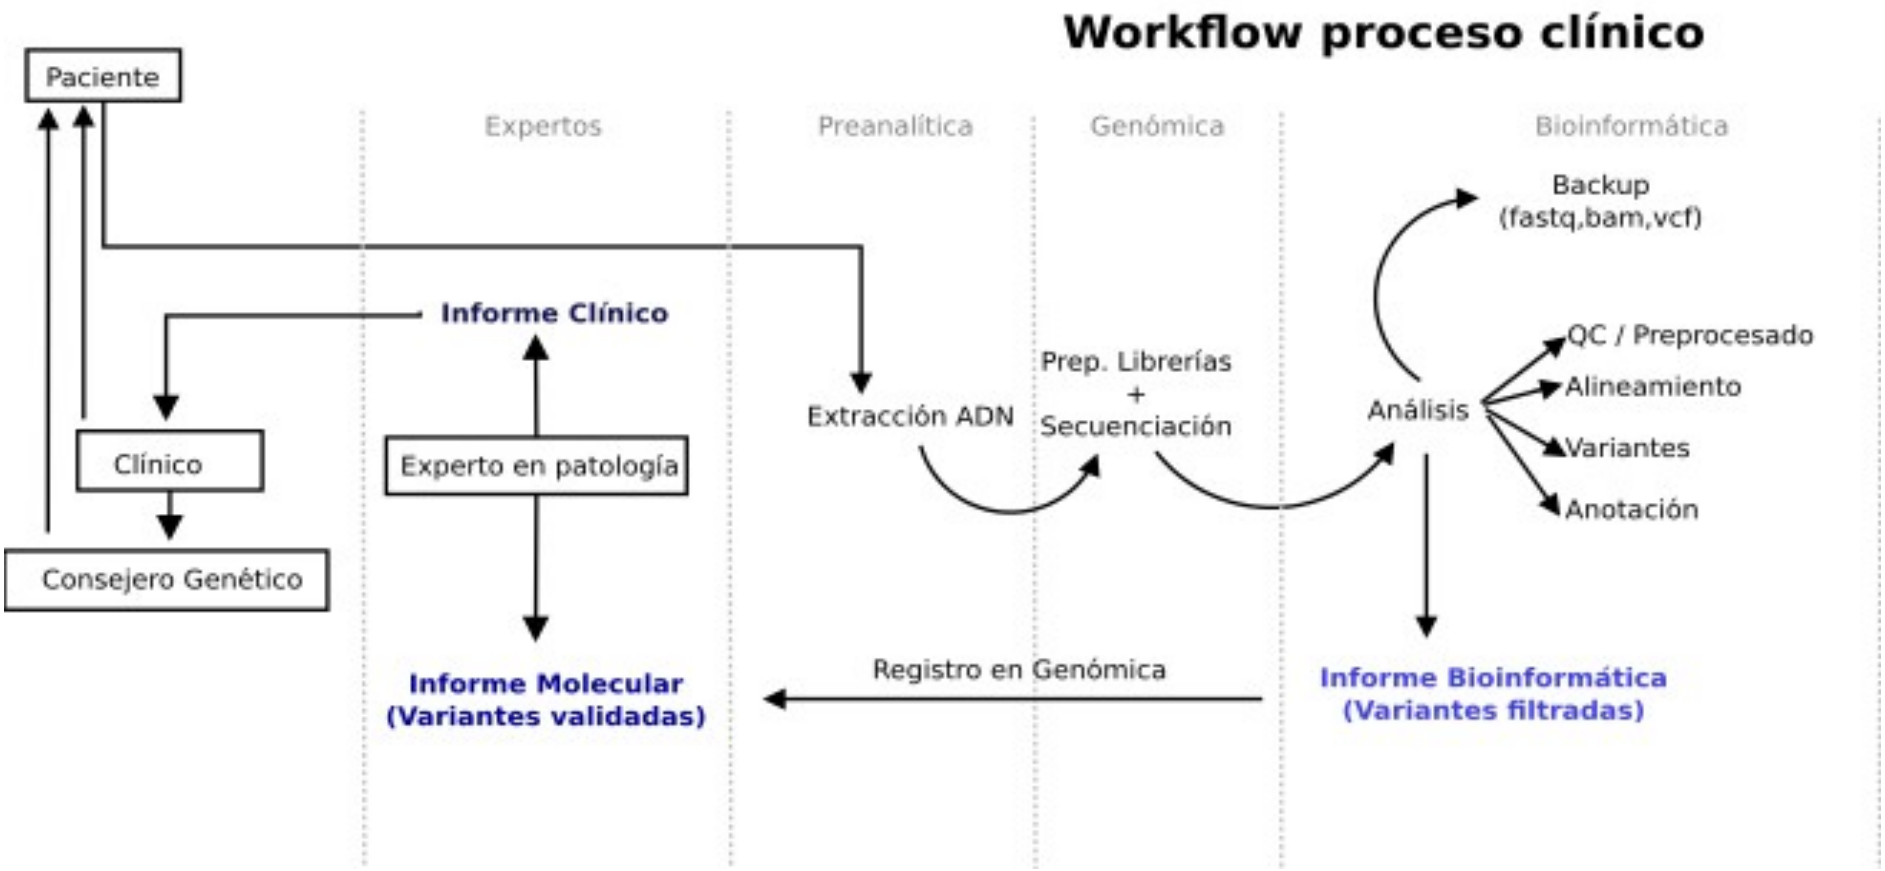

Modelo multidisciplinar

Algunos servicios de genética se han diseñado de manera que todas las fases que implican la secuenciación masiva y que todos los profesionales que participan estuviesen físicamente en un mismo espacio trabajando y colaborando dentro de un equipo multidisciplinar.

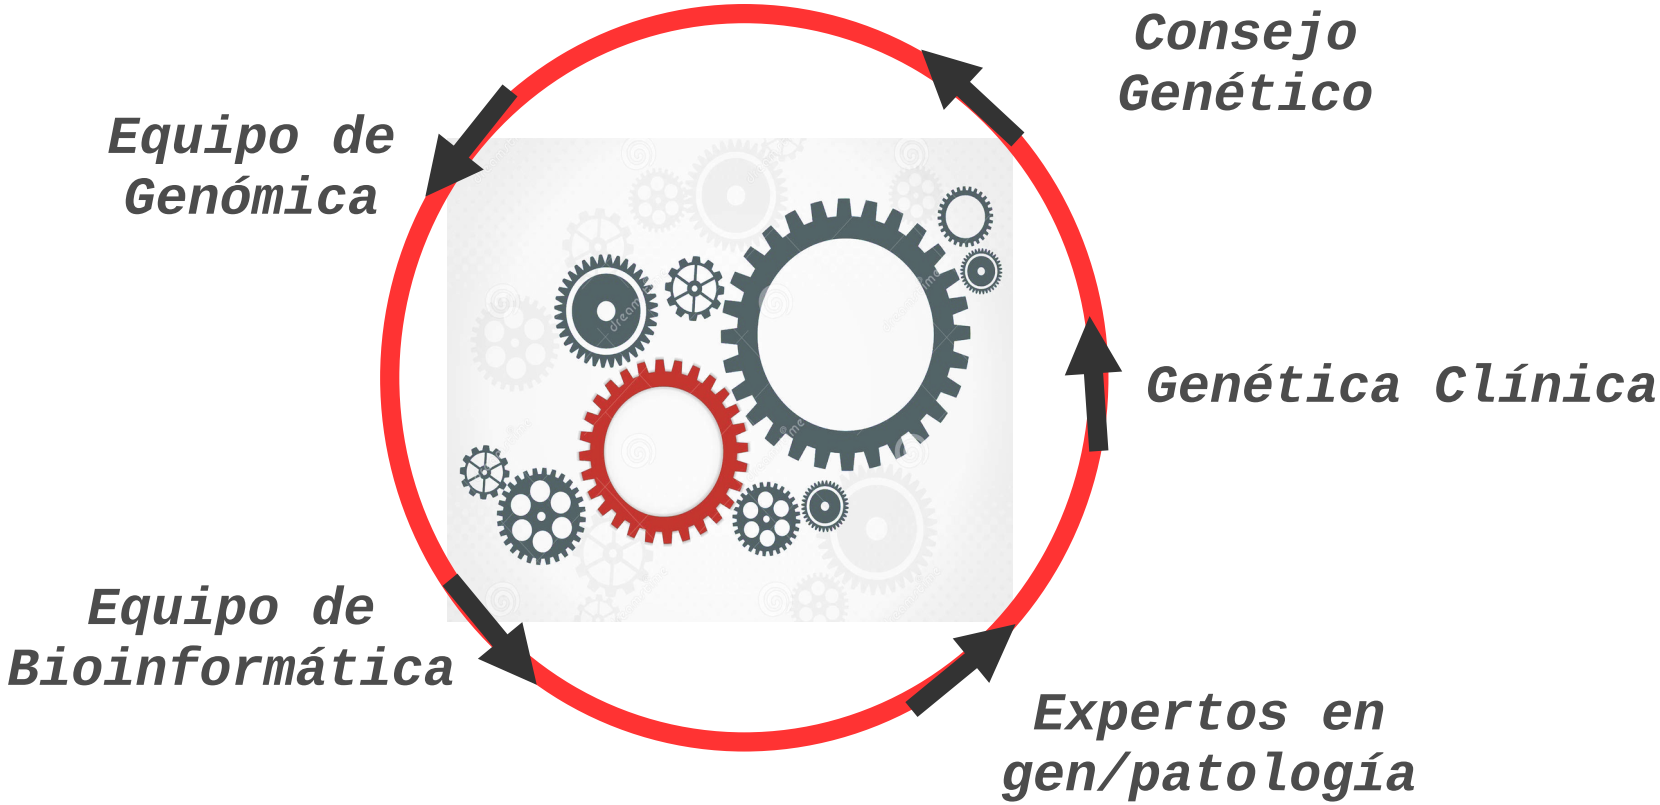

Visión de un laboratorio de Bioinformática Clínica

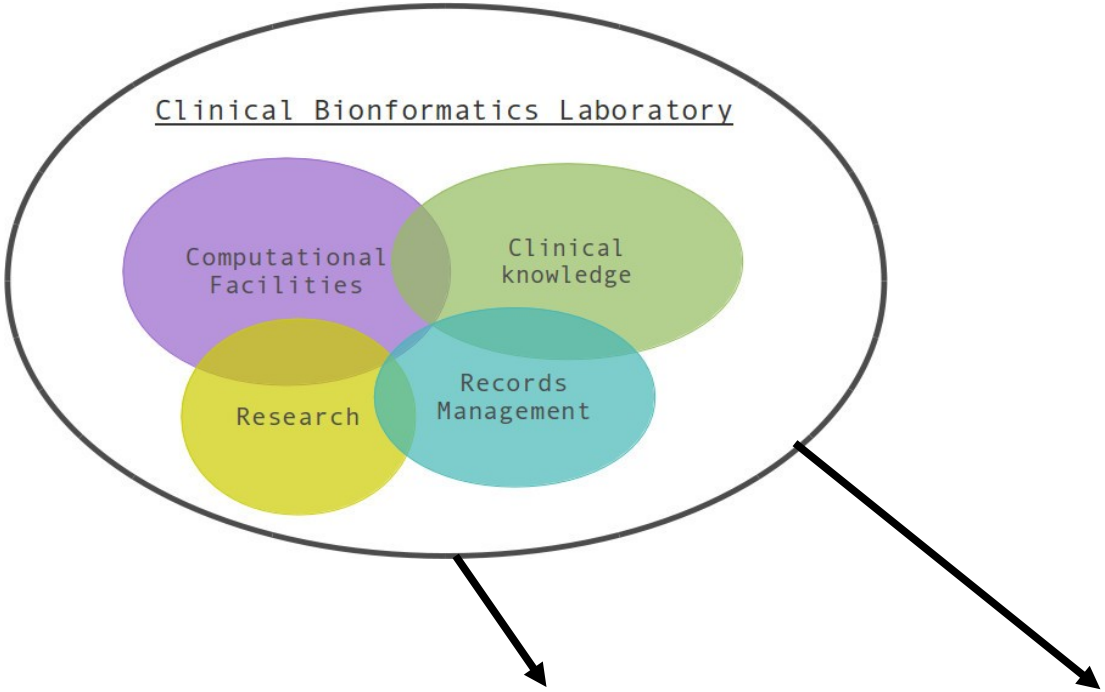

Especialización de tareas

Modelo integrado: *diagnóstico vs. investigación*

Gestión de los estudios/registros:
→ trazabilidad
→ reproducibilidad
→ custodia

Admistración de Infraestructura computacional

Laboratorios de Genética Molecular

Los bioinformáticos estamos en el entorno clínico principalmente, para asumir el análisis y la gestión de los datos obtenidos por *secuenciación masiva*

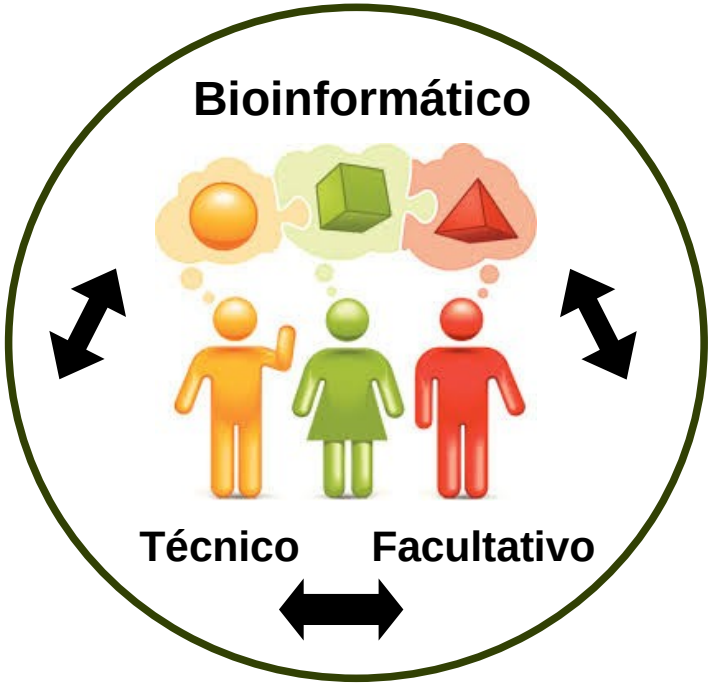

- Equipos multidisciplinares
- Áreas de conocimiento nuevas (lenguajes y conceptos nuevos)
- Una forma de diagnóstico nueva

Laboratorios de Genética Molecular

Los bioinformáticos estamos en el entorno clínico principalmente, para asumir el análisis y la gestión de los datos obtenidos por *secuenciación masiva*

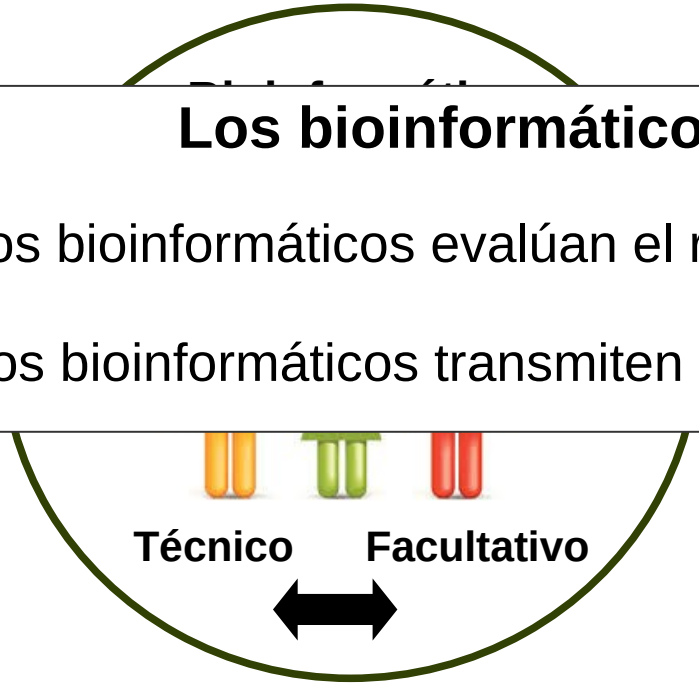

Los bioinformáticos somos una figura 'bisagra':

- Los bioinformáticos evalúan el rendimiento de la **parte experimental**
- Los bioinformáticos transmiten los datos al **experto molecular/facultativo**

- Una forma de diagnóstico nueva

Modelo *global vs.* modelo *delegado en terceros*

Multidisciplinary team that allows interaction among:

Experimental Genomics
Algorithms/Data analysis
Medical Practice

SOPHiA GENETICS®

DREAMgenics
Genomes made easy

illumina®

NIMGenetics
New Integrated Medical Genetics

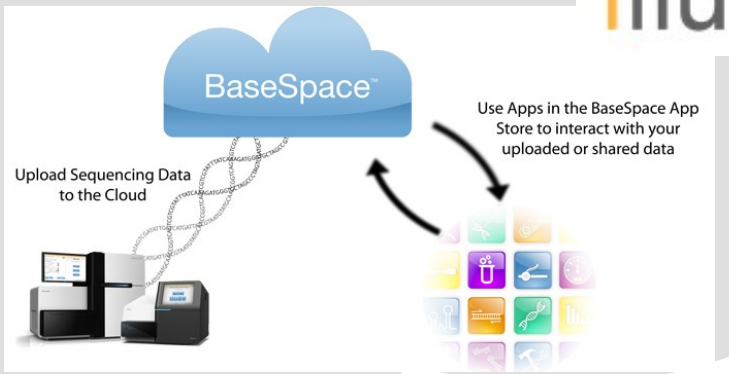

Tipos de diseños y estudios

Captura dirigida de ADN

Genes conocidos

Paneles específicos de enfermedad

Diseño 'customizado'
- Roche
- Nextera
-IDT...

Cardiopatías
Epilepsias (Dravet)
Displasia Esquelética
Hipercolesterolemia
Dermatológicas
Endocrinas

Paneles de propósito general

Diseños comerciales p.ej TruSightOne™ (TSO, Illumina)

'Exoma clínico'

Enfoque abierto

Exomas (WES)

- SureSelect (Agilent)
-TrueSeq (Illumina)
-Nextera(Illumina)
-NimbleGen SeqCap EZ (Roche)

Discapacidad intelectual sindrómica
Cuadros sindrómicos no identificados

Genomas (WGS)

No implementado

Tipos de diseños y estudios

Captura dirigida de ADN

Genes conocidos

Paneles específicos de enfermedad

Diseño 'customizado'
- Roche
- Nextera
-IDT...

Cardiopatías
Epilepsias (Dravet)
Displasia Esquelética
Hipercolesterolemia
Dermatológicas
Endocrinas

Paneles de propósito general

Diseños comerciales p.ej TruSightOne™ (TSO, Illumina)

'Exoma clínico'

Enfoque abierto

Exomas (WES)

- SureSelect (Agilent)
-TrueSeq (Illumina)
-Nextera(Illumina)
-NimbleGen SeqCap EZ (Roche)

Discapacidad intelectual sindrómica
Cuadros sindrómicos no identificados

Genomas (WGS)

No implementado

DNA-Seq: flujo de trabajo

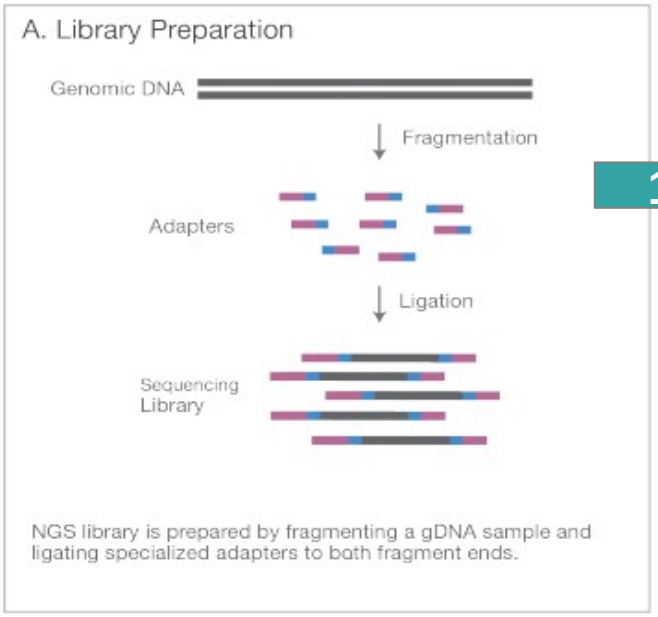

1

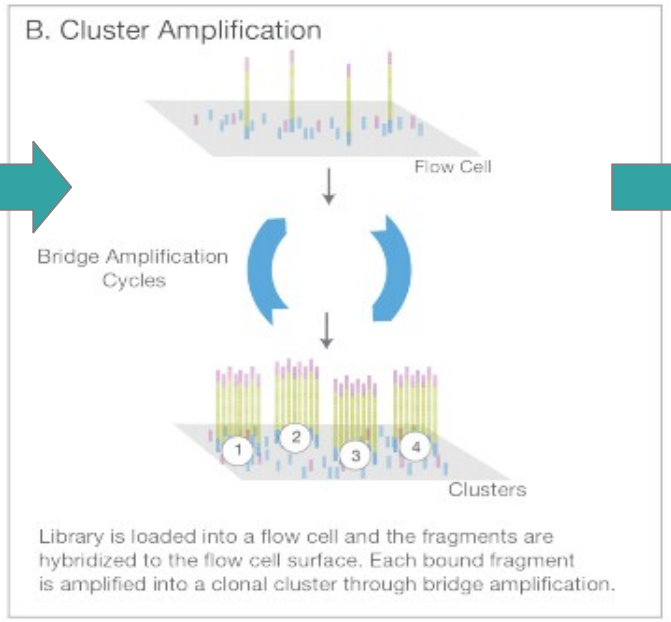

2

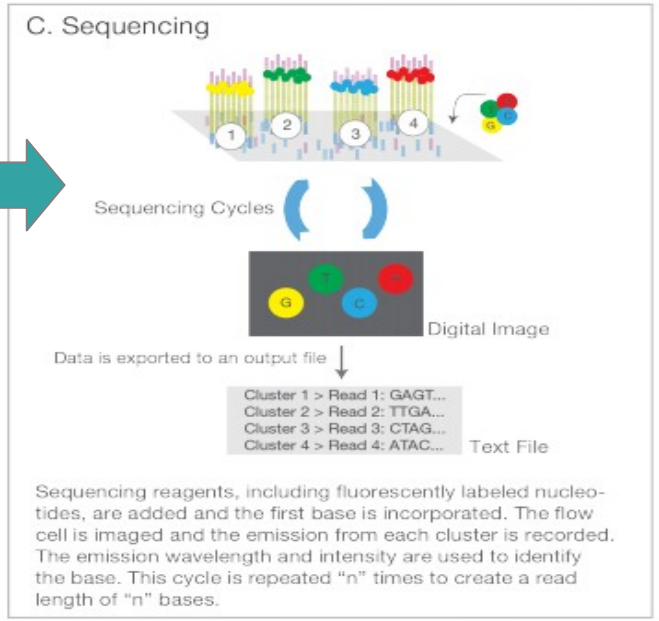

3

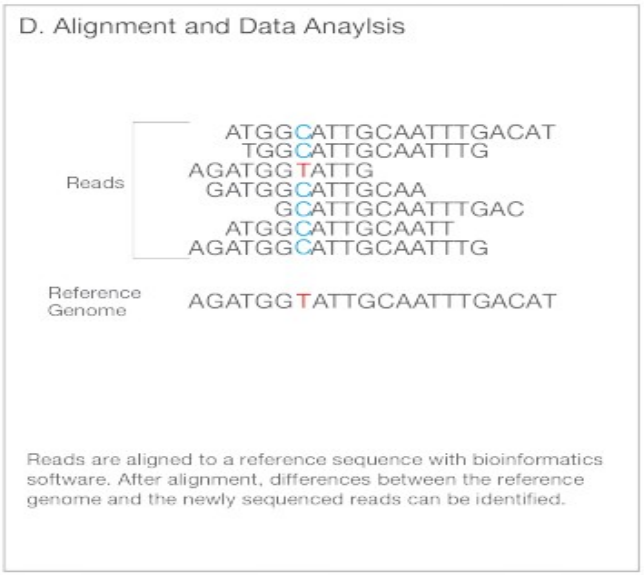

www.illumina.com/technology/next-generation-sequencing.html

illumina

Esquema de análisis (un poco más complejo)

- ✓ Preciso
- ✓ Interpretable
- ✓ Útil para el paciente

Muestra

Informe

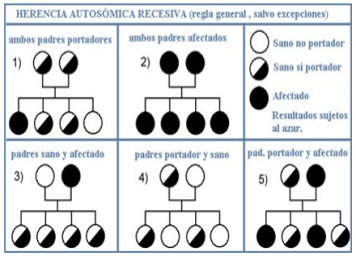

Interpretación/ Validación

Librerías ADN

Anotación Funcional

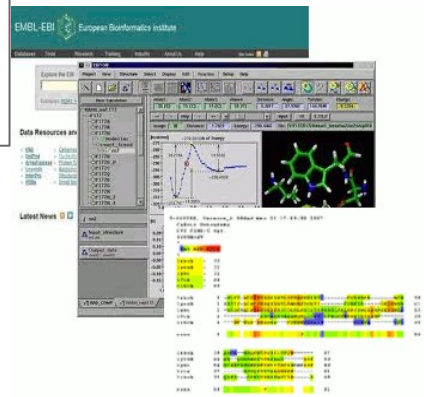

Secuenciación

Detección Variantes

Recepción (bcl/fastq)

Backup

Filtrado
(Contol Calidad)

Alineamiento

NGS vs. Sanger

FISH
~ 100,000 pb
(regiones cromosómicas)

aCGH/aSNPs
~ 25,000- 400,000 pb
(genoma completo)

Cariotipo
~ 5-10 Mpb
(cromosoma)

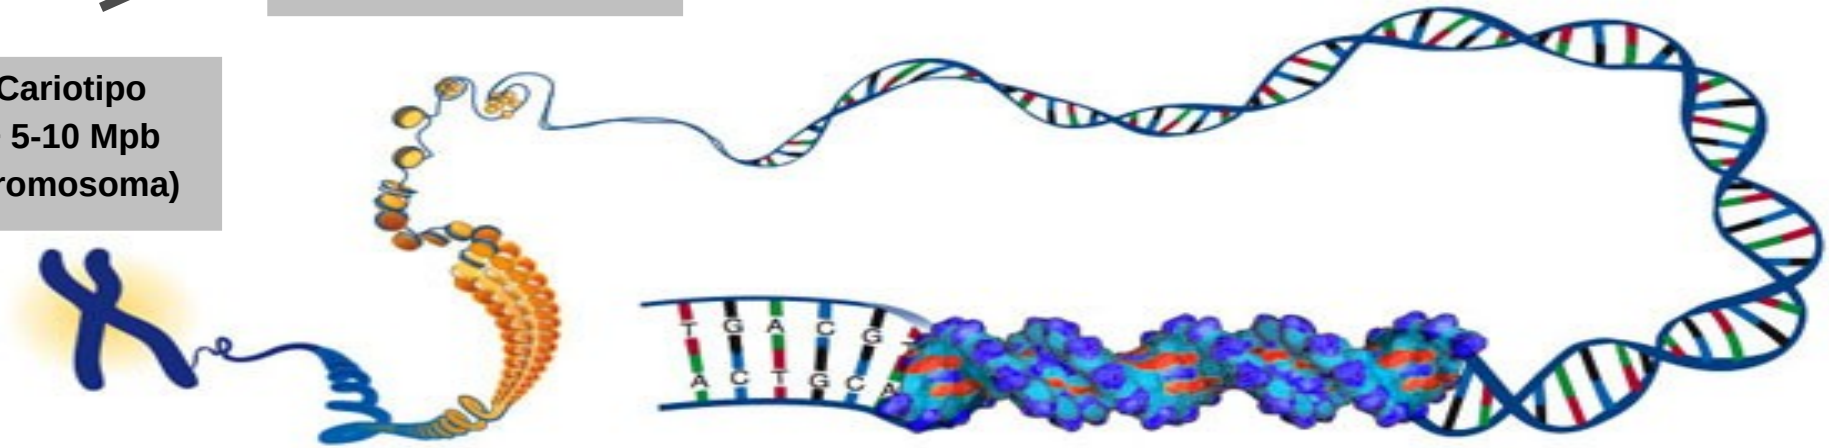

Secuenciación Masiva (NGS)
1 pb (genoma completo)

Secuenciación Sanger
1 pb
(gen a gen)

Es un conjunto de técnicas bioquímicas cuya finalidad es determinar el contenido de nucleótidos (A, C, G y T) de una muestra de ADN. Es decir, la secuenciación masiva permite conocer la secuencia de ADN de cada individuo.

Secuenciación masiva como algoritmo diagnóstico

→ La técnica permite el estudio simultáneo de muchos genes:

- ✘ Muestra conjuntos de cambios que pueden explicar mejor el fenotipo del paciente (monogénica ↔ oligogénica)

- ✘ Pero... se generan tablas con muchas variantes que son difíciles de interpretar. Se necesita:
  - una buena descripción fenotípica
  - presencia de **personal facultativo y especialista**
  - presencia de personal con perfil **bioinformático**
  - política de manejo de ficheros

→ El rendimiento diagnóstico, depende de muchos factores. No existe una solución cerrada y se realiza el diagnóstico sin una armonización de criterios ni calidad

- ✘ Falta de consistencia y reproducibilidad

Plataformas de secuenciación en el INGEMM

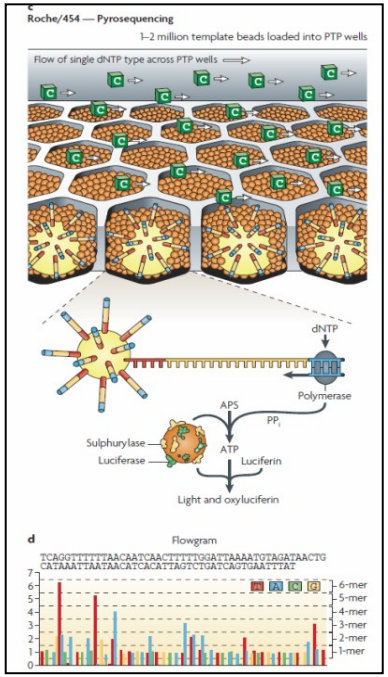

Pyrosequencing

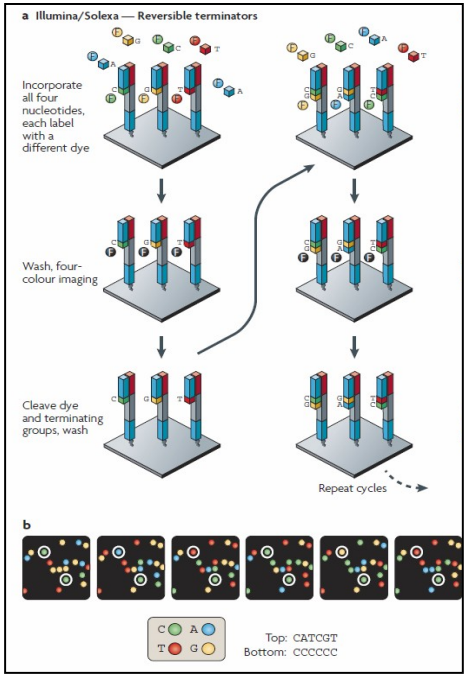

Four-colour cyclic reversible

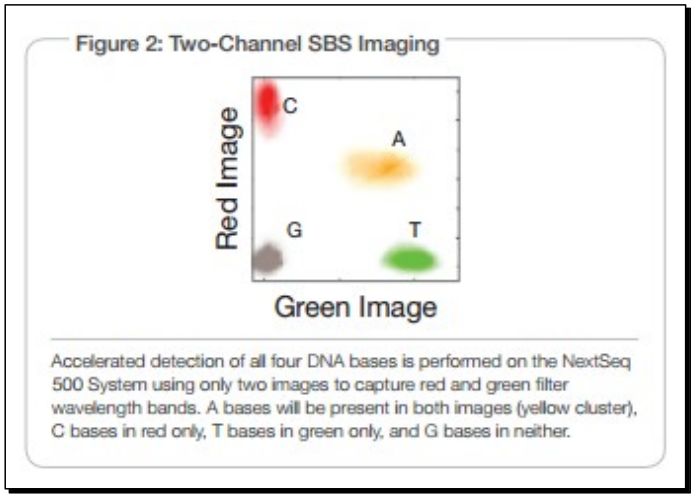

Two-channel SBS

* cortesía Elena Vallespín

Determinación del nucleótido: *"nucleotide calling"*

Aquí es donde se determina el modelo para asignar en cada posición de cada lectura, qué nucleótido se ha leído y con qué calidad

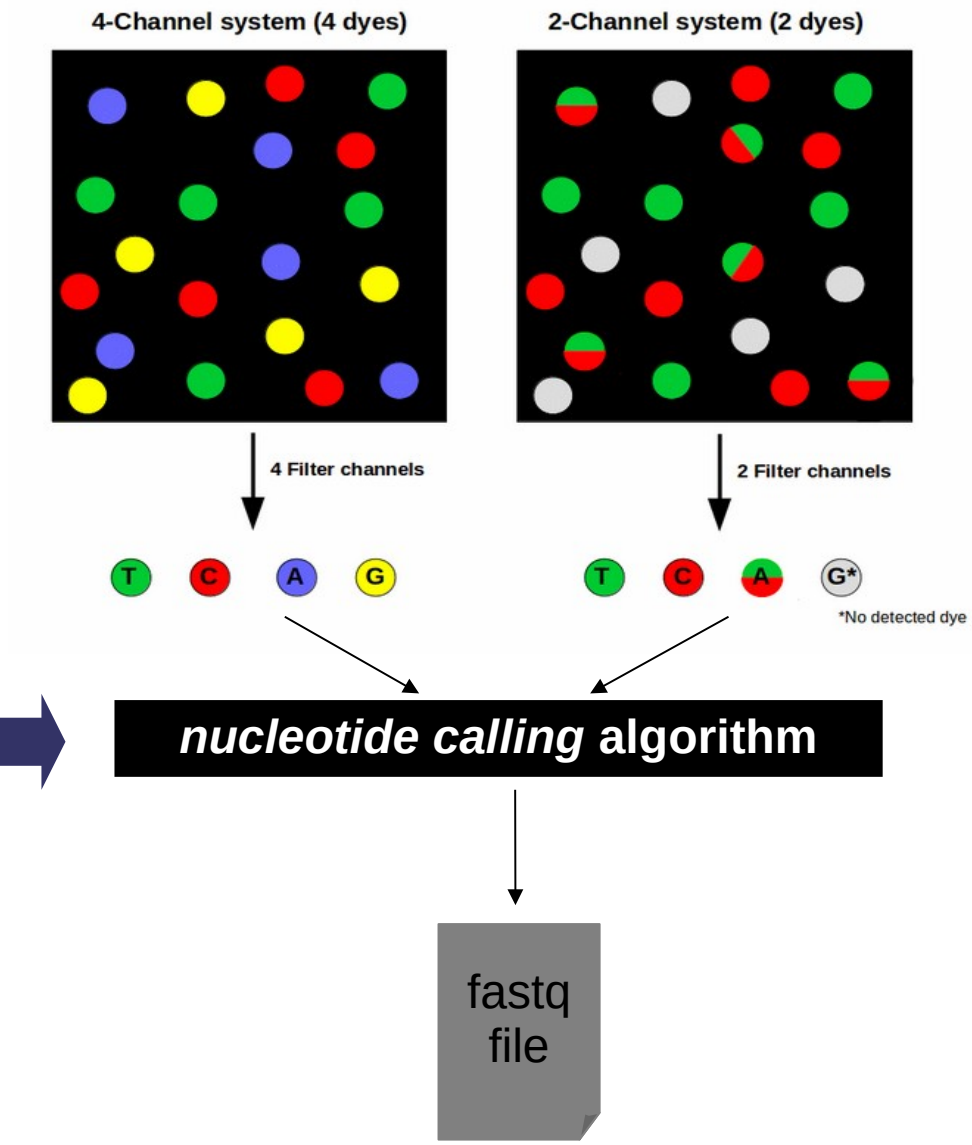

*https://www.ecseq.com/support/ngs/do_you_have_two_colors_or_four_colors_in_Illumina

Paired-end vs. Single-end

Formas de secuenciar un fragmento de ADN:

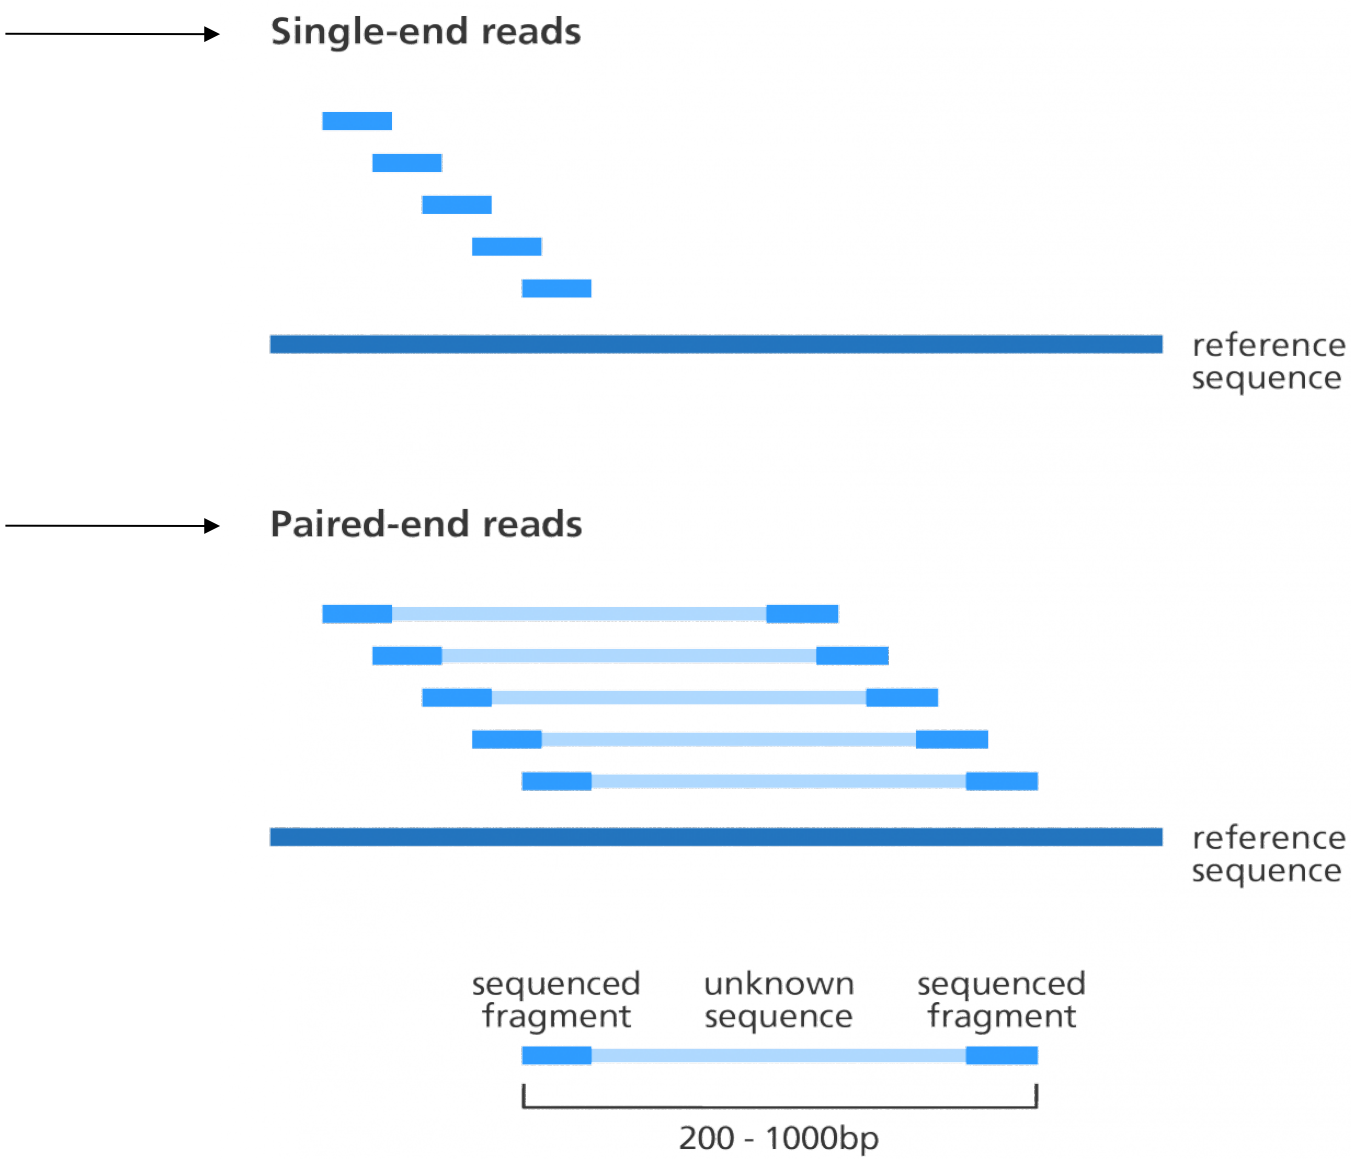

*https://www.illumina.com/science/technology/next-generation-sequencing/paired-end-vs-single-read-sequencing.html

Fichero fastq

Se considera que es el dato 'crudo' que sale del secuenciador, pero en realidad son los ficheros de imágenes *bcl, la salida cruda de la secuenciación

En una secuenciación *paired-end* se obtienen dos ficheros por cada muestra: R1 y R2. Cada lectura que pertenece al mismo fragmento, comparte identificador en los ficheros R1 y R2

First sequence in "left" file

```
@HWI-ST896:156:D0JFYACXX:5:1101:1652:2132 1:N:0:GATCAG
ACTGCATCCTGGAAAGAATCAATGGTGGCCGGAAAGTGTTTTTCAAATACAAGAGTGACAATGTGCCCTGTTGTTT
+
ACCCCCCCCCCCCCCCCCCCCCCCCCCCCCCBC?CCCCCCCCC@@CACCCCCACCCCCCCCCCCCCCCCCCCCCCC
```

First sequence in "right" file

```
@HWI-ST896:156:D0JFYACXX:5:1101:1652:2132 2:N:0:GATCAG
CTCAAATGGTTAATTCTCAGGCTGCAAATATTCGTTCAGGATGGAAGAACATTTTCTCAGTATTCCATCTAGCTGC
+
C<CCCCCCCACCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCCBCCCCCCCCCCCCCCCCCACCCCCACCC=
```

Esta cadena de caracteres representa la calidad de los nucleótidos

Calidad en el fichero fastq

- La calidad con la que se determina cada nucleótido, se expresa con un número que se denomina *'Phred score'*

- El score Phred es $-10\log_{10}P$, donde P es la probabilidad de que el nucleótido *'i'* que se emite, es n_i

- En el fichero se codifica el score Phred con una letra. La tabla de correspondencia es la tabla asciii

Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%

Correspondencia entre probabilidad P y phred s.

ASCII_BASE=33 Illumina, Ion Torrent, PacBio and Sanger

Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII
0	1.00000	33 !	11	0.07943	44 ,	22	0.00631	55 7	33	0.00050	66 B
1	0.79433	34 "	12	0.06310	45 -	23	0.00501	56 8	34	0.00040	67 C
2	0.63096	35 #	13	0.05012	46 .	24	0.00398	57 9	35	0.00032	68 D
3	0.50119	36 $	14	0.03981	47 /	25	0.00316	58 :	36	0.00025	69 E
4	0.39811	37 %	15	0.03162	48 0	26	0.00251	59 ;	37	0.00020	70 F
5	0.31623	38 &	16	0.02512	49 1	27	0.00200	60 <	38	0.00016	71 G
6	0.25119	39 '	17	0.01995	50 2	28	0.00158	61 =	39	0.00013	72 H
7	0.19953	40 (	18	0.01585	51 3	29	0.00126	62 >	40	0.00010	73 I
8	0.15849	41)	19	0.01259	52 4	30	0.00100	63 ?	41	0.00008	74 J
9	0.12589	42 *	20	0.01000	53 5	31	0.00079	64 @	42	0.00006	75 K
10	0.10000	43 +	21	0.00794	54 6	32	0.00063	65 A			

ASCII_BASE=64 Old Illumina

Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII
0	1.00000	64 @	11	0.07943	75 K	22	0.00631	86 V	33	0.00050	97 a
1	0.79433	65 A	12	0.06310	76 L	23	0.00501	87 W	34	0.00040	98 b
2	0.63096	66 B	13	0.05012	77 M	24	0.00398	88 X	35	0.00032	99 c
3	0.50119	67 C	14	0.03981	78 N	25	0.00316	89 Y	36	0.00025	100 d
4	0.39811	68 D	15	0.03162	79 O	26	0.00251	90 Z	37	0.00020	101 e
5	0.31623	69 E	16	0.02512	80 P	27	0.00200	91 [	38	0.00016	102 f
6	0.25119	70 F	17	0.01995	81 Q	28	0.00158	92 \	39	0.00013	103 g
7	0.19953	71 G	18	0.01585	82 R	29	0.00126	93]	40	0.00010	104 h
8	0.15849	72 H	19	0.01259	83 S	30	0.00100	94 ^	41	0.00008	105 i
9	0.12589	73 I	20	0.01000	84 T	31	0.00079	95 _	42	0.00006	106 j
10	0.10000	74 J	21	0.00794	85 U	32	0.00063	96 `			

Tabla de codificación del score phred en el fichero fastq

Visualización fichero fastq

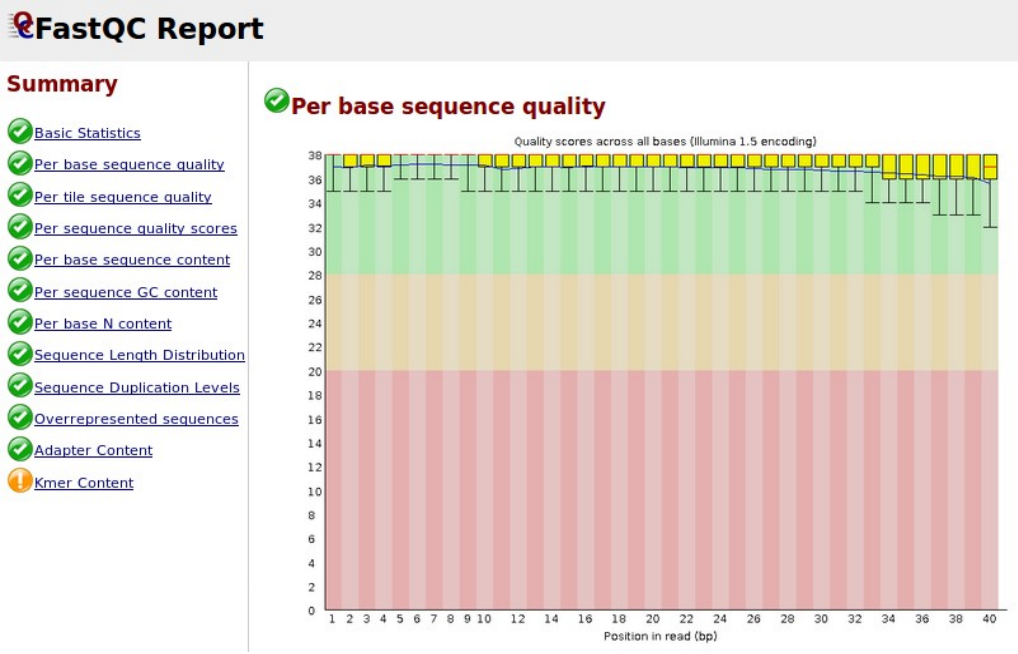

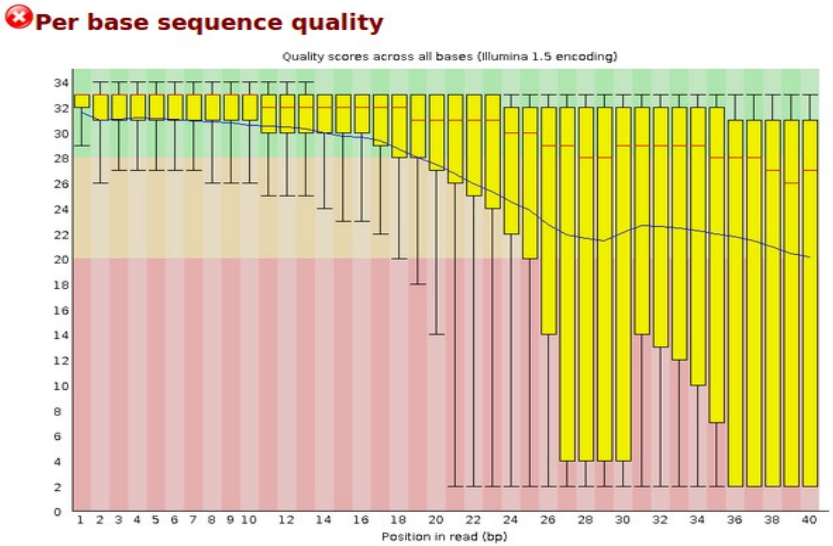

Fastc: https://www.bioinformatics.babraham.ac.uk/projects/fastqc/

Permite visualizar ficheros fastq y bam

Facilita ver la calidad en varias perspectivas:

- Calidad por nucleótido o ciclo
- Calidad por secuencia
- Distribución del contenido nucleotídico en cada ciclo
- Secuencias repetidas

Resumen NGS (hasta alineamiento)

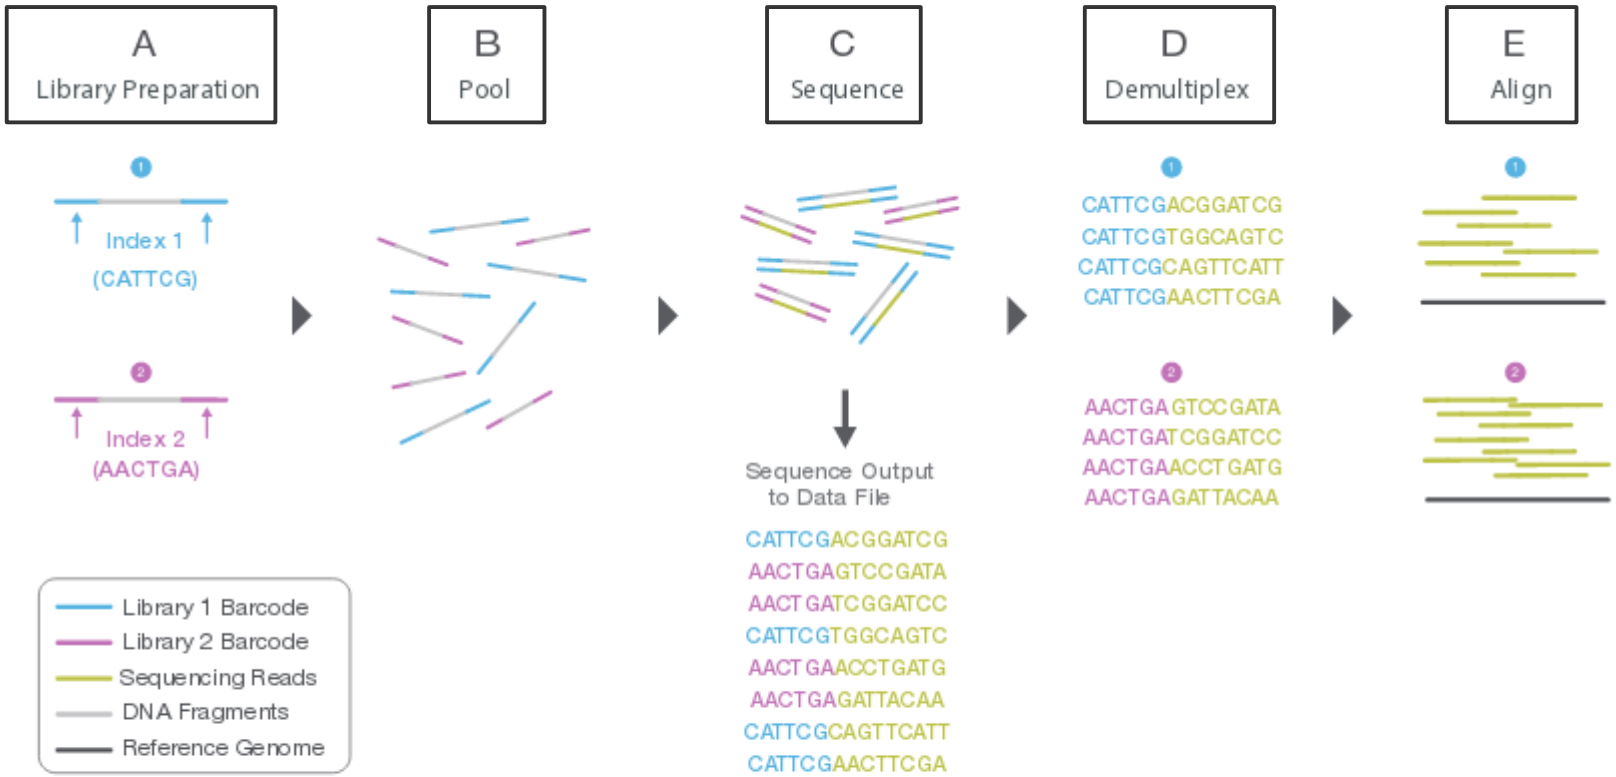

Figure 5: Library Multiplexing Overview.

a. Two distinct libraries are attached to unique index sequences. Index sequences are attached during library preparation.

b. Libraries are pooled together and loaded into the same flow cell lane.

c. Libraries are sequenced together during a single instrument run. All sequences are exported to a single output file.

d. A demultiplexing algorithm sorts the reads into different files according to their indexes.

e. Each set of reads is aligned to the appropriate reference sequence.

www.illumina.com/technology/next-generation-sequencing.html

illumina®

Resumen NGS

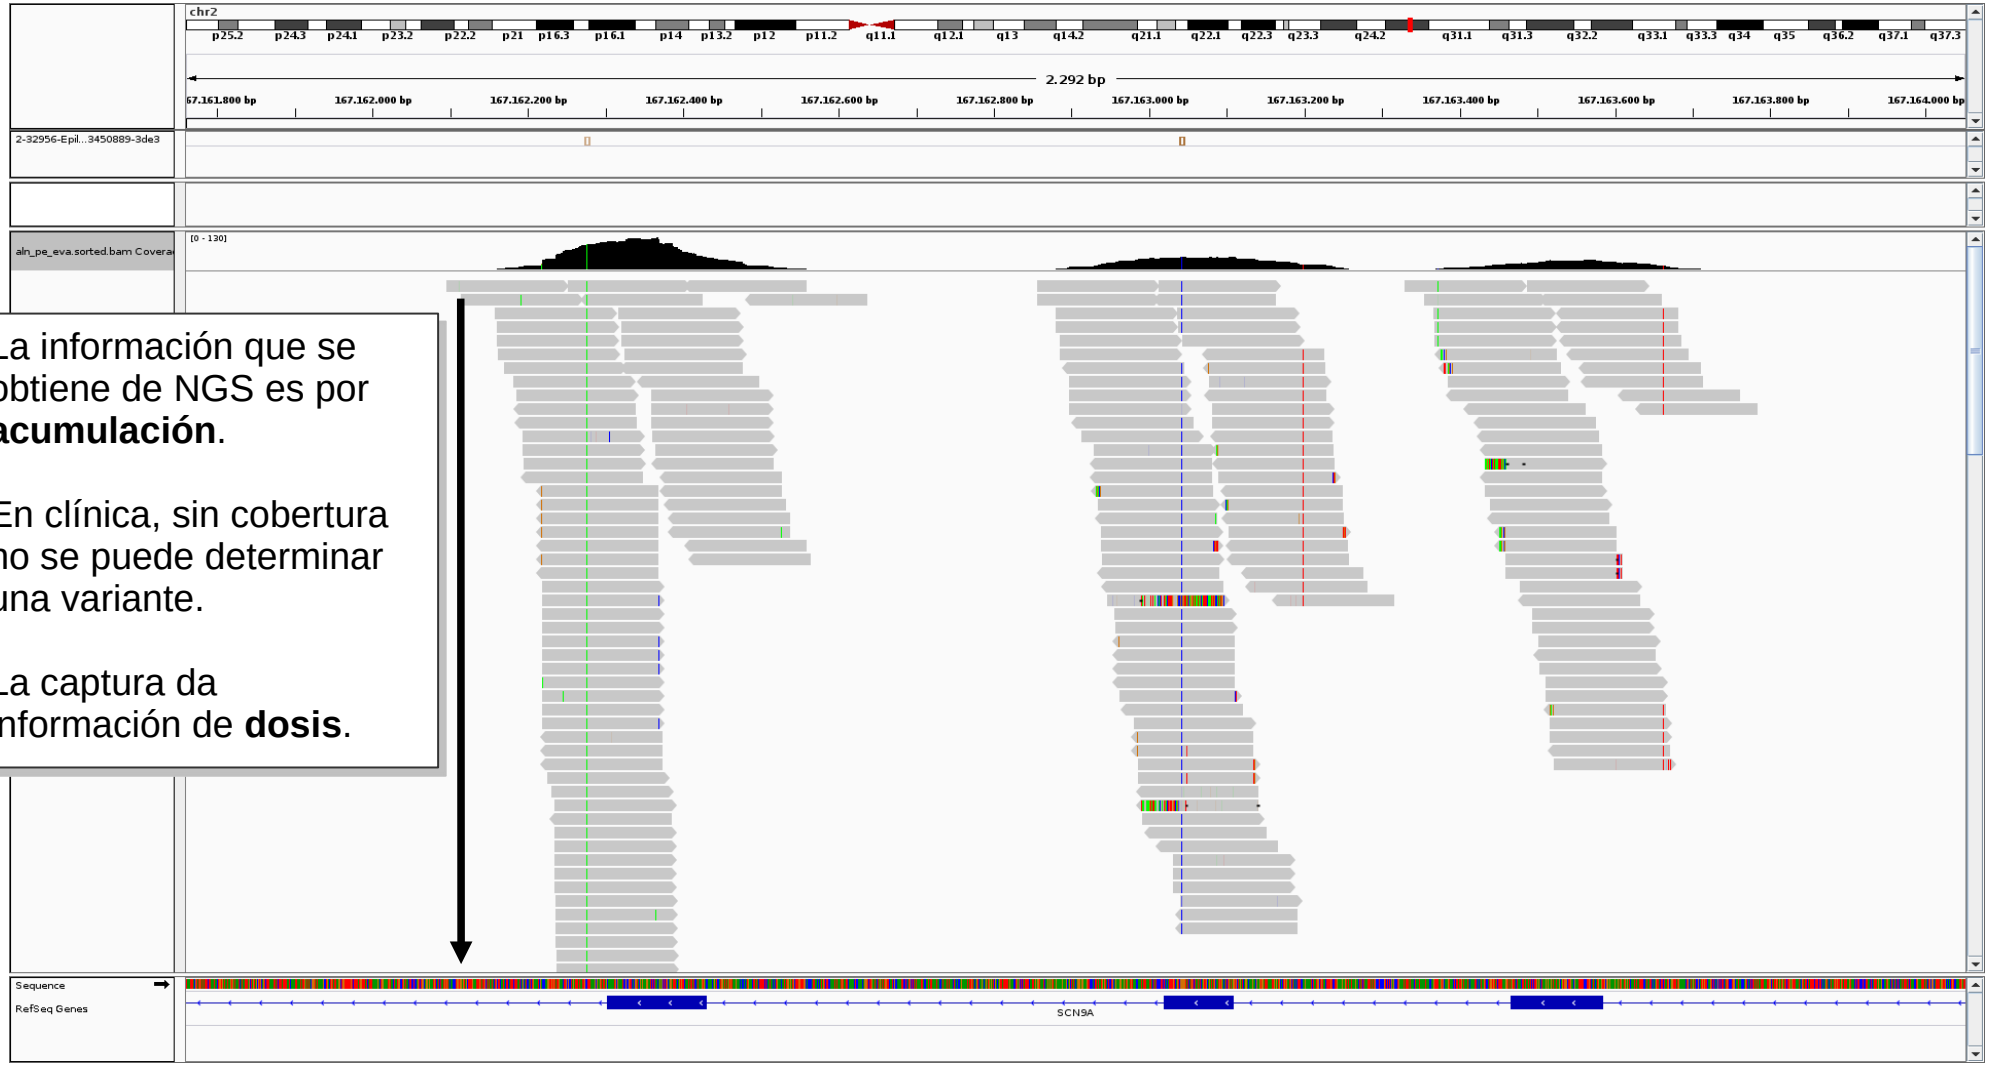

La información que se obtiene de NGS es por **acumulación**.

En clínica, sin cobertura no se puede determinar una variante.

La captura da información de **dosis**.

Limitaciones NGS

El análisis depende de muchos factores, lo que genera una cierta variabilidad en los datos finales:

→ Factores relacionados con la técnica experimental:

- Química de captura de ADN
- Plataforma de secuenciación
- Origen y tratamiento de la muestra
- Tamaño de la región diana (...)

→ Factores relacionados con el software y la metodología:

1) Existen multitud de herramientas, cada una con un sesgo.

2) Metodológicamente, existen 'guías de buenas prácticas' pero no una forma única de abordar el análisis.

3) No especialización de los análisis en función de la patología

No es posible leer con fiabilidad todas las regiones de interés.

Existe un 'tope' → 98 – 99%

Supp. Table S2. Overview of base-pair coverage for different platforms and coverage thresholds

Reference		Percentage RefSeq regions covered at						Percentage Ensembl regions covered					
		≥10x		≥15x		≥20x		≥10x		≥15x		≥20x	
Library	Cvg.	Mean	Range	Mean	Range	Mean	Range	Mean	Range	Mean	Range	Mean	Range
Agilent V4	77.92	93.87	92.44-94.76	91.50	88.87-93.12	88.75	84.88-91.21	92.62	91.17-93.55	90.19	87.55-91.83	87.41	83.56-89.89
Agilent V4	159.92	95.81	95.23-96.23	94.97	94.26-95.53	94.10	93.21-94.79	94.63	94.06-95.06	93.73	93.02-94.29	92.79	91.91-93.49
Agilent V5	100.17	97.26	96.57-97.81	96.06	94.97-96.99	94.57	93.05-95.96	96.40	95.68-97.00	95.13	94.02-96.09	93.58	92.05-94.98
NimbleGen V3	94.50	97.89	96.80-98.35	96.91	95.82-97.46	95.83	94.82-96.53	96.64	95.56-97.10	95.61	94.53-96.16	94.49	93.48-95.19
Complete Genomics	44.17	98.44	97.93-98.90	96.52	95.41-97.62	93.21	91.28-95.32	98.40	97.91-98.86	96.48	95.39-97.58	93.17	91.28-95.28
Complete Genomics	87.42	99.45	99.33-99.56	99.06	98.79-99.30	98.40	97.88-98.83	99.42	99.30-99.53	99.03	98.76-99.26	98.58	98.12-98.98
Illumina HiSeq	28.09	93.89	89.30-96.47	86.26	76.97-91.15	74.10	63.69-80.70	93.90	89.32-96.46	86.23	76.95-91.12	74.00	63.57-80.60
Illumina HiSeq	56.20	97.77	97.11-98.21	96.53	95.90-97.14	94.77	94.30-95.52	97.79	97.13-98.23	96.55	95.91-97.15	94.77	94.31-95.53
Illumina XTen	39.58	98.68	97.29-99.09	96.96	91.25-98.78	93.56	81.86-98.06	98.59	97.25-99.00	96.87	91.29-98.68	93.49	82.02-80.60

Hum Mutat. 2015 Aug;36(8):815-22. doi: 10.1002/humu.22813. Epub 2015 Jun 11.

Comparison of Exome and Genome Sequencing Technologies for the Complete Capture of Protein-Coding Regions.

Lelieveld SH[1], Spielmann M[2,3], Mundlos S[2,3], Veltman JA[1,4], Gilissen C[1].

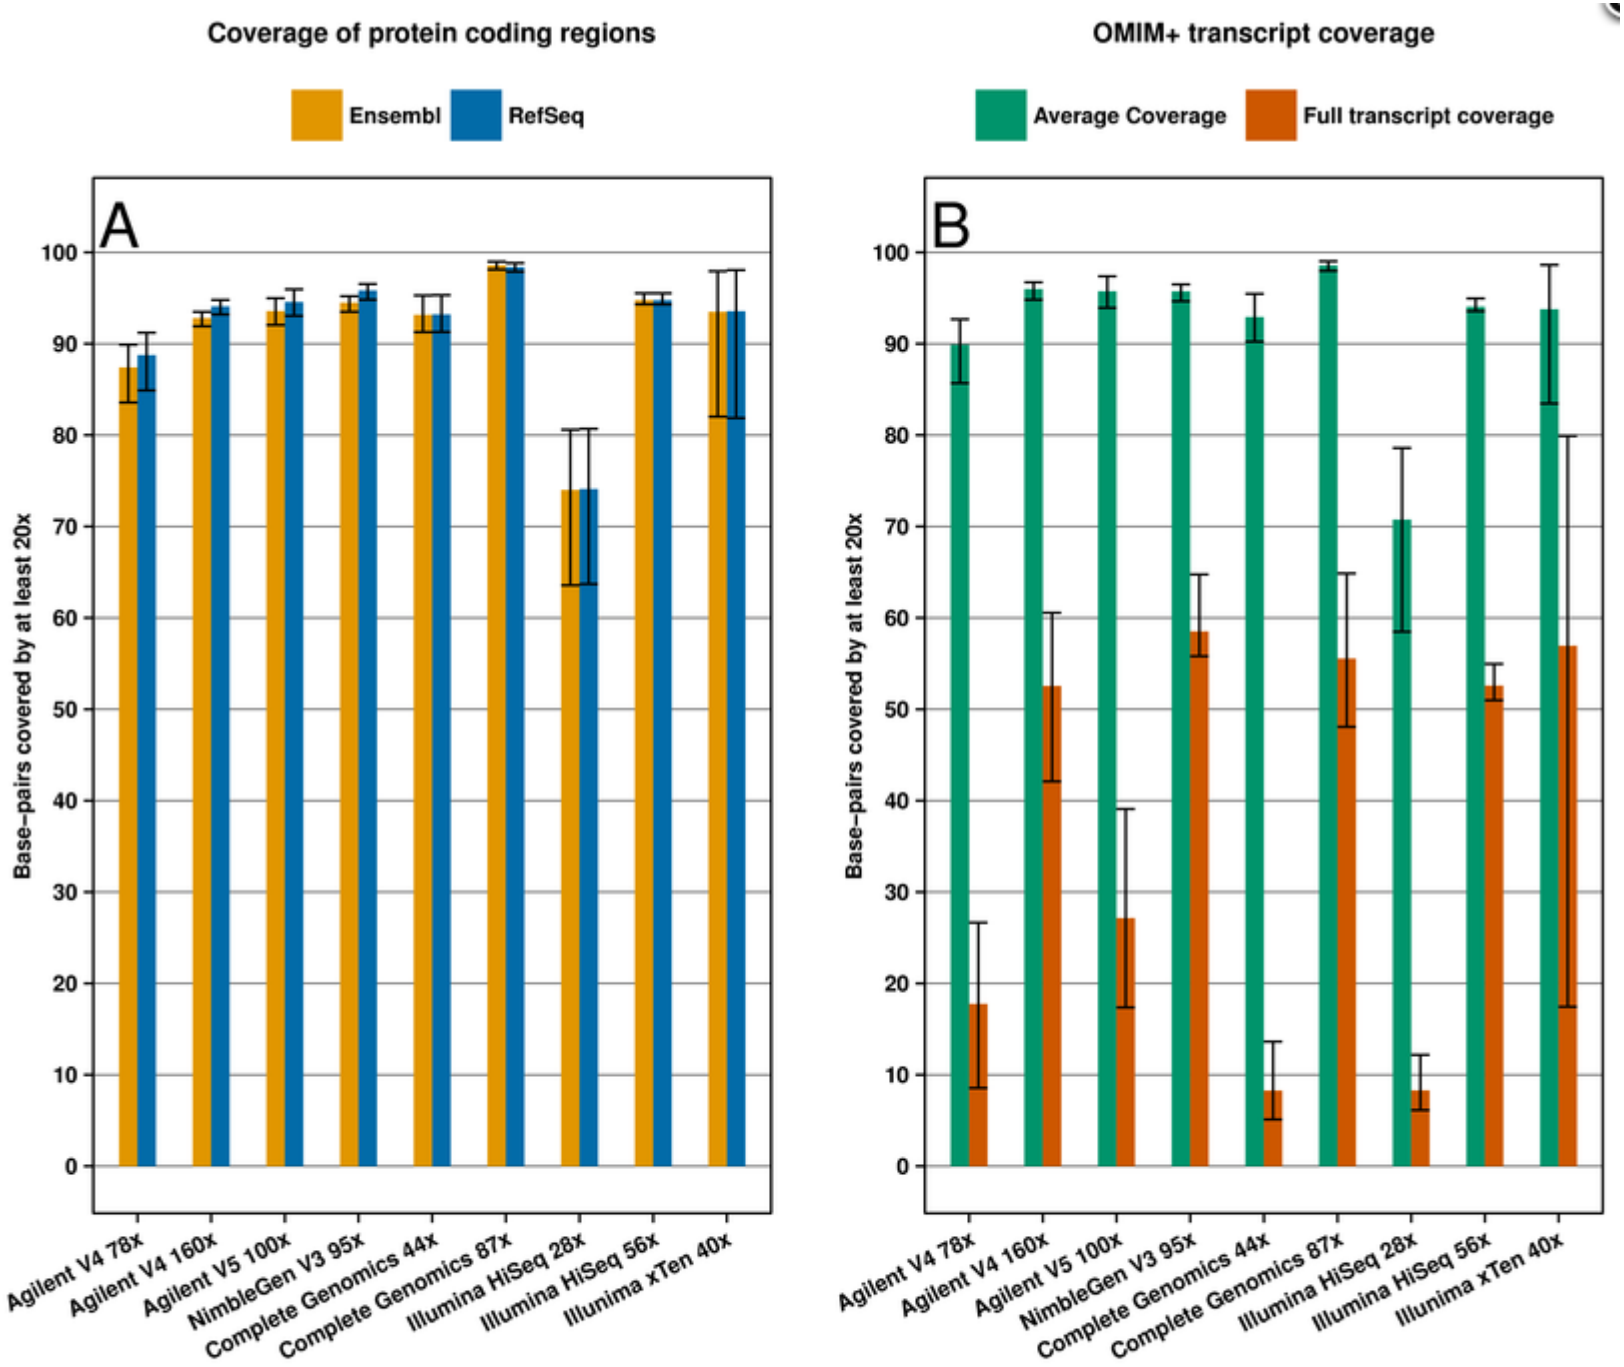

Figure 1. Coverage of the Ensembl and RefSeq annotated protein-coding regions and (full) coverage of 2,759 clinically relevant OMIM+ genes. **A**: The percentage of base pairs of Ensembl (in yellow) and RefSeq (in blue) annotated protein-coding regions covered by at least 20 reads for the tested platforms. **B**: Percentage of base pairs covered by at least 20 reads for the longest OMIM+ transcripts (in green). The red bars depict the percentage of the (longest) OMIM+ transcript base pairs that are fully covered by at least 20 reads.

Problemática de las lecturas cortas

1) Paired-end (PE) vs. Single-end (SE)

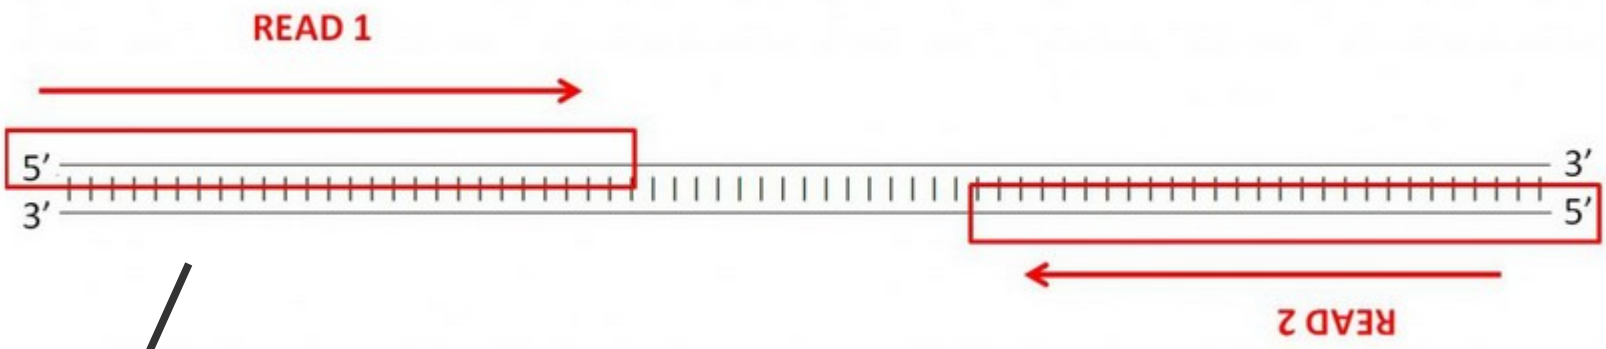

2) Alineamiento de PE contra un genoma de referencia

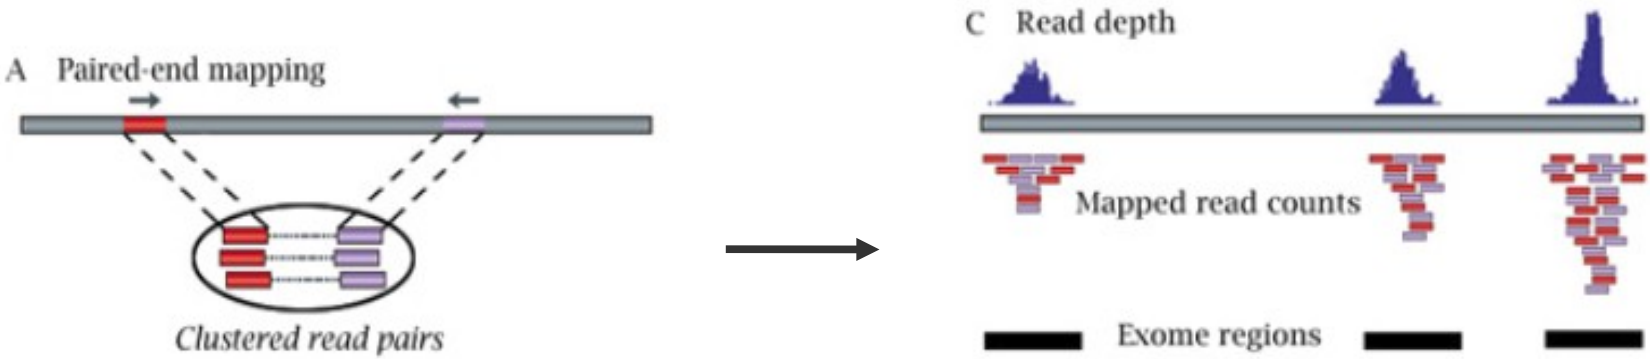

BMC Bioinformatics201314(Suppl 11):S1
https://doi.org/10.1186/1471-2105-14-S11-S1

La secuenciación masiva es una herramienta de cribado

La sensibilidad no es completa debido a que no se resuelven los genes en su totalidad

Hay que saber de antemano que no se pueden analizar el 100% de los exones de los genes

Causas de la 'falta de efectividad'

Composición genómica de la región diana

- Alto contenido en GC
- Baja complejidad: LCRs, homopolímeros, STR etc..
- Regiones con gran homología: pseudogenes, duplicaciones segmentales

Falta de efectividad en la captura dirigida

- Tipo de fragmentación: mejor cuanto más aleatoria
- Diseño de las sondas: Kit comercial vs. Diseños custom

Genoma de referencia

- Haplotipos alternativos, regiones de difícil acceso

Parametrización insuficiente en las herramientas bioinformáticas

Evaluación insuficiente de las pipelines de análisis

- Presencia de FP y FN: conocer el límite en rendimiento de la pipeline
- Compromiso entre sensibilidad y especificidad
  - → Materiales de referencia

Límites del conocimiento actual para la interpretación de variantes

Comunidad de usuarios poco formada

- Mala interpretación de los datos
- Falta de criterio para saber si una muestra es apta o no.

Detección de variantes

Cambios puntuales (SNVs)

Chr7(BRAF):g.14501302C > T

Deleciones pequeñas (INDELs)

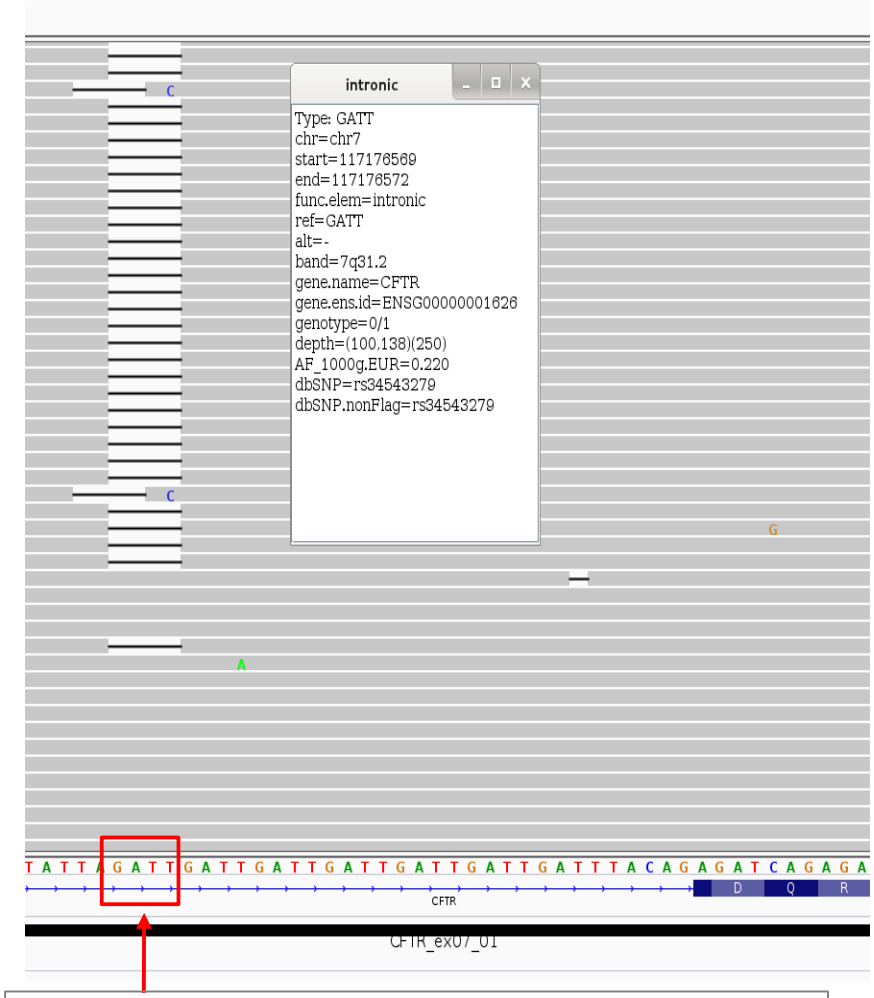

Chr7(CFTR):g.117176569 del GATT

Variant calling vs. Genotype calling

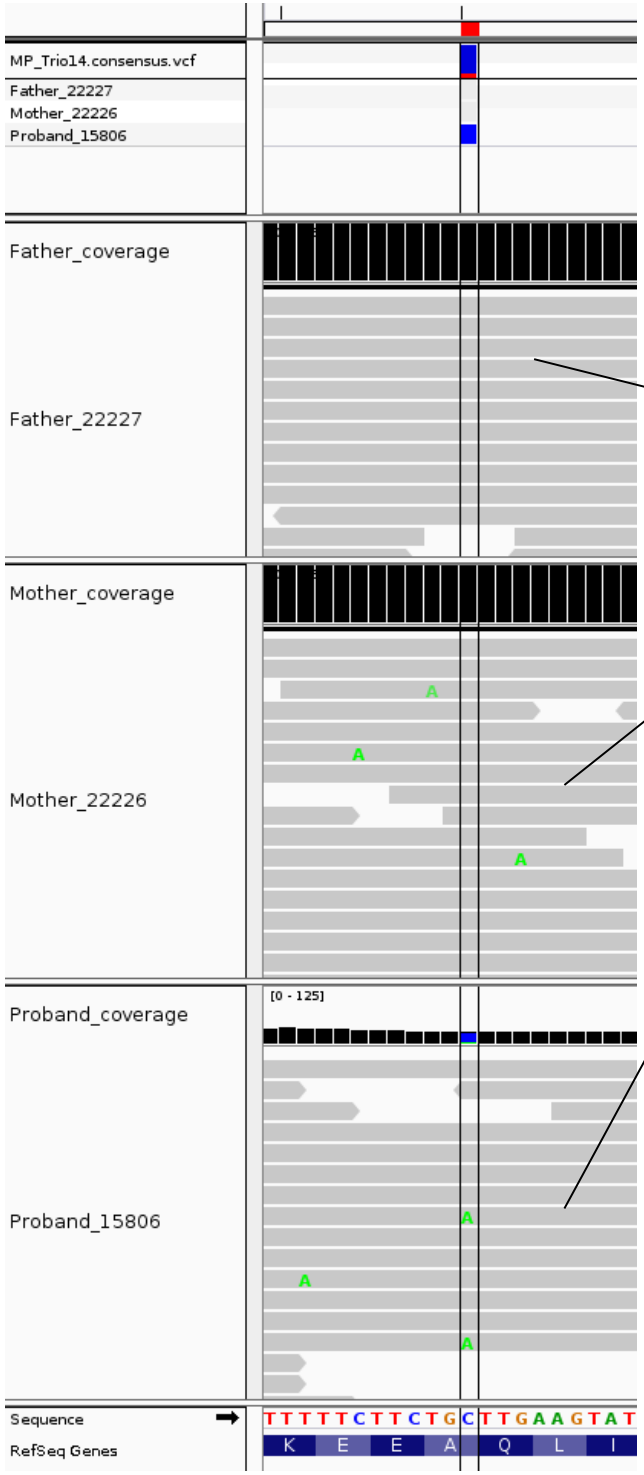

Genotype Calling

ID	GT	AD
Father	0/0	[293,0]
Mother	0/0	[264,0]
Proband	0/1	[20,5]

Número de 'callings' = 3
Número de variantes = 1

Variant Calling

ID	GT	AD
Father	./.	[0,0]
Mother	./.	[0,0]
Proband	0/1	[20,5]

Número de 'callings' = 1
Número de variantes = 1

[HOM_REF, HET, HOM_VAR]

[0/0, 0/1, 1/1]

La detección de variantes está determinada por el problema de estudio

El genotipo de un nucleótido se determina de forma indirecta a través del contaje de lecturas del alelo de referencia y/o mutado. Por tanto, ***el genotipo se determina con un grado de incertidumbre***.

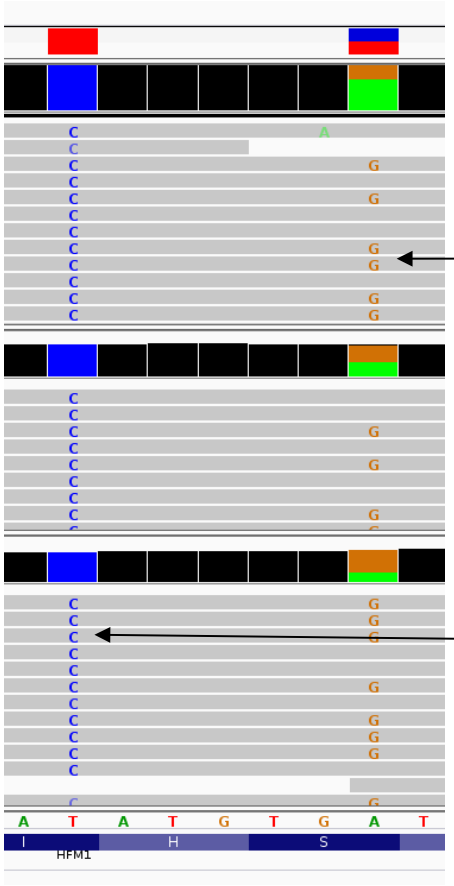

P(genotipo/observación)

0/1

1/1

La detección de variantes está determinada por el problema de estudio

"joint calling"

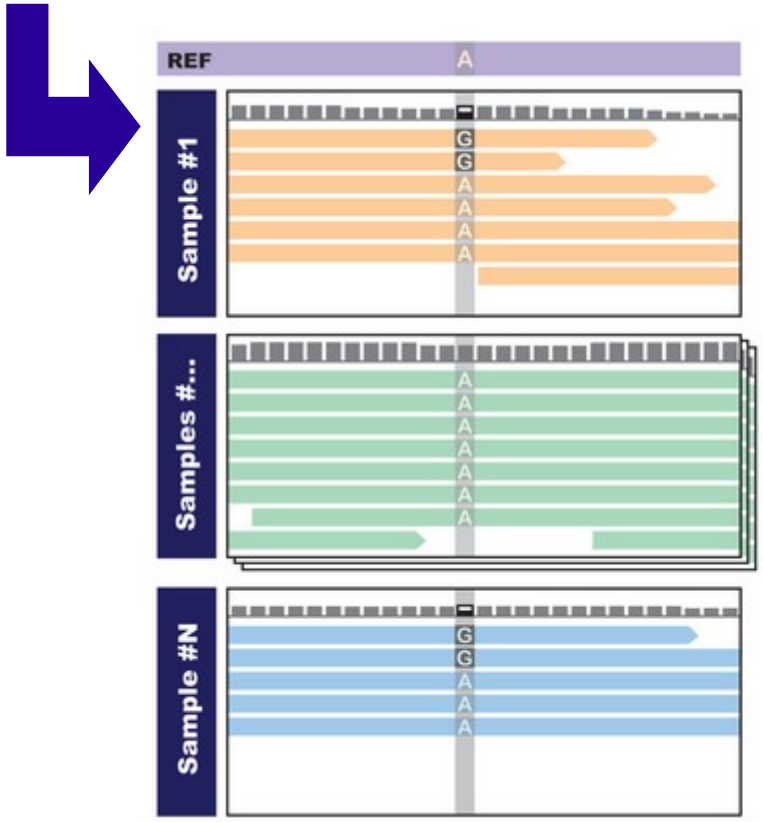

https://software.broadinstitute.org/gatk/documentation/article?id=11019

Bioinformática Clínica - Técnicas de secuenciación

Sesión 1 – 24/03/2025:

- Laboratorios de Bioinformática Clínica
- Técnicas de secuenciación empleadas en rutina diagnóstica
- Datos crudos generados
- Revisión de los datos generados
- Tipo de eventos genómicos y genéticos a determinar
- Limitaciones de las técnicas

- **Revisión de intereses**
- **Revisión de datos y herramientas**