Procesamiento de ficheros ómicos

Mario Solís López
31/03/2025

Procesamiento de ficheros ómicos

Sesión 4:

- Preprocesado
- Alineamiento (secuenciación masiva)
- Variant Calling
- Revisión visual de resultados

Objetivos

- ✓ Repasar los principales pasos del análisis de determinación de variantes germinales sobre datos de DNASeq de lectura corta
- ✓ Revisar el procesamiento del dato crudo de Illumina
- ✓ Comprender cómo realizar el control de calidad de la secuenciación
- ✓ Entender cómo realizar el pre-procesado de los datos
- ✓ Conocer las Best Practices de GATK
- ✓ Repasar salida del alineamiento
- ✓ Revisar herramientas de Variant Calling
- ✓ Revisión de ficheros resultantes
- ✓ Conocer recursos online de donde descargar pipelines de análisis

Introducción

- Análisis bioinformático de los datos de secuenciación masiva.
  - Determinación de las mutaciones causales.
- Es necesario llevar a cabo un **control de calidad**.

Secuenciación

- La secuenciación debe realizarse únicamente con muestras de DNA de alta calidad:
  - Espectrofotometría: *Nanodrop*
  - Electroforesis en gel: *Bioanalyser*
- Antes de secuenciar, las librerías se comprueban en el *Bioanalyser*.
- **¡Secuenciación**!
- El secuenciador almacena las lecturas en el formato *BCL*.
- Conversión de BCL a FASTQ → **Demultiplexado**
  - Para demultiplexar → *bcl2fastq2* (https://support.illumina.com/downloads/bcl2fastq-conversion-software-v2-20.html)
  - Algunos secuenciadores devuelven los *FASTQ*.

Demultiplexado

- Tanto el programa de Illumina ***bcl2fastq2/BCLConvert*** como los secuenciadores devuelven un report de **demultiplexado**.

- Múltiples marcadores de calidad por muestra:

  – '*Clusters'* → necesario un número mínimo por muestra

  – '*% of the lane*'

  – '*% perfect barcode*'

  – '*%Q30*'

  – '*Cluster PF (%)*'

Demultiplexado

- Requiere fichero de configuración denominado SampleSheet
  - Formato similar a un csv de configuración
  - Contiene información del nombre de las muestras
  - Índices (i7 e i5, si es dual index)
  - Configuración para herramientas de análisis de Illumina
- En resumen, contiene la información necesaria para extraer del dato crudo de la secuenciación, los ficheros FASTQs de las muestras
- Se suele preparar junto con la hoja de trabajo de preparación de la placa de muestras

Demultiplexado

- Re
  -
  -
  -
  -
- En to crudo de
- Se placa de

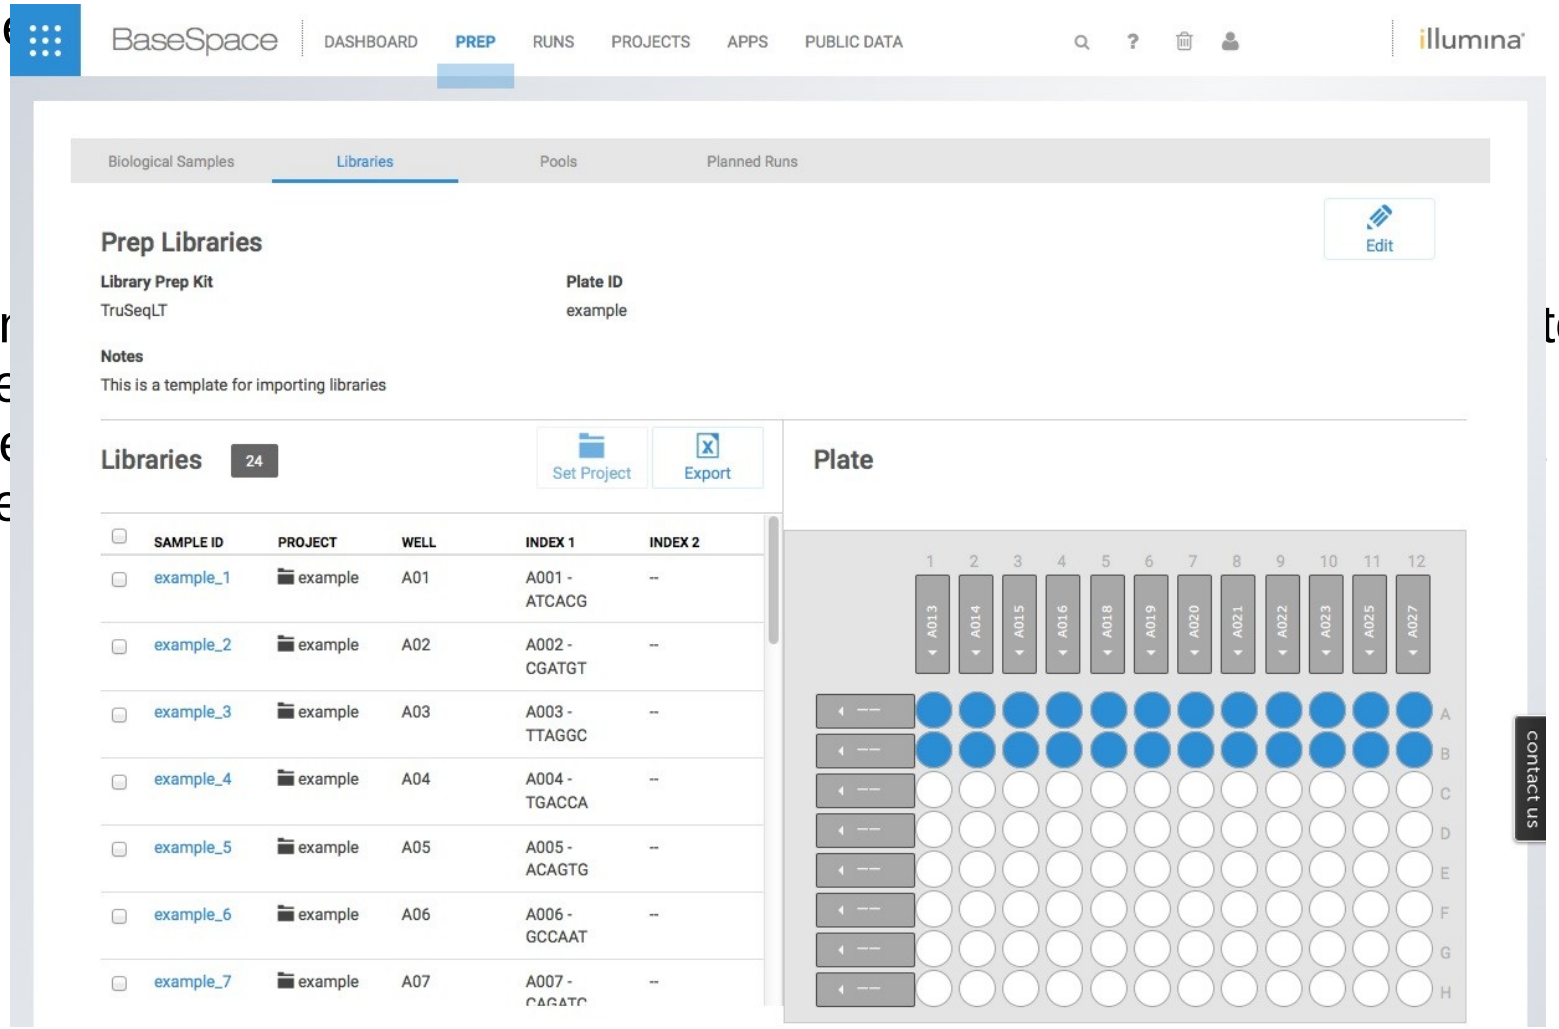

Demultiplexado

- Re
  -
  -
  -
  -
- En to crudo de
- Se placa de

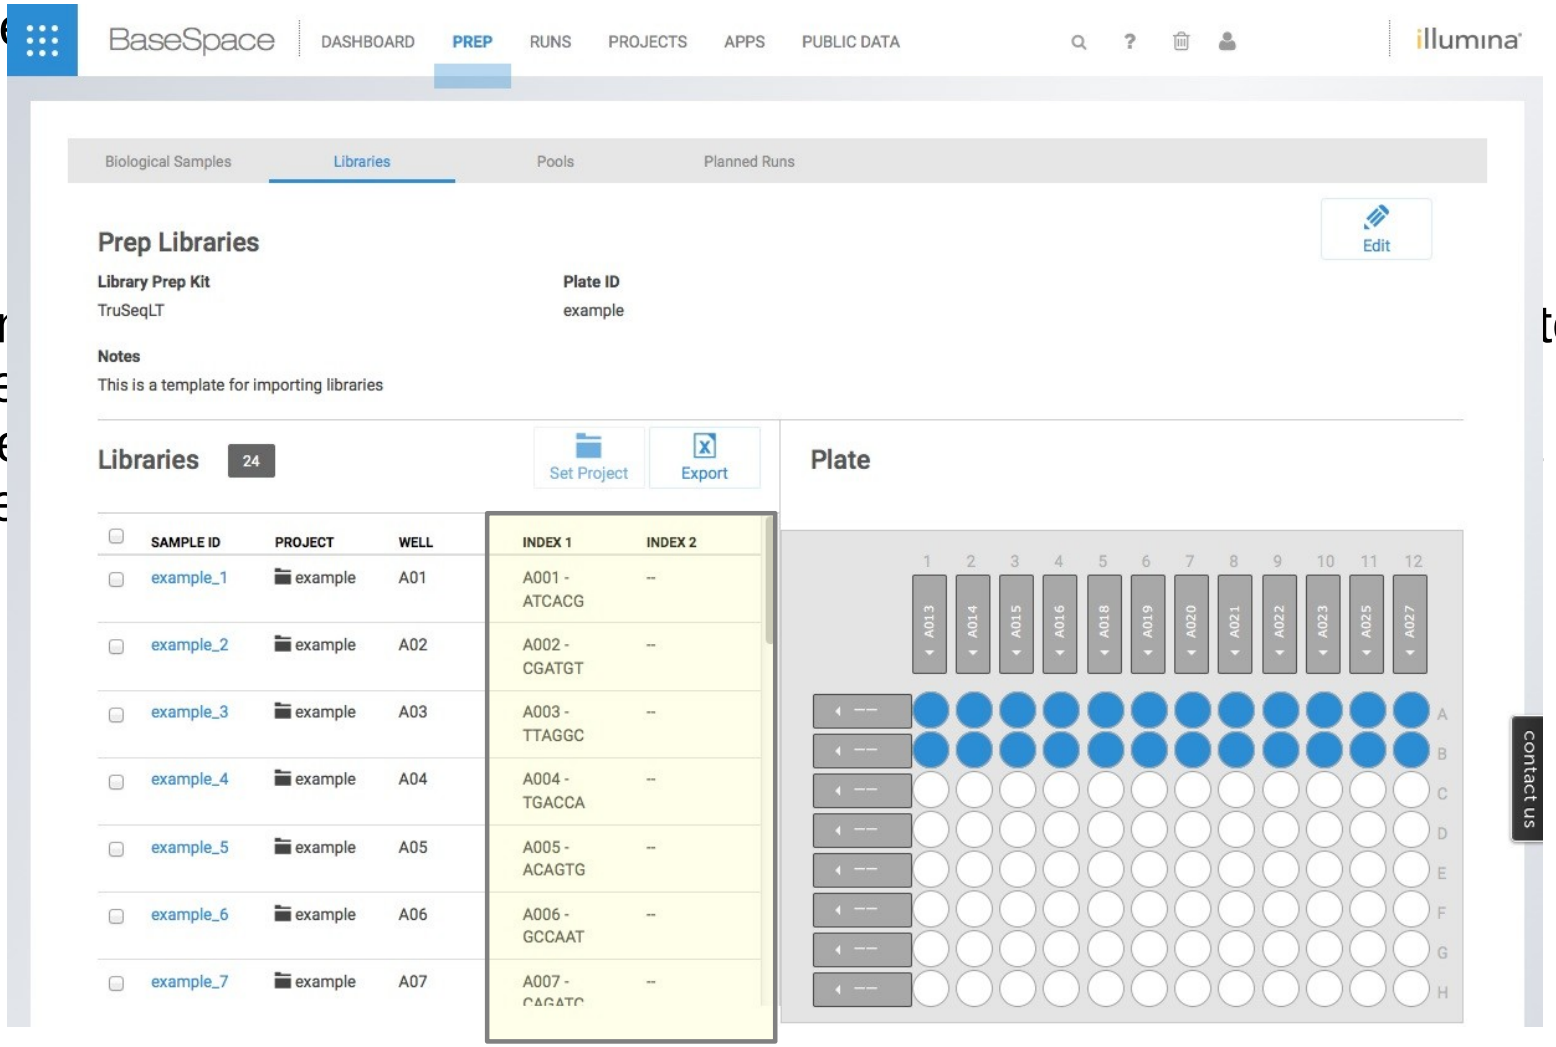

Demultiplexado

A	B	C	D	E	F	G	H	I	J	K
[Header]										
IEMFileVersion	5									
Investigator Name	Lachlan Morrison									
Experiment Name	Mouse_RNAseq									
Date	8/08/2023									
Workflow	GenerateFASTQ									
Application	FASTQ Only									
Instrument Type	MiSeq									
Assay	TruSeq Nano DNA									
Index Adapters	TruSeq DNA UD Indexes									
Chemistry	Amplicon									
[Reads]										
151										
151										
[Settings]										
[Data]										
Sample_ID	Sample_Name	Sample_Plate	Sample_Well	Index_Plate_Well	I7_Index_ID	index	I5_Index_ID	index2	Sample_Project	Description
Sample1				A01	UDI0001	CCGCGGTT	UDI0001	AGCGCTAG	Mouse_RNAseq	
Sample2				B01	UDI0002	TTATAACC	UDI0002	GATATCGA	Mouse_RNAseq	
Sample3				C01	UDI0003	GGACTTGG	UDI0003	CGCAGACG	Mouse_RNAseq	
Sample4				D01	UDI0004	AAGTCCAA	UDI0004	TATGAGTA	Mouse_RNAseq	
Sample5				E01	UDI0005	ATCCACTG	UDI0005	AGGTGCGT	Mouse_RNAseq	
Sample6				F01	UDI0006	GCTTGTCA	UDI0006	GAACATAC	Mouse_RNAseq	
Sample7				G01	UDI0007	CAAGCTAG	UDI0007	ACATAGCG	Mouse_RNAseq	
Sample8				H01	UDI0008	TGGATCGA	UDI0008	GTGCGATA	Mouse_RNAseq	

Demultiplexado

- Hay diferentes placas de índices comerciales
- Se puede utilizar un único índice (single-index, solo i7) o dos (dual-index, i7 e i5)
- Es importante desde el laboratorio y desde bioinformática tener controlados qué índices tiene cada muestra
- Un error en una asignación de un índice implica un cambio de muestra

Demultiplexado

- El demultiplexado genera un report de calidad en formato HTML plano
- Permite revisar el número de clusters asignado a cada índice (o pareja de índices), y, a cada muestra que tenga esos índices
- También reporta el número de clusters para cada índice (o pareja de índices) que no tienen muestra asignada, de forma rankeada (top unknown).
- Esto permite identificar si ha habido una incorrecta asignación en los índices de las muestras
- Igualmente se reporta el % de clusters que ha pasado el filtro de calidad y el Q30 de cada muestra

Demultiplexado

AACJL2VHV
[default project]
22-1198
AACTGCAA+TGAGCTGA
23-2504
AGCTGAAG+GCAAGCTG
23-3762
TATGCCGC+CACGGAAT
24-1602
ATTCCGTG+CTTCAGCT
24-2038
TCAGCTCA+GCGGCATA
24-2082
TGAGGAGT+ATTGCGCG
24-2083
ATGACGAA+ACTCCTCA
24-2084
TACGGCGA+TTCGTCAT
24-2219
ATTAGGAG+TTGCAGTT
24-2220
CAGCAATA+CTCCTAAT
24-2221
GCCAAGCT+TATTGCTG
24-2222
AGCGAGTT+TCGCCGTA
24-2223
TGTATCAC+AACTCGCT
24-2224
GATCGCCT+GTGATACA

AACJL2VHV / [all projects] / [all samples] / [all barcodes]

hide barcodes

Flowcell Summary

Clusters (Raw)	Clusters(PF)	Yield (MBases)
1,770,758,496	1,230,493,311	359,304

Lane Summary

Lane	Project	Sample	Barcode sequence	PF Clusters	% of the lane	% Perfect barcode	% One mismatch barcode	Yield (Mbases)	% PF Clusters	% >= Q30 bases	Mean Quality Score
1	default	22-1198	AACTGCAA+TGAGCTGA	38,821,281	6.51	100.00	0.00	11,336	100.00	91.88	32.81
1	default	23-2504	AGCTGAAG+GCAAGCTG	32,627,604	5.47	100.00	0.00	9,527	100.00	92.12	32.86
1	default	23-3762	TATGCCGC+CACGGAAT	34,885,415	5.85	100.00	0.00	10,187	100.00	91.73	32.80
1	default	24-1602	ATTCCGTG+CTTCAGCT	34,281,464	5.75	100.00	0.00	10,010	100.00	91.89	32.81
1	default	24-2038	TCAGCTCA+GCGGCATA	32,405,734	5.43	100.00	0.00	9,462	100.00	91.70	32.77
1	default	24-2082	TGAGGAGT+ATTGCGCG	35,485,591	5.95	100.00	0.00	10,362	100.00	91.32	32.71
1	default	24-2083	ATGACGAA+ACTCCTCA	32,977,454	5.53	100.00	0.00	9,629	100.00	91.17	32.67
1	default	24-2084	TACGGCGA+TTCGTCAT	33,009,930	5.53	100.00	0.00	9,639	100.00	91.73	32.78
1	default	24-2219	ATTAGGAG+TTGCAGTT	35,077,221	5.88	100.00	0.00	10,243	100.00	92.37	32.90
1	default	24-2220	CAGCAATA+CTCCTAAT	36,208,264	6.07	100.00	0.00	10,573	100.00	92.23	32.87
1	default	24-2221	GCCAAGCT+TATTGCTG	38,756,610	6.50	100.00	0.00	11,317	100.00	92.22	32.88
1	default	24-2222	AGCGAGTT+TCGCCGTA	33,053,279	5.54	100.00	0.00	9,652	100.00	91.73	32.78
1	default	24-2223	TGTATCAC+AACTCGCT	33,001,180	5.53	100.00	0.00	9,636	100.00	91.84	32.81
1	default	24-2224	GATCGCCT+GTGATACA	38,985,058	6.54	100.00	0.00	11,384	100.00	91.82	32.80
1	default	24-2225	GACTCAAT+AGGCGATC	38,846,405	6.51	100.00	0.00	11,343	100.00	91.33	32.71

Demultiplexado

- El demultiplexado genera un report de calidad en formato HTML plano
- Permite revisar el número de clusters asignado a cada índice (o pareja de índices), y, a cada muestra que tenga esos índices
- También reporta el número de clusters para cada índice (o pareja de índices) que no tienen muestra asignada, de forma rankeada (top unknown).
- Esto permite identificar si ha habido una incorrecta asignación en los índices de las muestras
- Igualmente se reporta el % de clusters que ha pasado el filtro de calidad y el Q30 de cada muestra

- Es posible predecir el número de clusters deseado en función de la cobertura deseada en la región de captura
- Si una muestra no llega a un número adecuado, la muestra no debería ser empleada en el análisis y debería resecuenciarse, salvo para casos críticos (no hay más muestra, es una urgencia...)

FASTQ

- Las lecturas se almacenan en el formato FASTQ (.fq, .fastq, .fastq.gz…).
- Similar al formato FASTA.
- Contienen información sobre la calidad de cada base de cada lectura.
- Las calidades se codifican en formato ASCII y, dependiendo de la plataforma, pueden tener distinto rango o codificación.

FASTQ

- Las lecturas se almacenan en el formato FASTQ (.fq, .fastq, .fastq.gz…).
- Similar al formato FASTA.
- Contienen información sobre la calidad de cada base de cada lectura.
- Las calidades se codifican en formato ASCII y, dependiendo de la plataforma, pueden tener distinto rango o codificación.

```
@M00665:113:000000000-AW3FM:1:1101:18487:1927 2:N:0:1
TTCTCGCAGCTAACAGGGTGGAAACTGTTGAAAGTTTGGCTTTTGATTGGATTTCAAAGAATCTCTATT
+
BFDDFFA11AB11A1100B000110D1DF12211DFG1/BGGHH1/AF101BBGF222100BFGEG2FG
```

- Cabecera (@) : identificador de secuencia.
- Secuencia de nucleótidos.
- Opcional (+).
- Valores de calidad de los nucleótidos de la línea 2 → BASEQ

FASTQ

- Las lecturas se almacenan en el formato FASTQ (.fq, .fastq, .fastq.gz…).
- Similar al formato FASTA.
- Contienen información sobre la calidad de cada base de cada lectura.
- Las calidades se codifican en formato ASCII y, dependiendo de la plataforma, pueden tener distinto rango o codificación.
- Un valor de calidad Q refleja la probabilidad de que la correspondiente determinación de una base sea incorrecta
- ‘Phred Quality Score’:

$$Q = -10 \log_{10} P$$

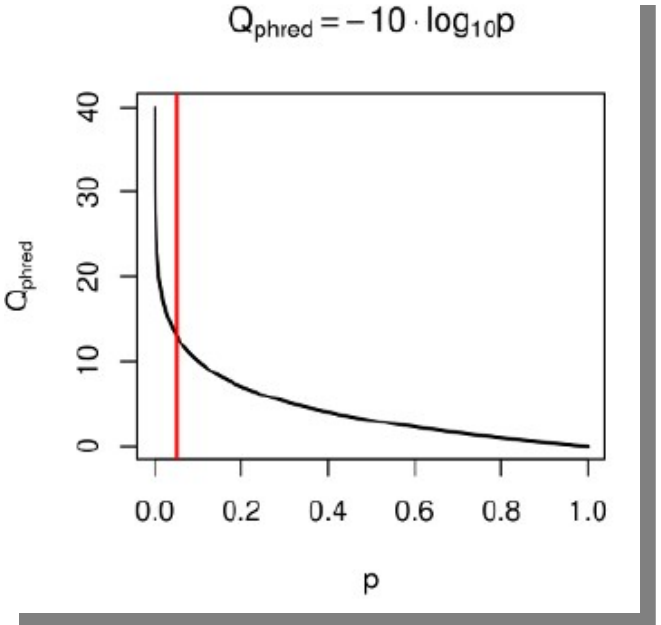

Control de calidad de FASTQ

- El QC en los FASTQ va a permitir:
  - Evaluar el proceso de secuenciación y las librerías.
  - Detectar lecturas de baja calidad.
  - Detectar lecturas que corresponden a moléculas secuenciadas no deseadas.
- Para analizar la calidad de las lecturas presentes en un FASTQ existen diversas herramientas:
  - **FASTQC** (https://www.bioinformatics.babraham.ac.uk/projects/fastqc/)
  - **MultiQC** (http://multiqc.info/)
  - Dentro de Bioconductor (R): ShortRead, QuasR, htSeqTools.

FASTQC

- *FASTQC* genera informes que permiten detectar problemas originados tanto en el secuenciador como en la preparación de librerías.

- Reporta múltiples parámetros de calidad, usando un sistema de tres colores: verde (normal), naranja (anormal) y rojo (erróneo).

  - Resumen del *FASTQ*

    - Contiene el nombre del fichero cargado, la codificación, número de lecturas...

FASTQC

– ‘*Per base sequence quality’:*

- Evaluación de la calidad de bases por posición en la secuencia.
- Por debajo de un BASEQ de 20 → ‘*trimming*’ de secuencias.

FASTQC

– ‘*Per base sequence quality*’:

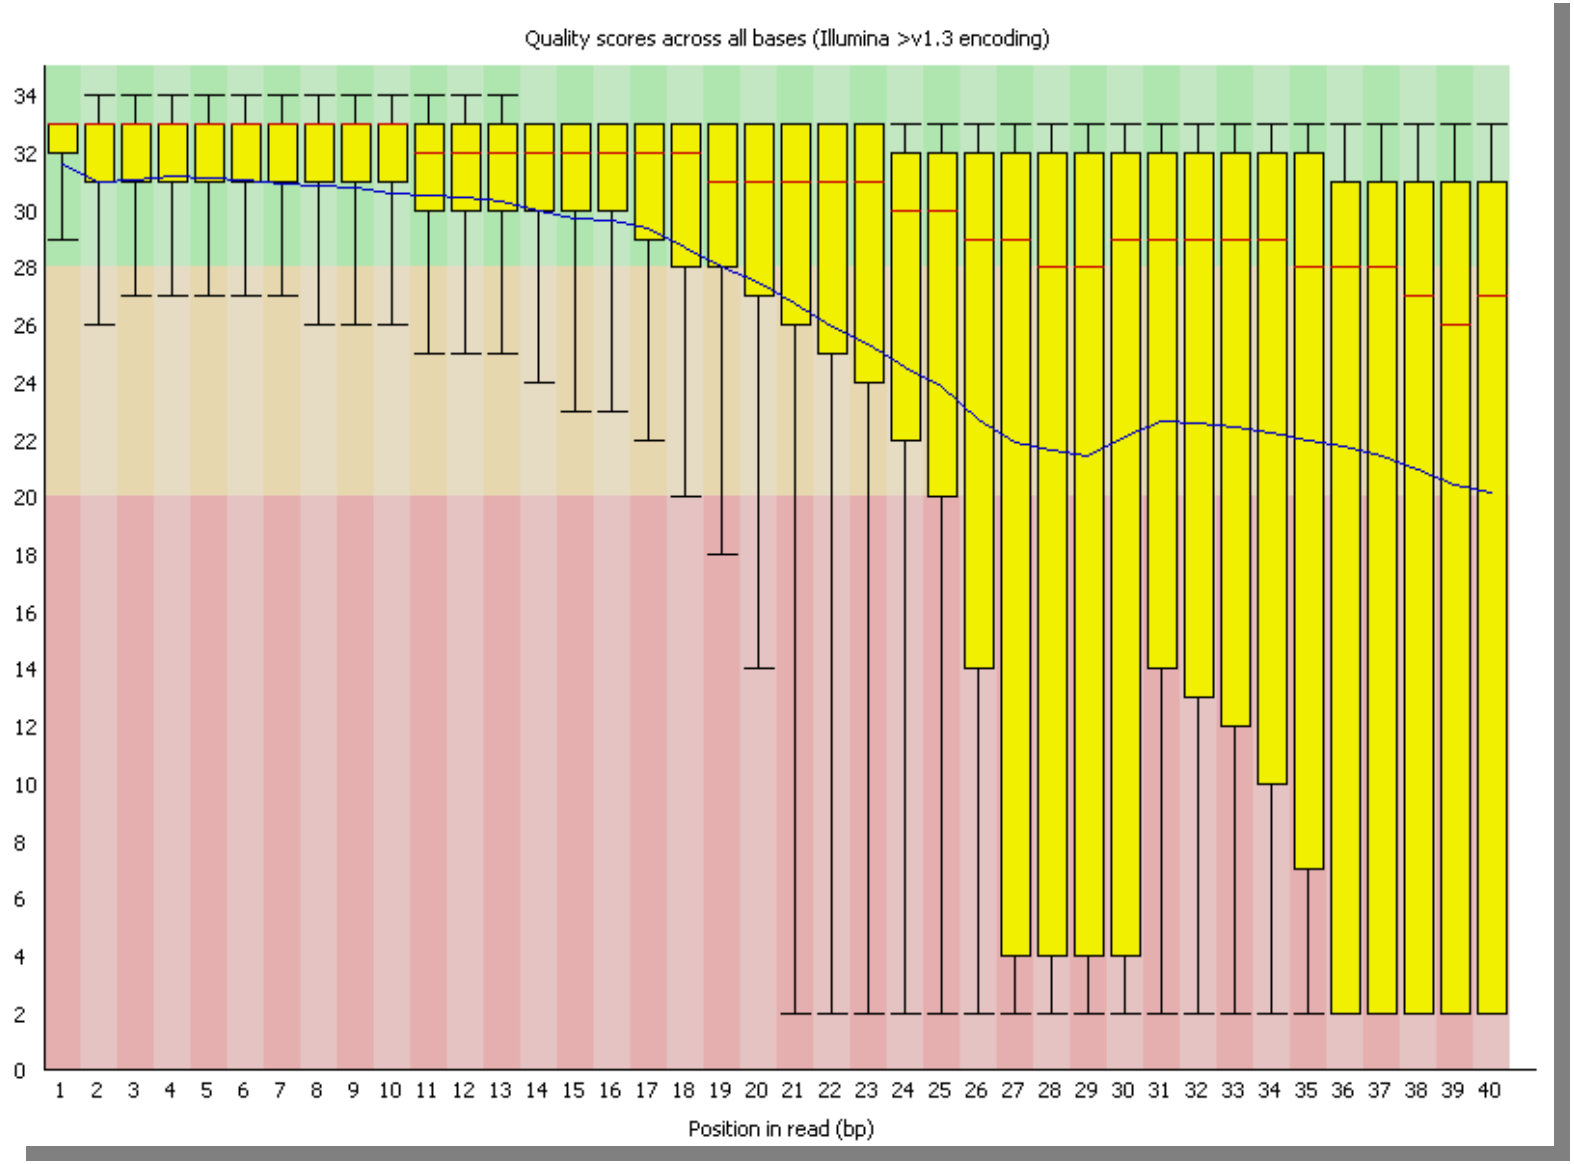

FASTQC

– ‘*Per base sequence quality*’:

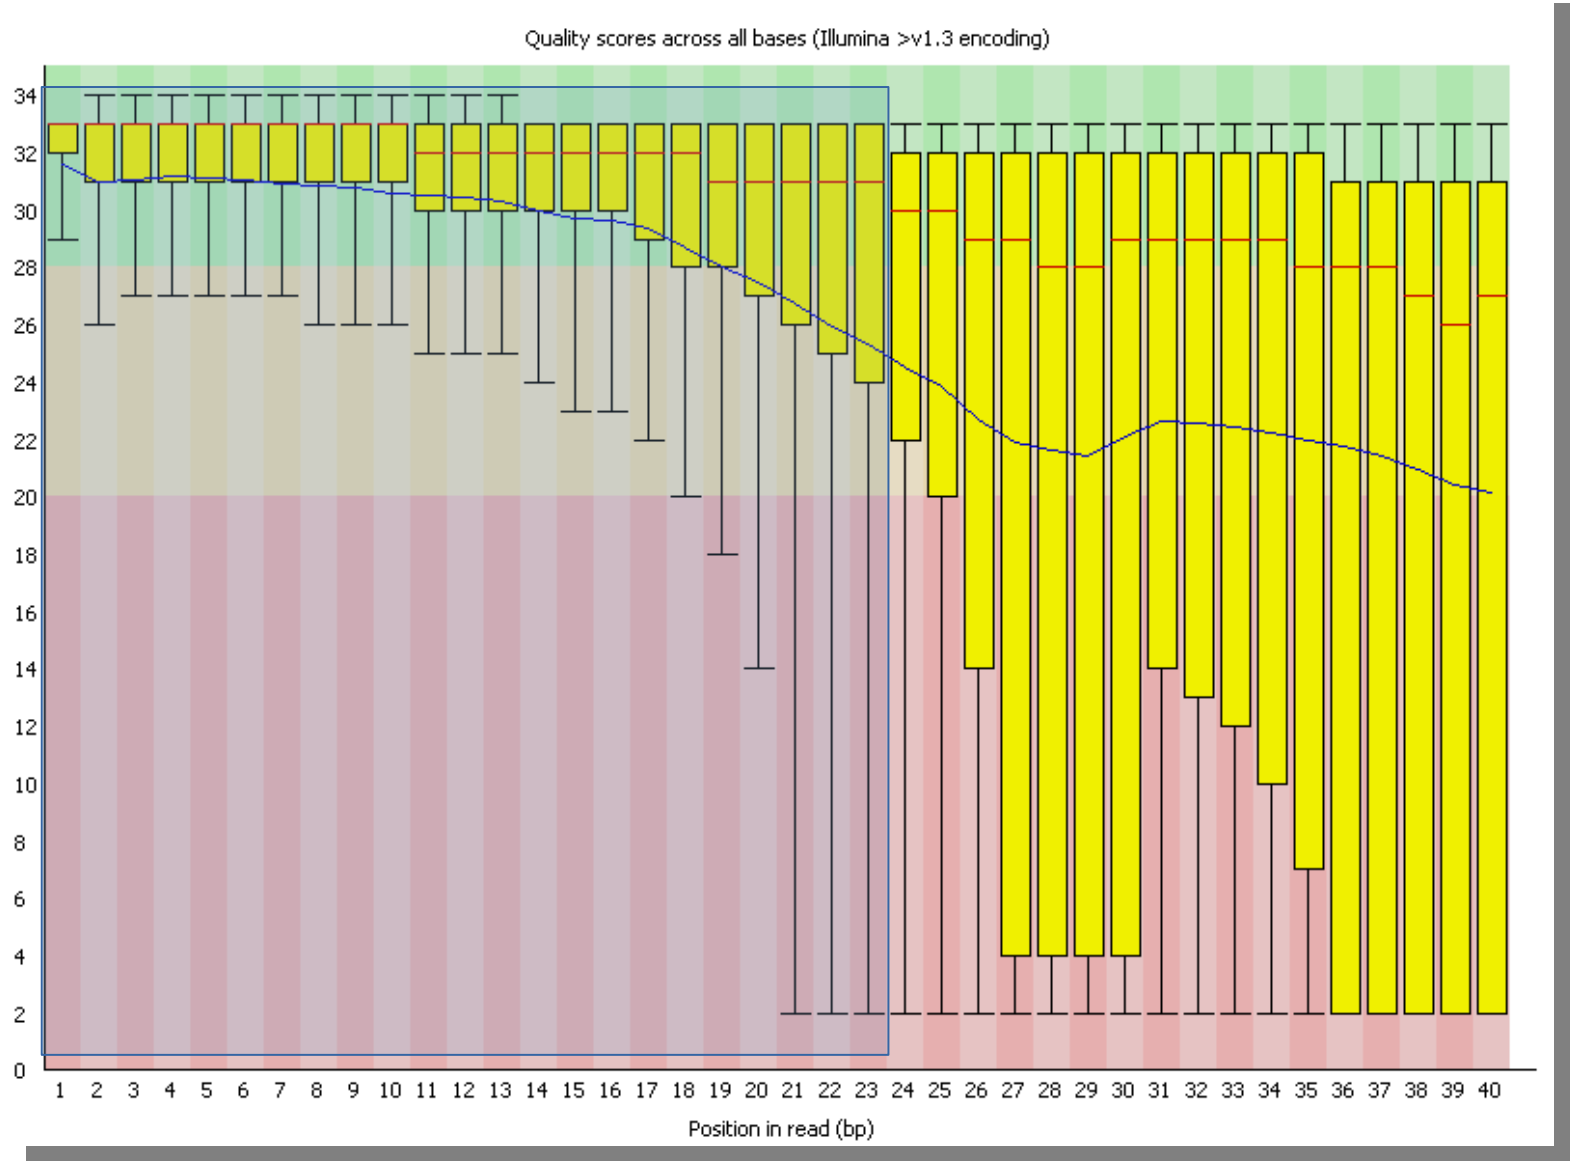

FASTQC

– ‘*Per sequence quality score’:*

- Se evalua el número de secuencias por calidad de bases media.
- Distribución uniforme en alta calidad.
- Filtrar secuencias cuya calidad media no alcance el umbral.

FASTQC

– ‘*Per sequence quality score’:*

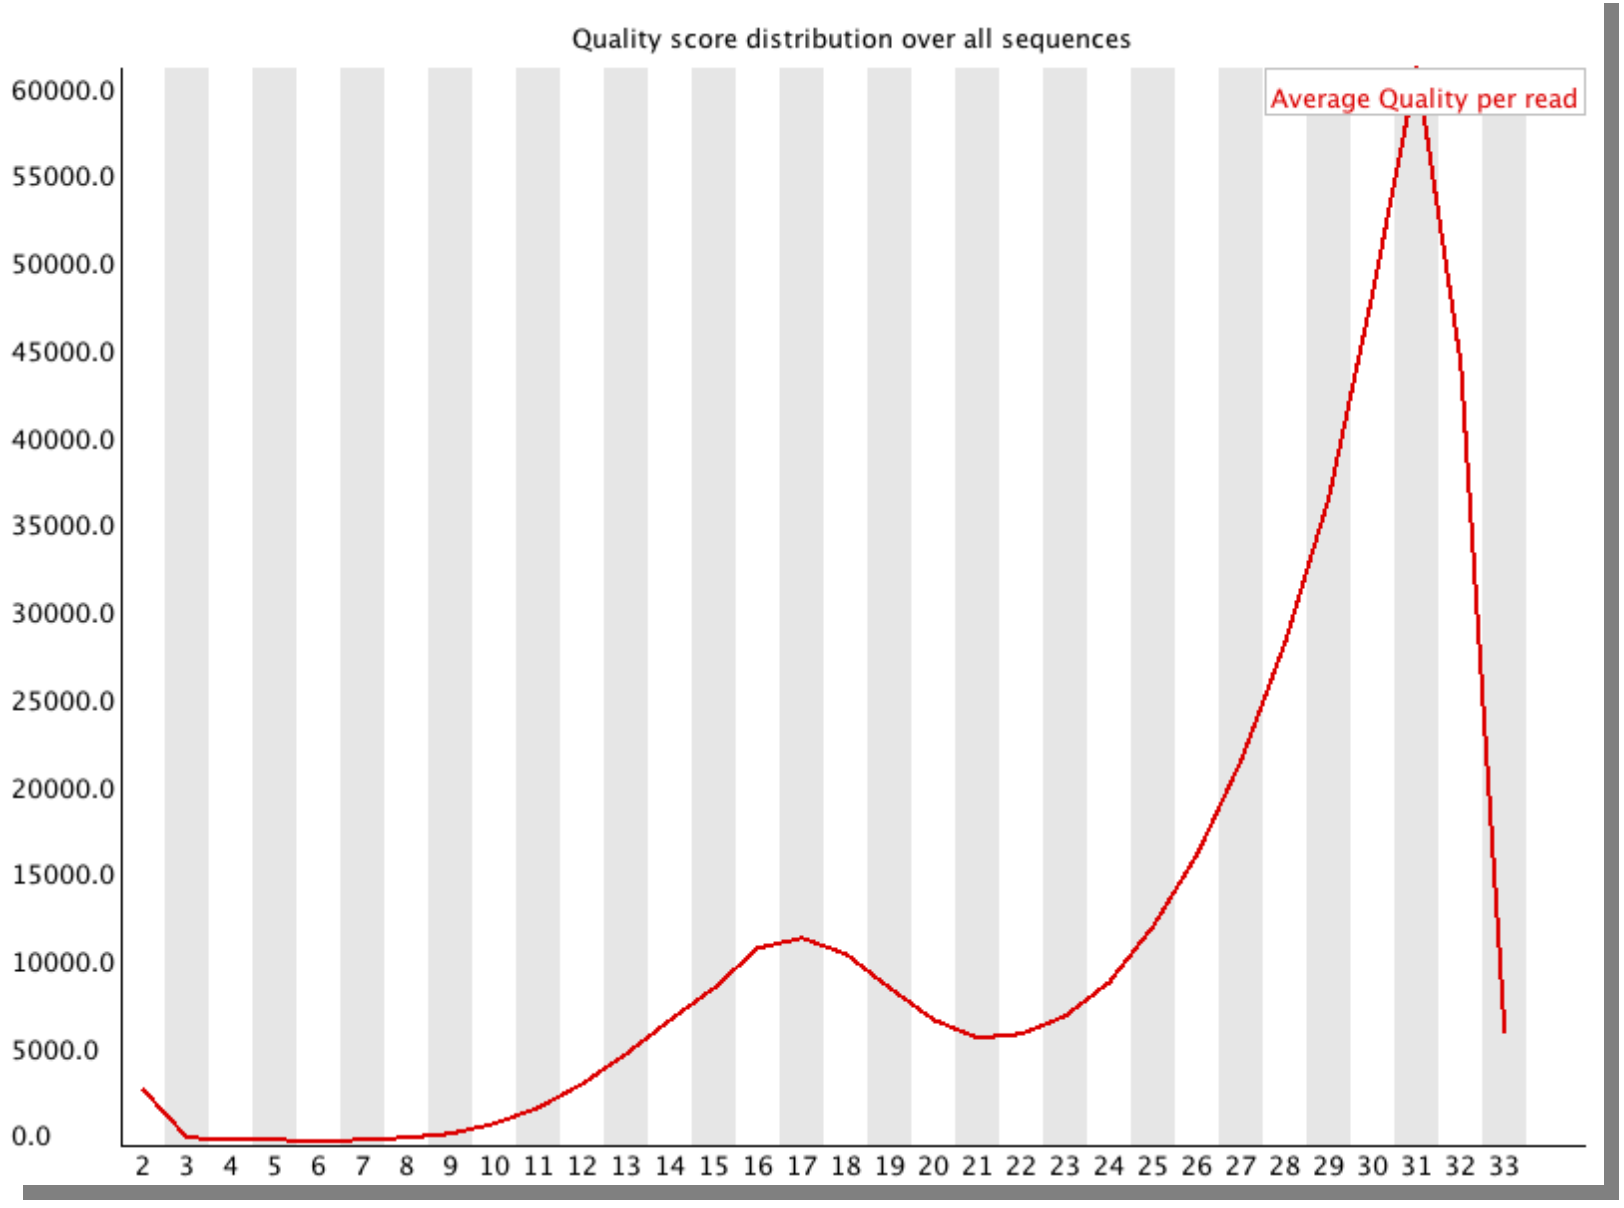

FASTQC

– *'Per sequence quality score':*

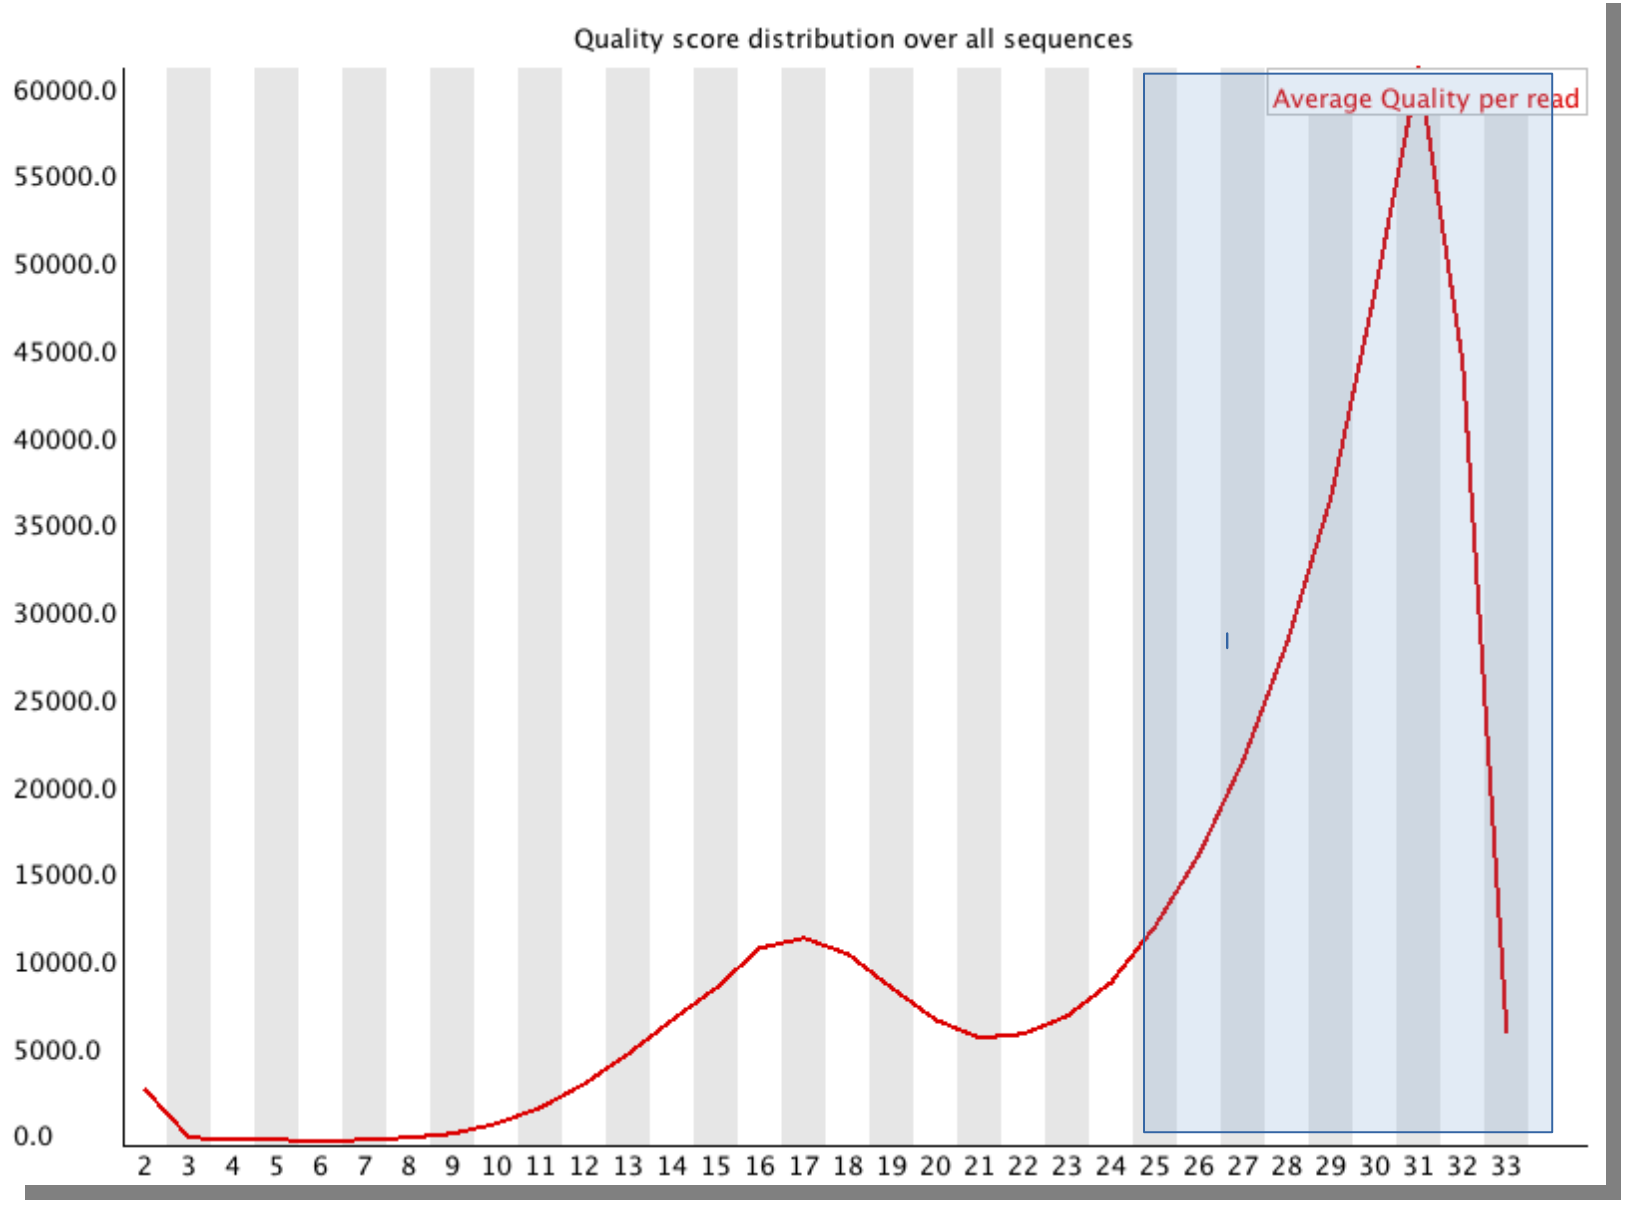

FASTQC

– ‘*Per base sequence content’:*

- Distribución homogénea y similar de los 4 pares de bases.
- No alterada por la posición de la base en la lectura.
- Líneas paralelas.

FASTQC

– *'Per base sequence content':*

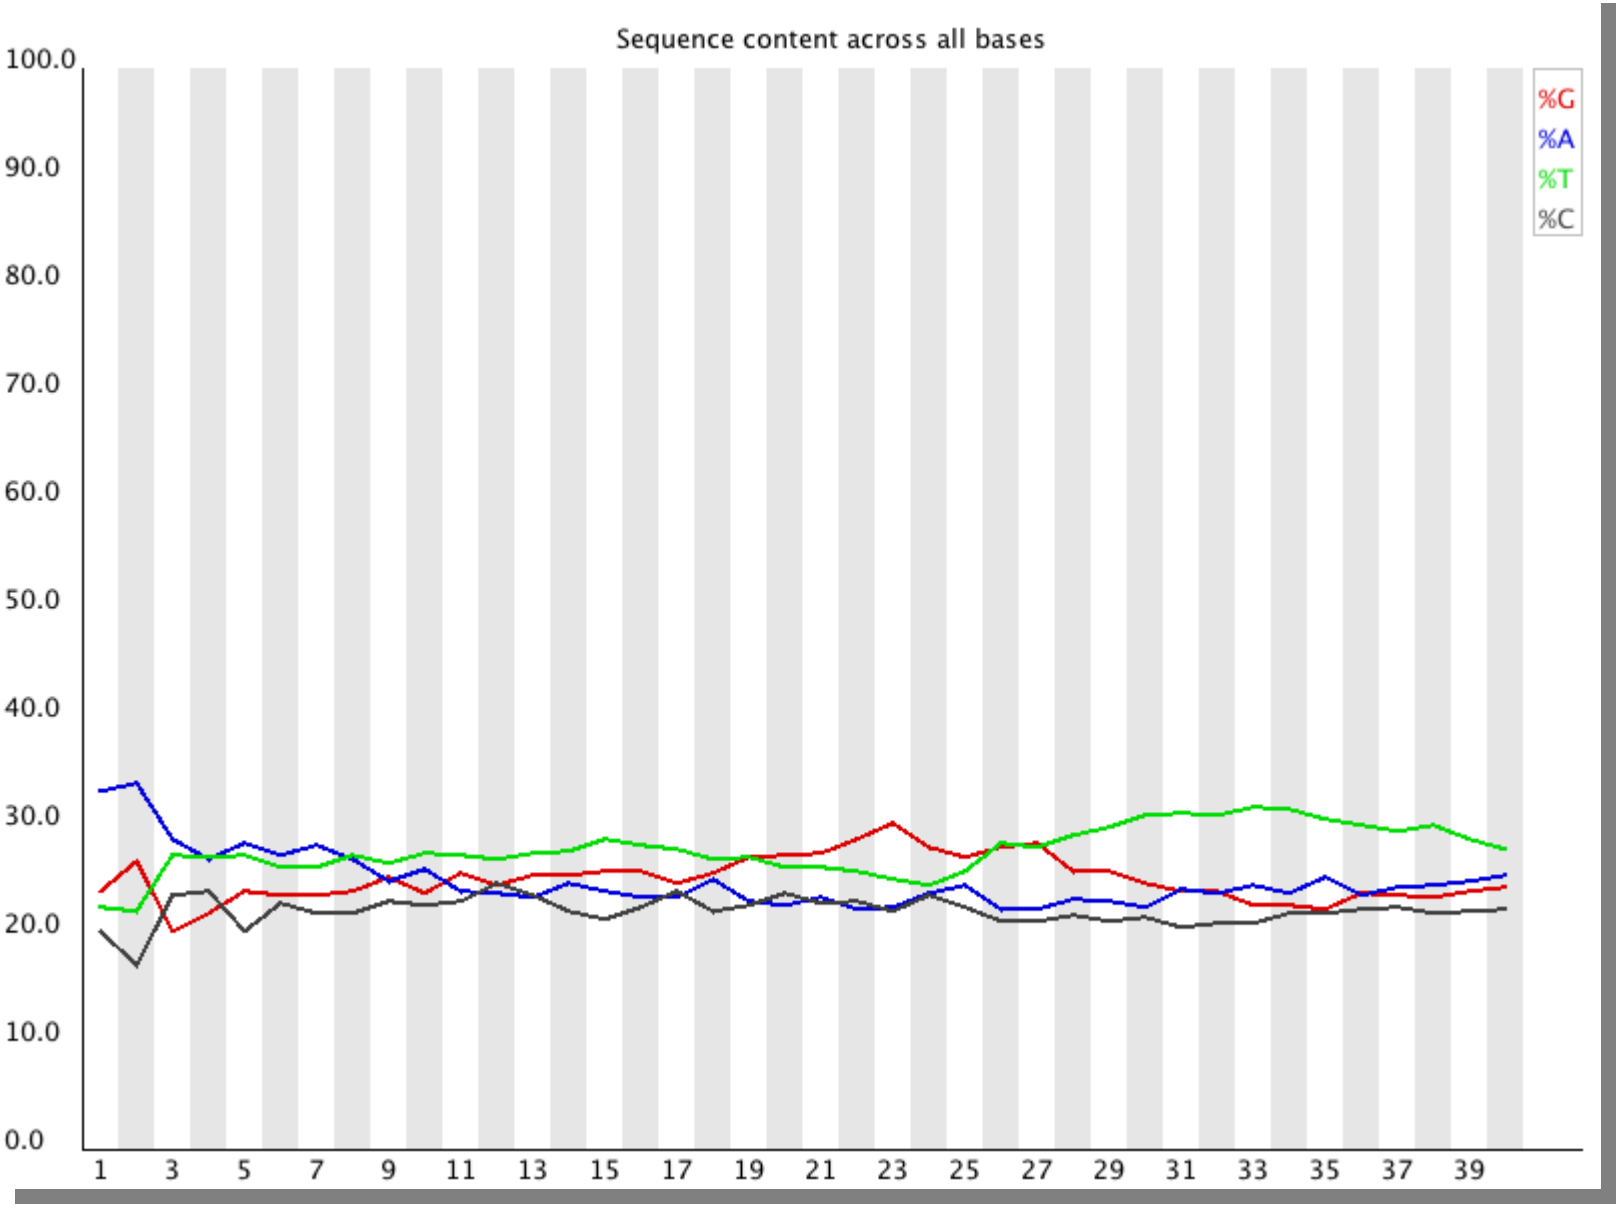

FASTQC

– ‘*Per base GC content’:*

- No debe depender de la posición de la base en la lectura.

FASTQC

– *'Per base GC content':*

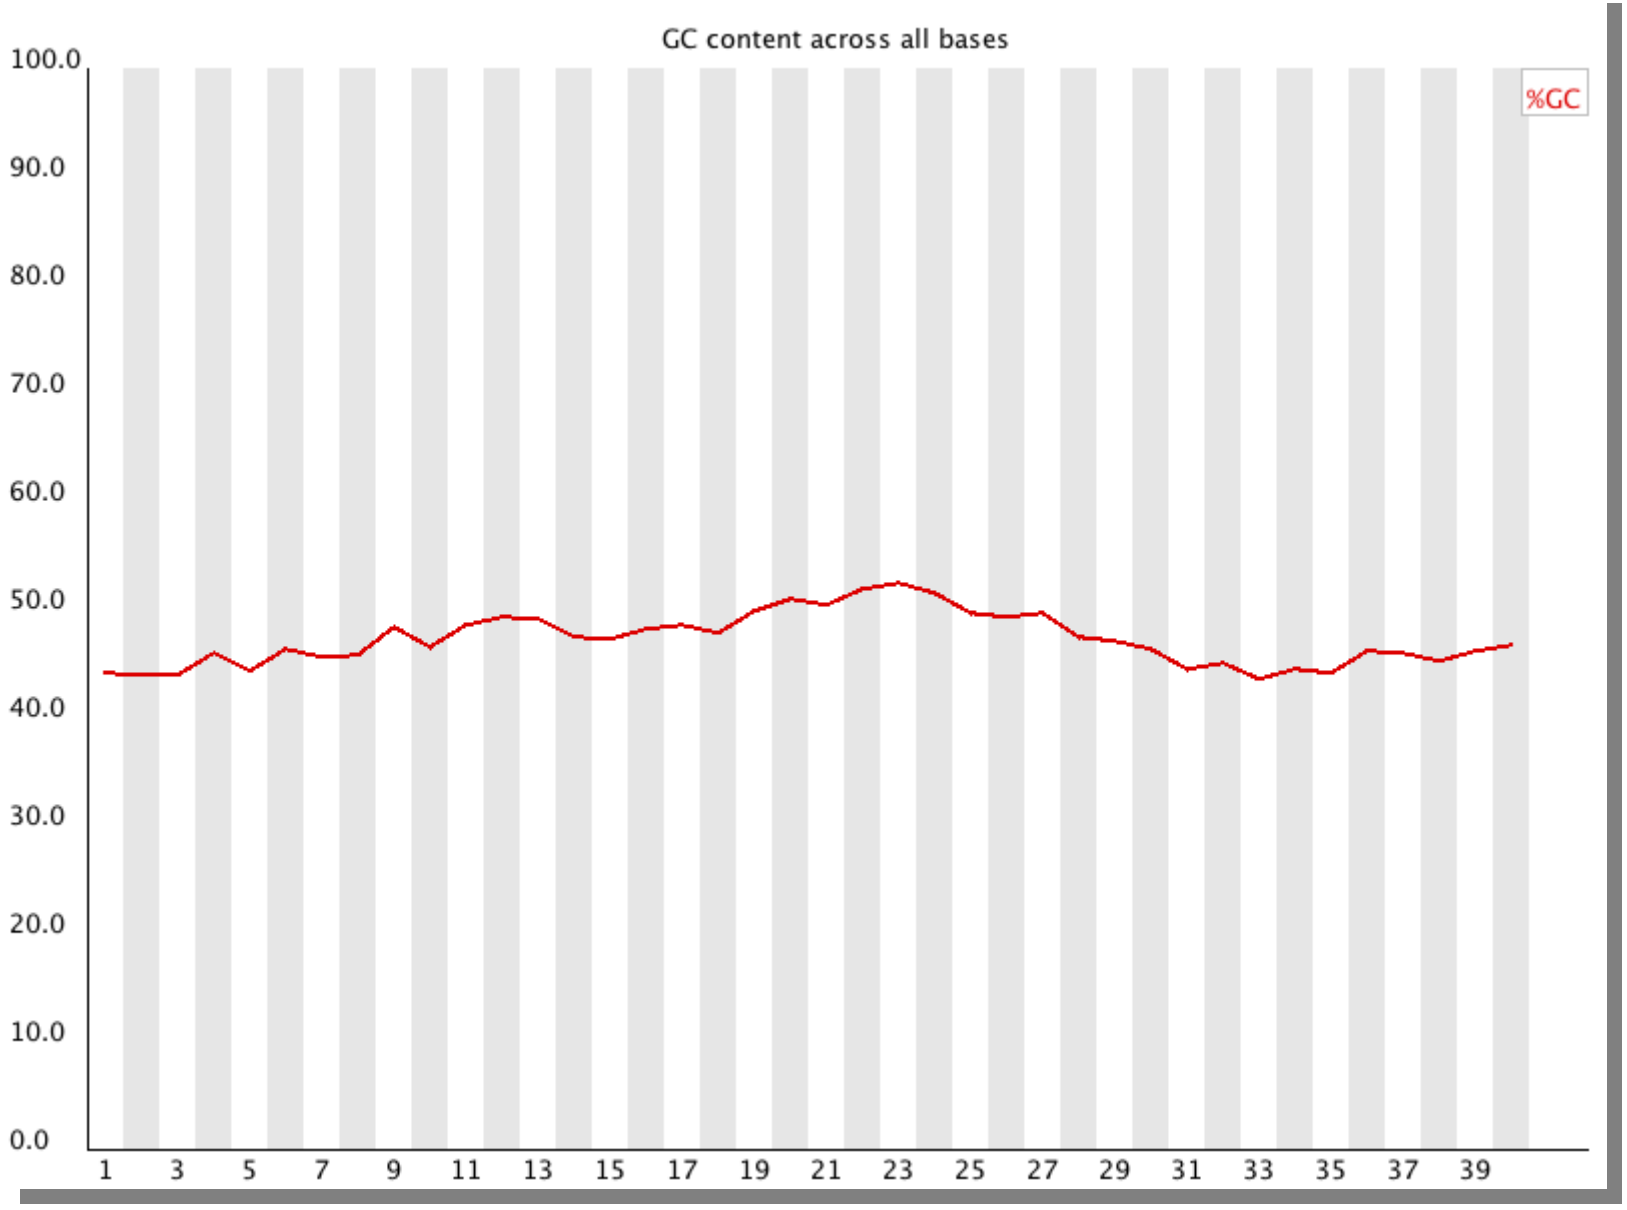

FASTQC

– ‘*Per sequence GC content’:*

- Distribución del contenido en GC a través de todas las secuencias.

- Debería observarse una distribución normal.

FASTQC

– *'Per sequence GC content':*

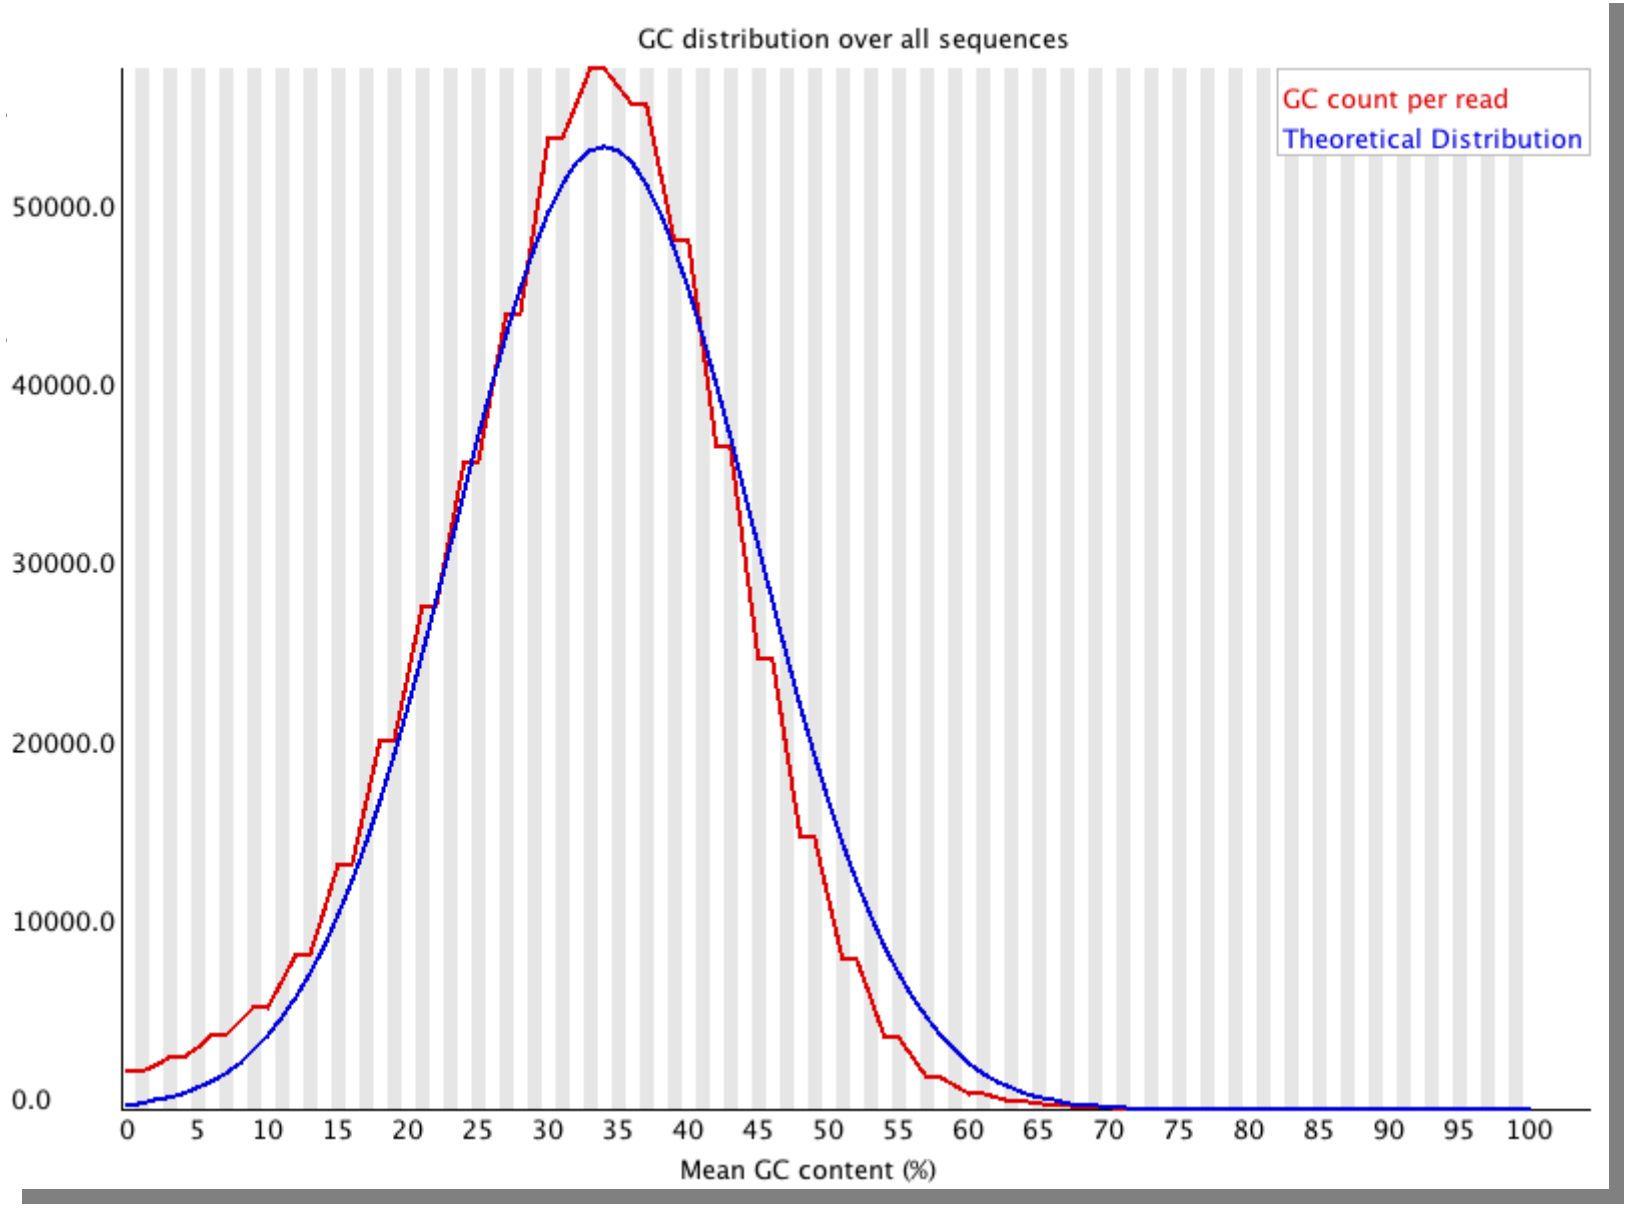

FASTQC

– ‘*Per base N content’:*

- No debería observarse nada

FASTQC

– *'Per base N content':*

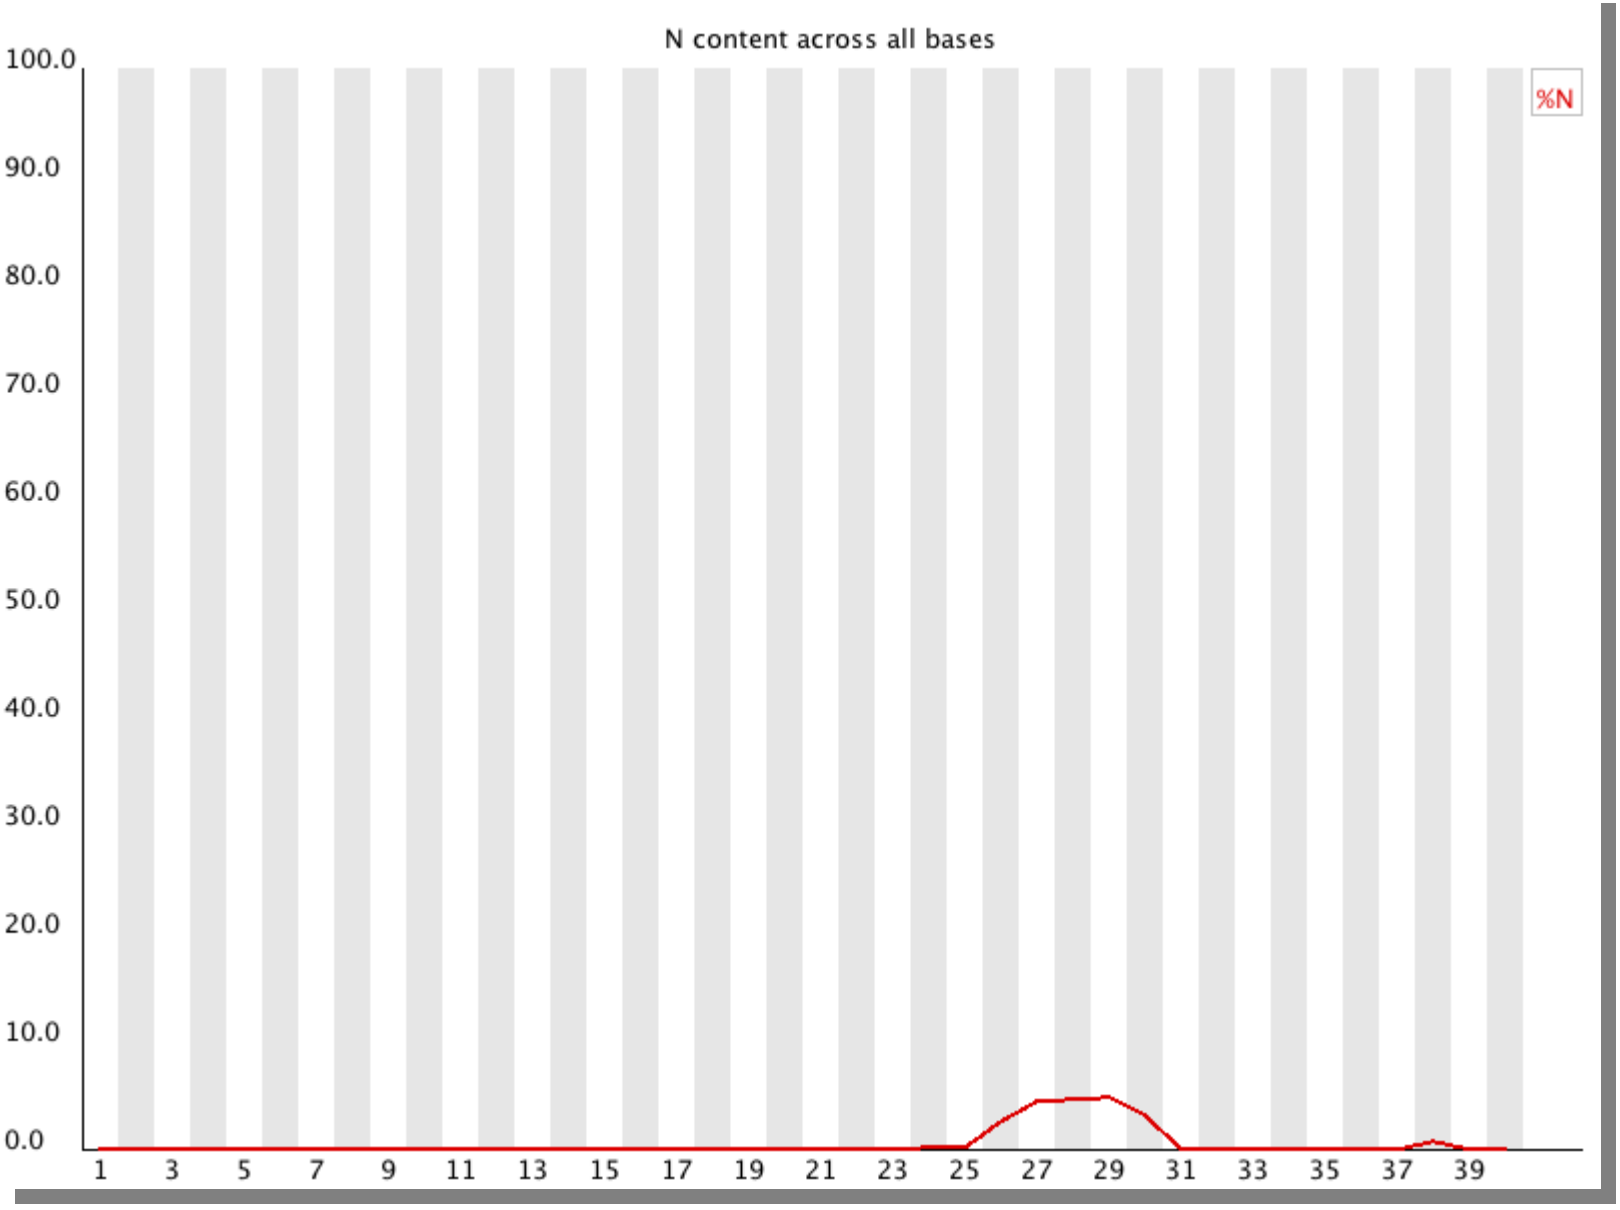

MULTIQC

- Corre una batería de herramientas de calidad:
  https://docs.seqera.io/multiqc/modules/

- Mantenida por seqera

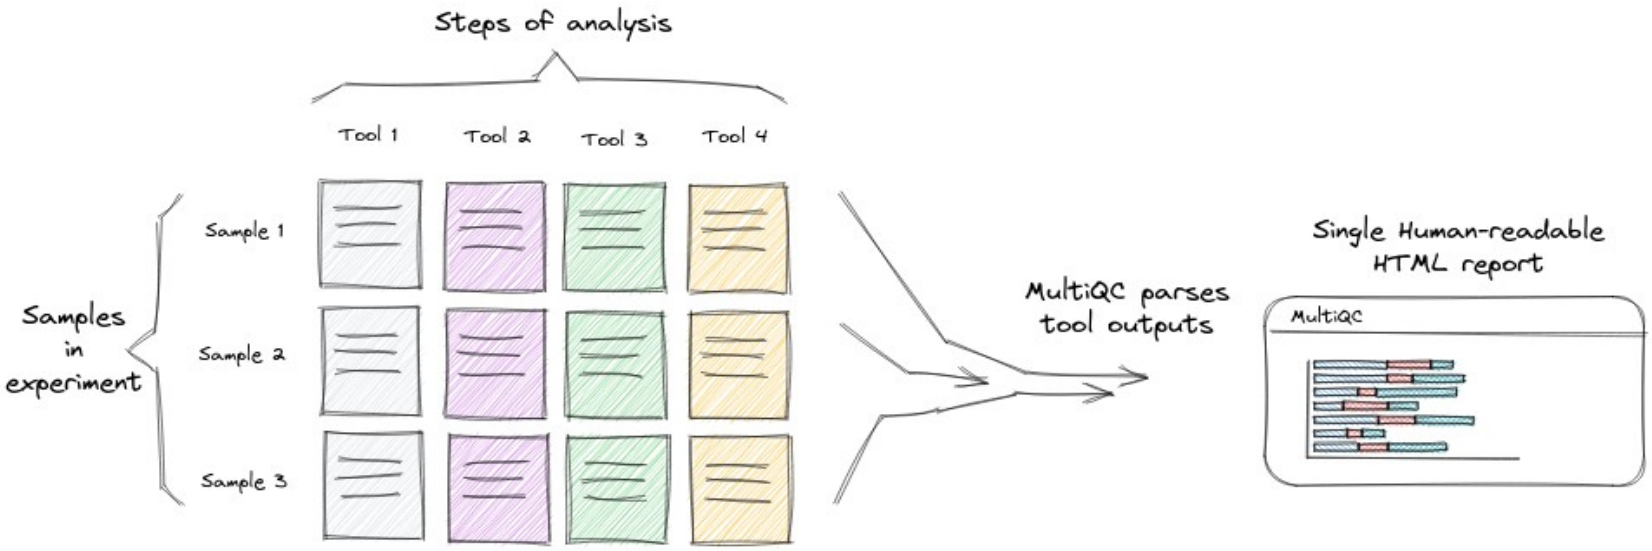

MULTIQC

- Vamos a instalar MultiQC
  https://docs.seqera.io/multiqc/getting_started/installation

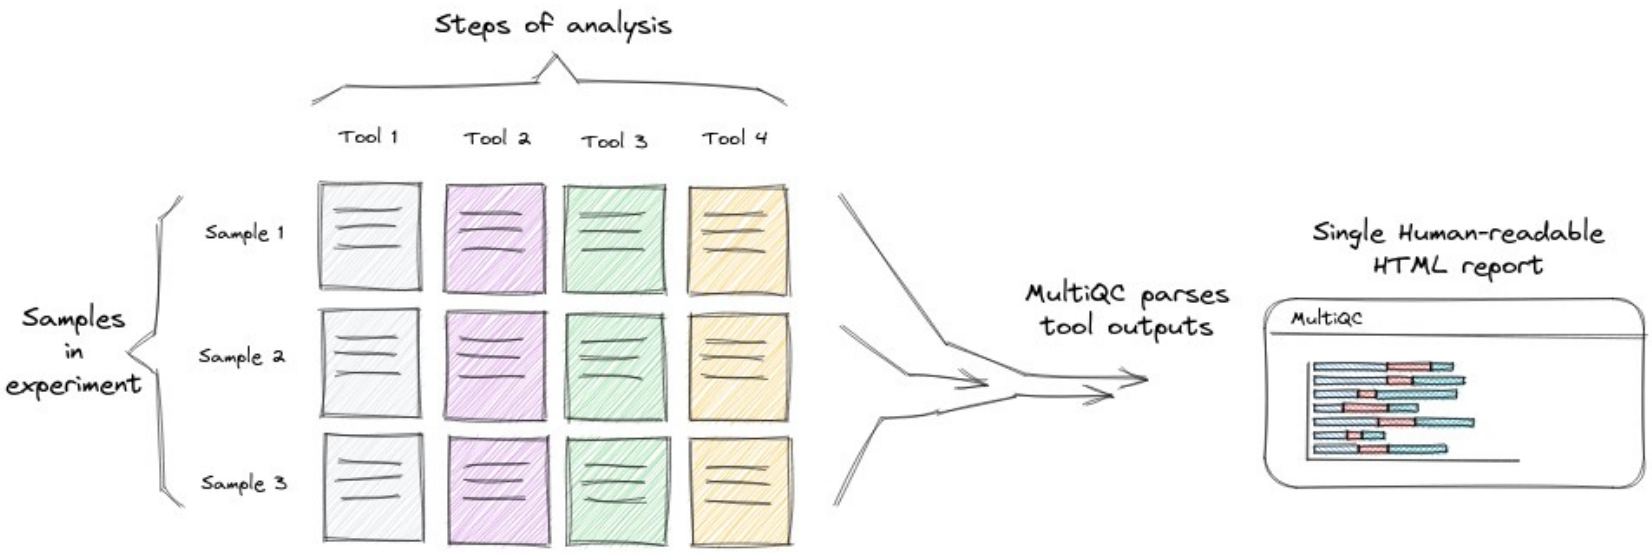

Pipeline Demux+QC

- Vamos a revisar una pipeline que emplea varias de las herramientas presentadas
- https://nf-co.re/demultiplex/1.6.0

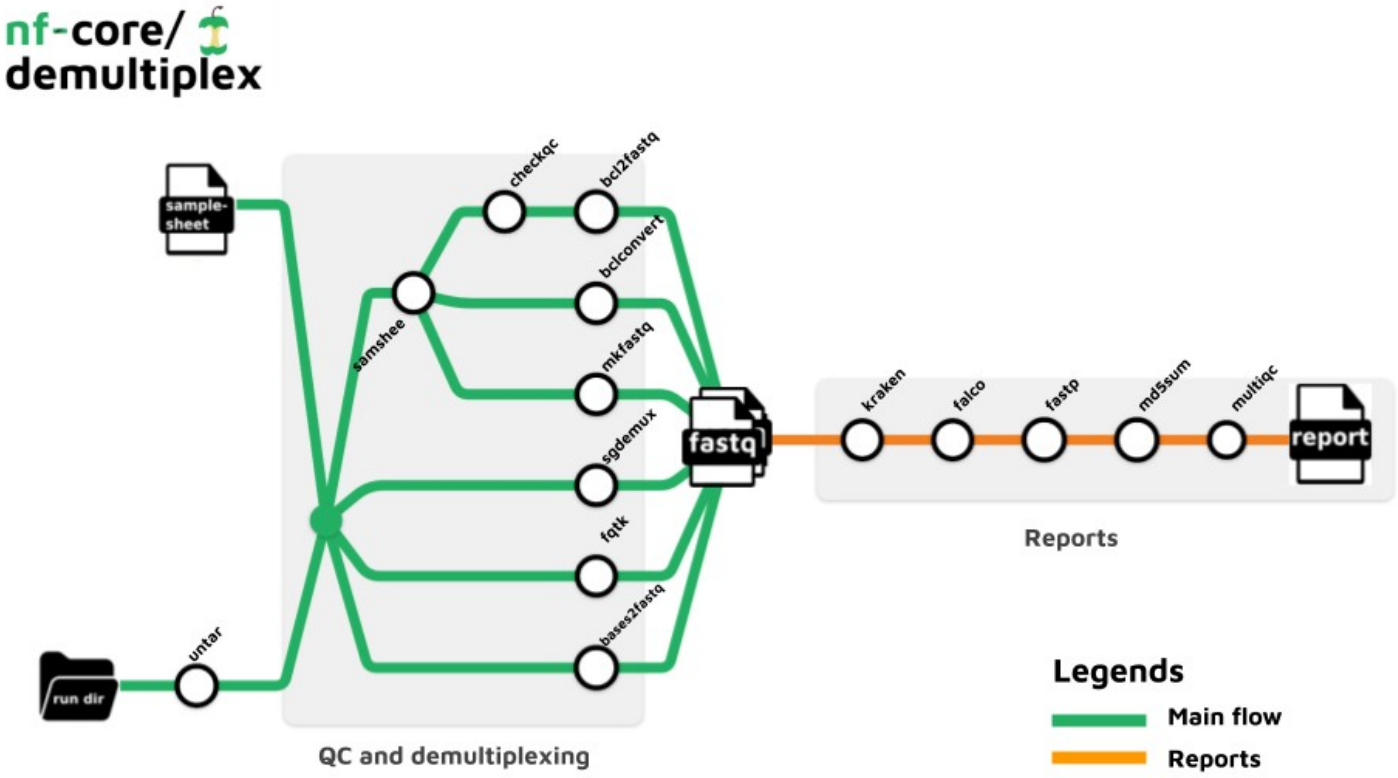

(A) Preprocesado de las lecturas

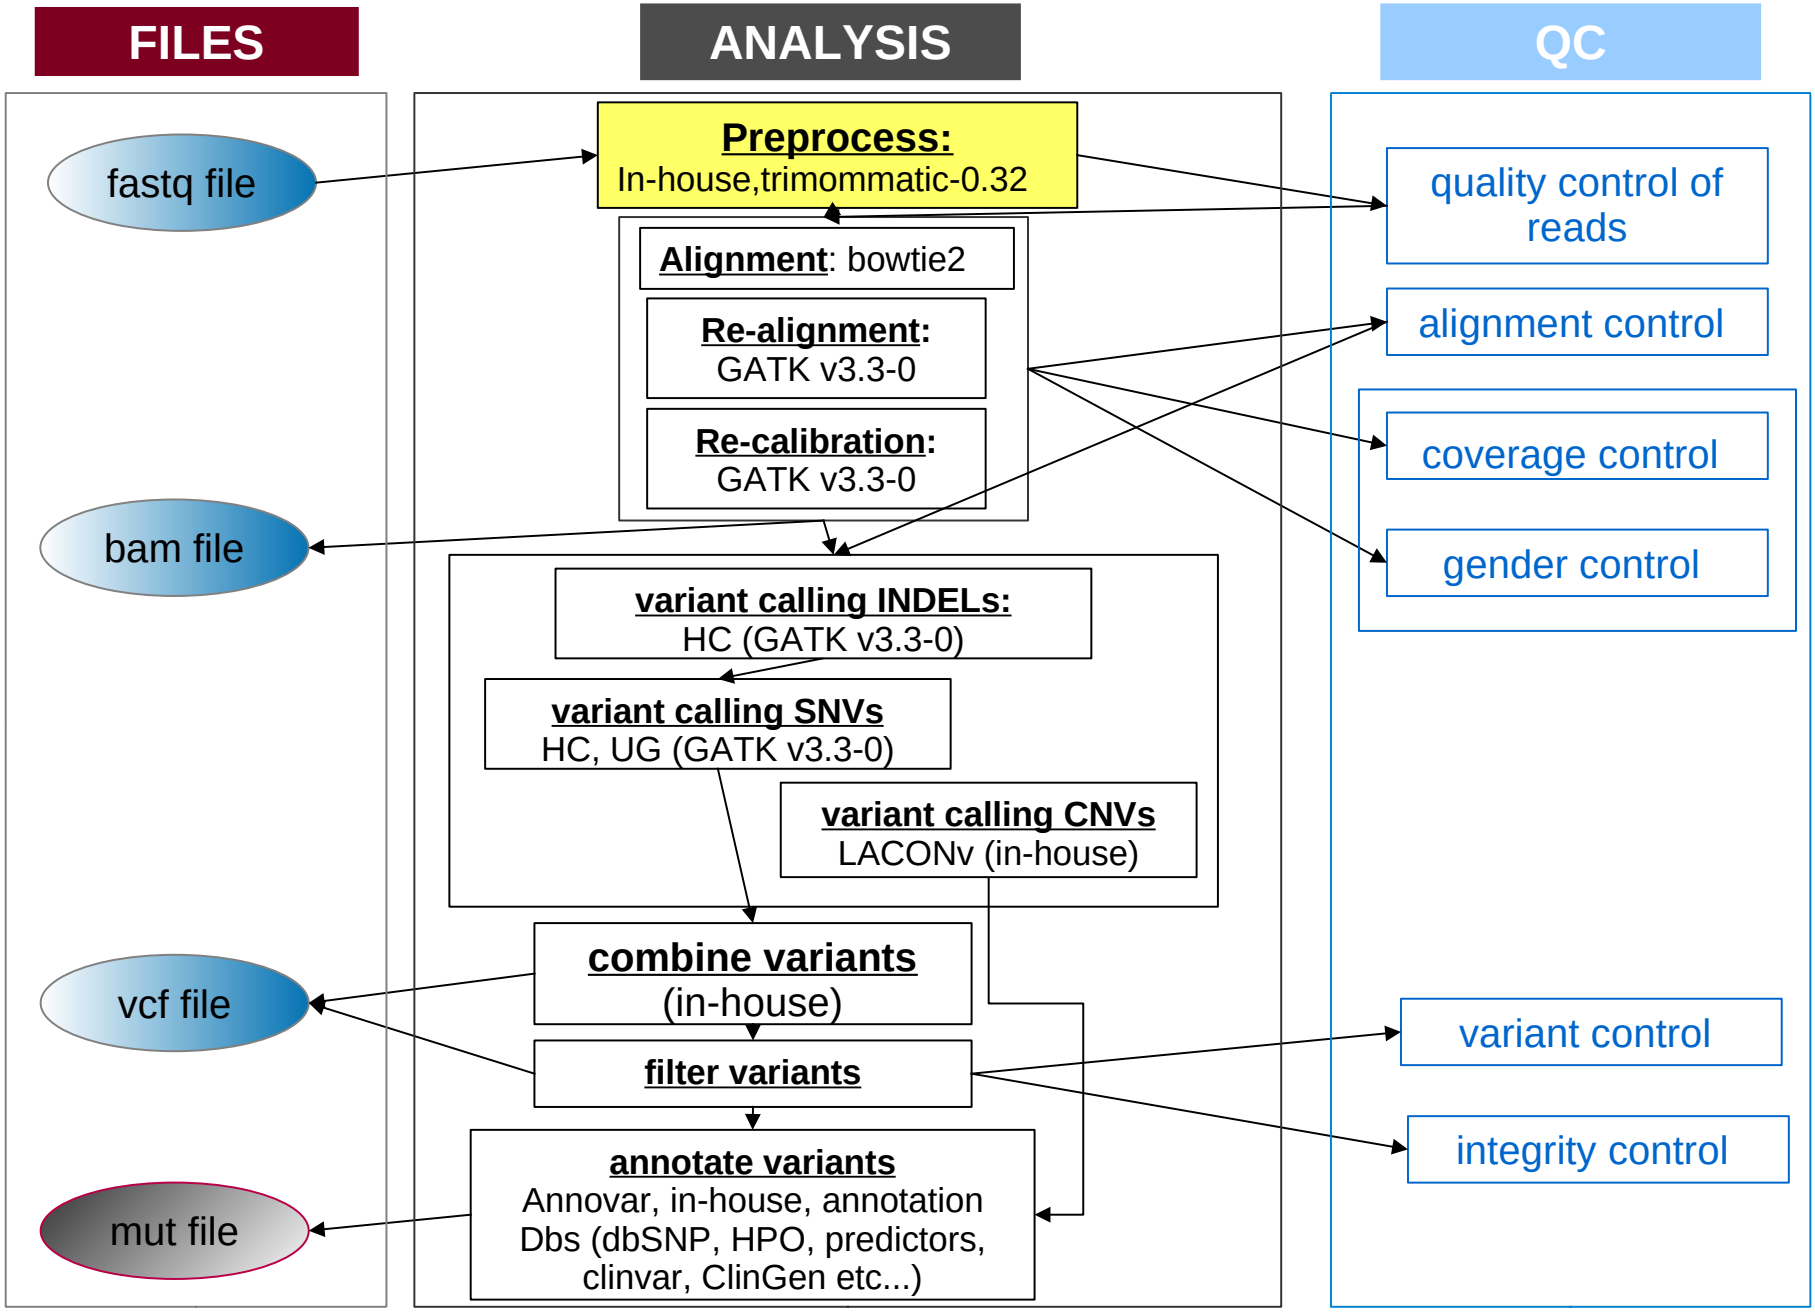

Filtrado y preprocesado

- Tras evaluar la calidad de los FASTQ, se deberá llevar a cabo:
  - La eliminación de los **adaptadores**.
  - El '***trimmeado***' de las lecturas.
  - El **filtrado** de lecturas que no supera un umbral de calidad.
- Existen diversos programas que proporcionan las herramientas para llevar a cabo el preprocesado de los FASTQ:
  - *Trimmomatic* (*http://www.usadellab.org/cms/?page=trimmomatic*)
  - *Cutadapt* (*https://github.com/marcelm/cutadapt/*)
  - BBTools (*https://archive.jgi.doe.gov/data-and-tools/software-tools/bbtools/bb-tools-user-guide/bbduk-guide/*)

Preprocesado

Hay que eliminar de las lecturas los adaptadores y los índices (*clipping*). Habitualmente se quita en el 'demultiplexado', pero pueden quedar fragmentos

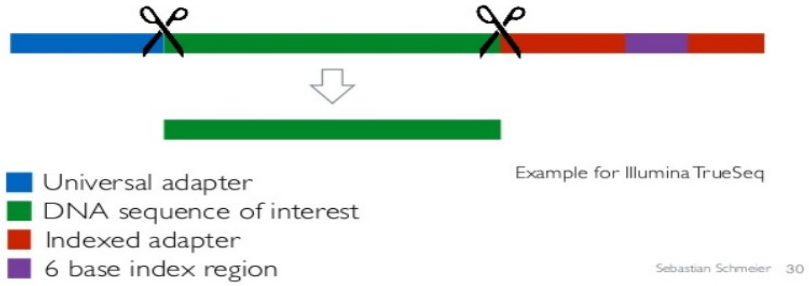

Además existen partes de las lecturas de ADN que deben ser filtradas:

→ debido a baja calidad

→ debido a la existencia de secuencias preferenciales

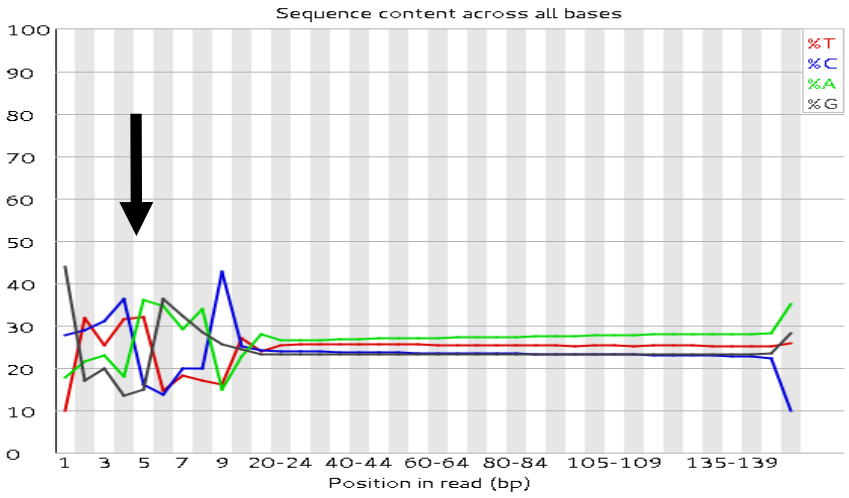

Phred score

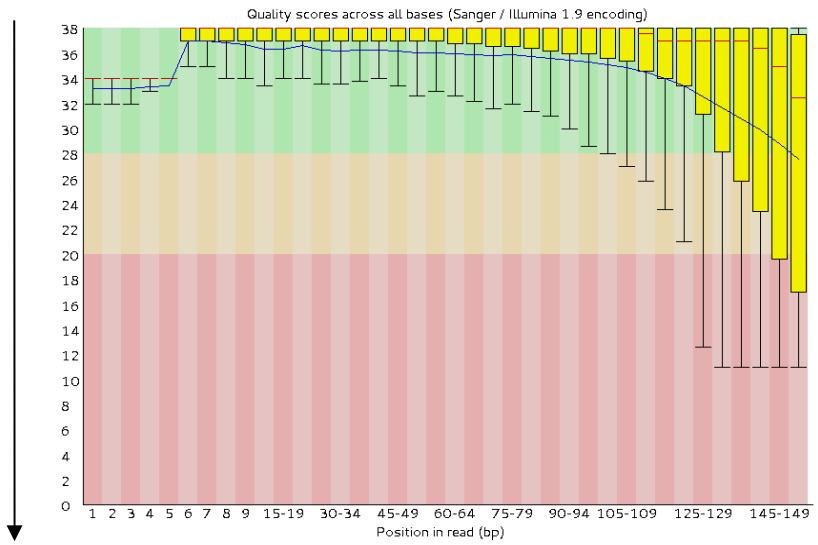

Preprocesado (II)

Trimmomatic: programa de uso generalizado para hacer el preprocesado o *'trimming'*

```
java -jar  trimmomatic.jar PE -threads 2 -phred33  \
reads_1.fastq.gz  reads_2.fastq.gz  \
reads_P_1.fastq.gz   reads_U_1.fastq.gz  \
reads_P_2.fastq.gz   reads_U_2.fastq.gz  \
ILLUMINACLIP:TruSeq3-PE.fa:2:30:10  SLIDINGWINDOW:4:5  LEADING:5 TRAILING:5 MINLEN:25
```

Hay un conjunto amplio de herramientas que ha desarrollado la comunidad bioinformática para filtrar las lecturas:

https://omictools.com/adapter-trimming-category

Preprocesado (III)

BBDUK: programa para la detección de bases de datos de adaptadores y contaminantes

- Elimina secuencias artefacturales además de adaptadores
- Por ejemplo, phiX

JGI WEB ARCHIVES

VISIT JGI.DOE.GOV Search this website SEARCH

Data & Tools

Home › Data & Tools › Software › BBTools › BBTools User Guide › BBDuk Guide

BBTools User Guide

- Usage Guide
- Installation Guide
- Data Preprocessing
- Add Adapters Guide
- BBDuk Guide
- BBMap Guide
- BBMask Guide
- BBMerge Guide
- BBNorm Guide
- CalcUniqueness Guide
- Clumpify Guide
- Dedupe Guide
- Reformat Guide
- Repair Guide
- Seal Guide
- Split Nextera Guide
- Statistics Guide
- Tadpole Guide
- Taxonomy Guide

BBTools FAQ and Support Forums

BBDuk Guide

"Duk" stands for Decontamination Using Kmers. BBDuk was developed to combine most common data-quality-related trimming, filtering, and masking operations into a single high-performance tool. It is capable of quality-trimming and filtering, adapter-trimming, contaminant-filtering via kmer matching, sequence masking, GC-filtering, length filtering, entropy-filtering, format conversion, histogram generation, subsampling, quality-score recalibration, kmer cardinality estimation, and various other operations in a single pass. Specifically, any combination of operations is possible in a single pass, with the exception of kmer-based operations (kmer trimming, kmer masking, or kmer filtering); at most 1 kmer-based operation can be done in a single pass. BBDuk2 allows multiple kmer-based operations in a single pass, and is otherwise equivalent to BBDuk.

BBDuk's parameters are described in its shellscript (bbduk.sh). This file provides usage examples of various common tasks.

Notes

Paired reads:

Paired reads interleaved in a single file will be autodetected based on their names; this can be overridden with the "interleaved" flag. The commands in this document assume either single-ended reads or paired reads in a single file. BBDuk also supports input or output of paired reads in dual files using the in1, in2, out1, and out2 flags, for example:

bbduk.sh in1=read1.fq in2=read2.fq out1=clean1.fq out2=clean2.fq

When dealing with paired reads in 2 files they should always be processed together, not one at a time. Pairs are always kept together – either both reads are kept, or both are discarded.

Proceso de análisis
Best Practices GATK

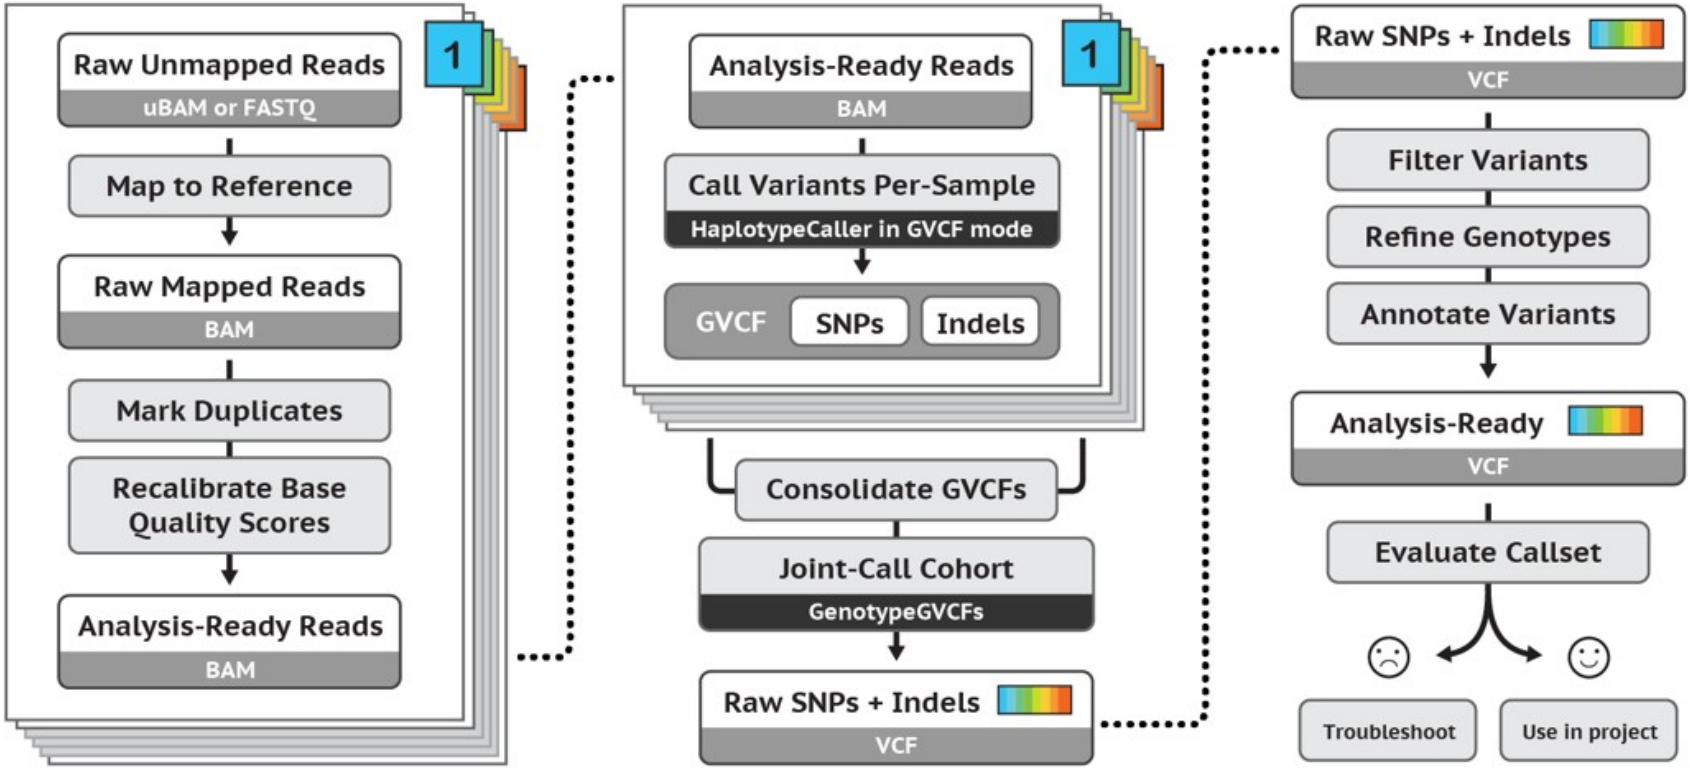

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

(B) Alineamiento de las lecturas

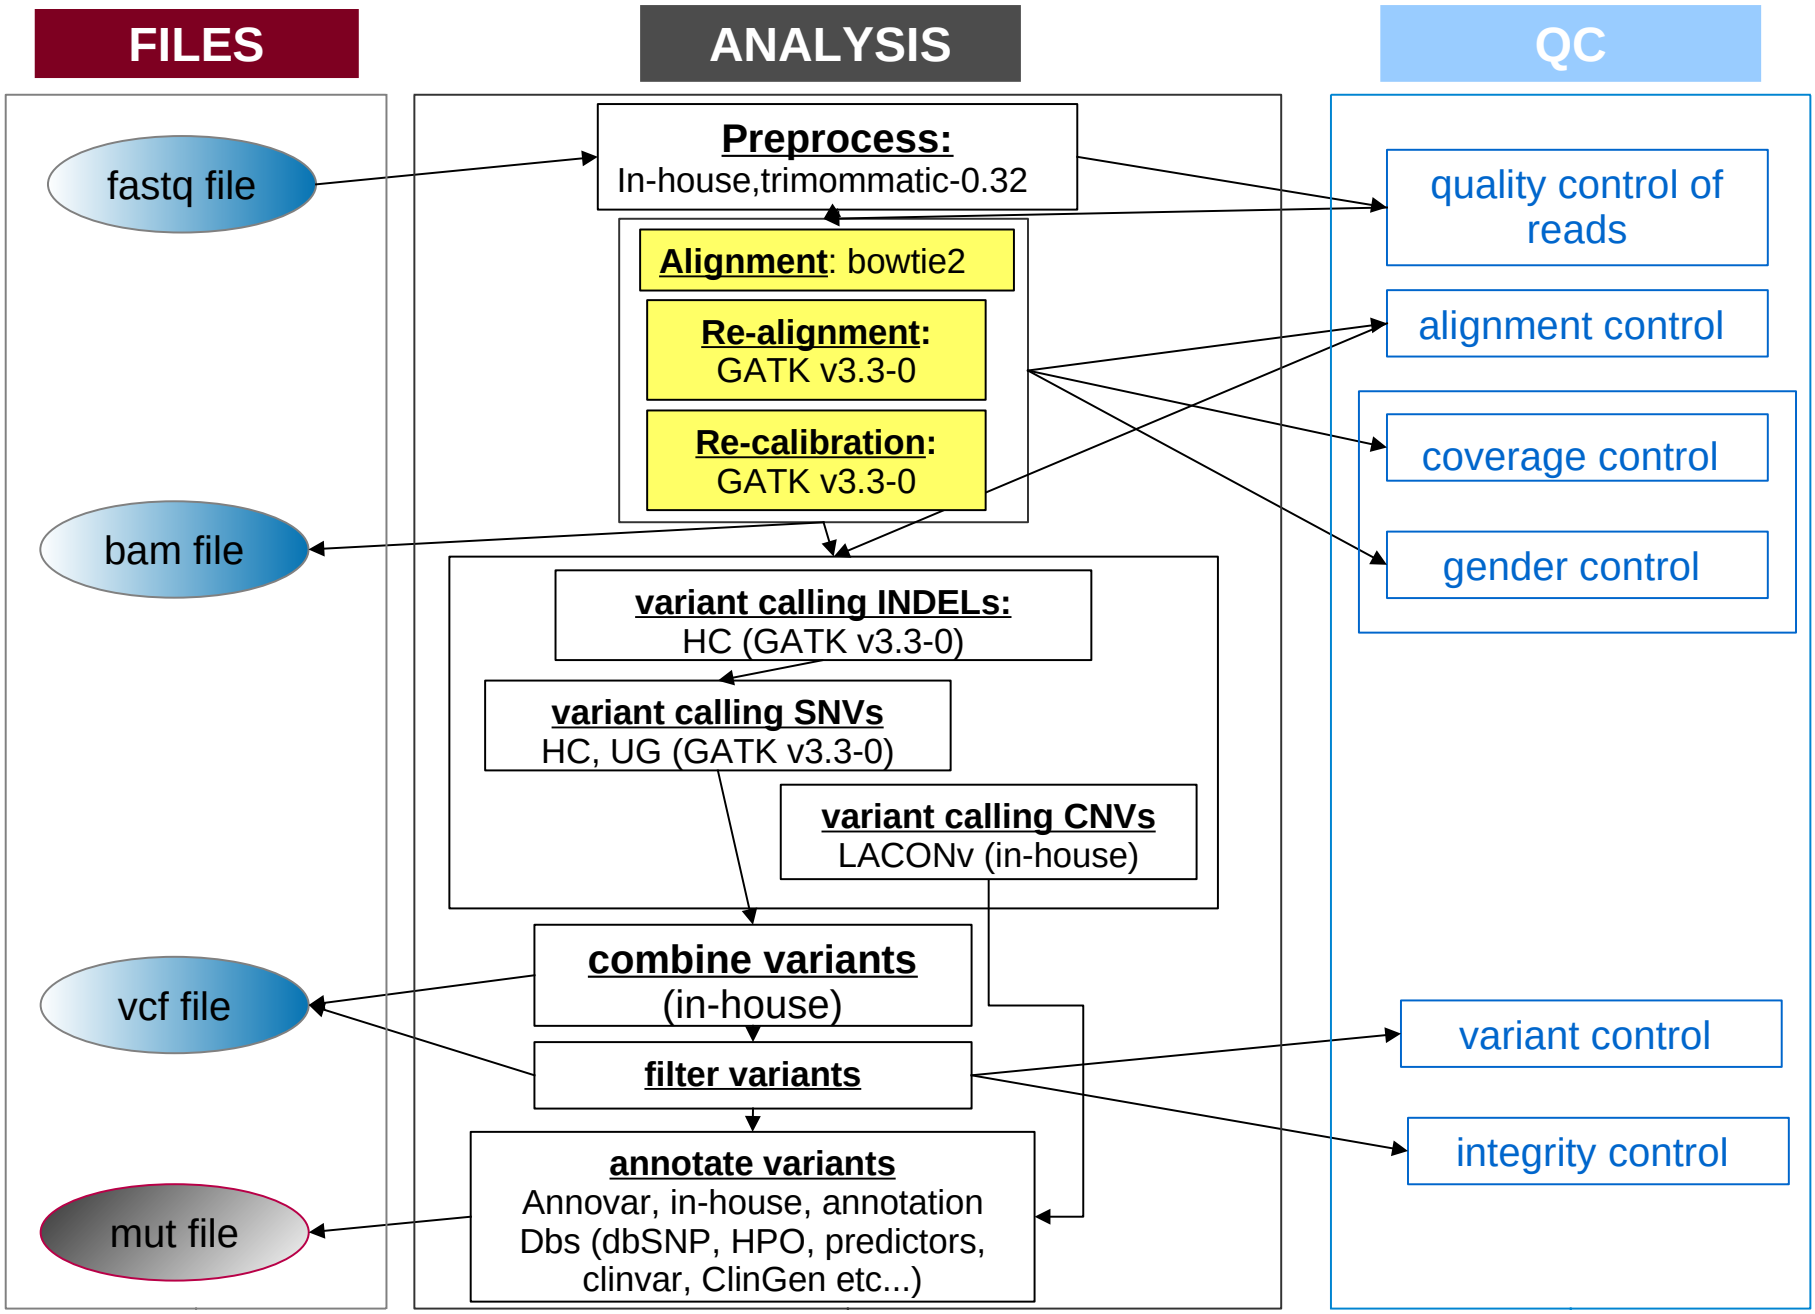

Alineamiento

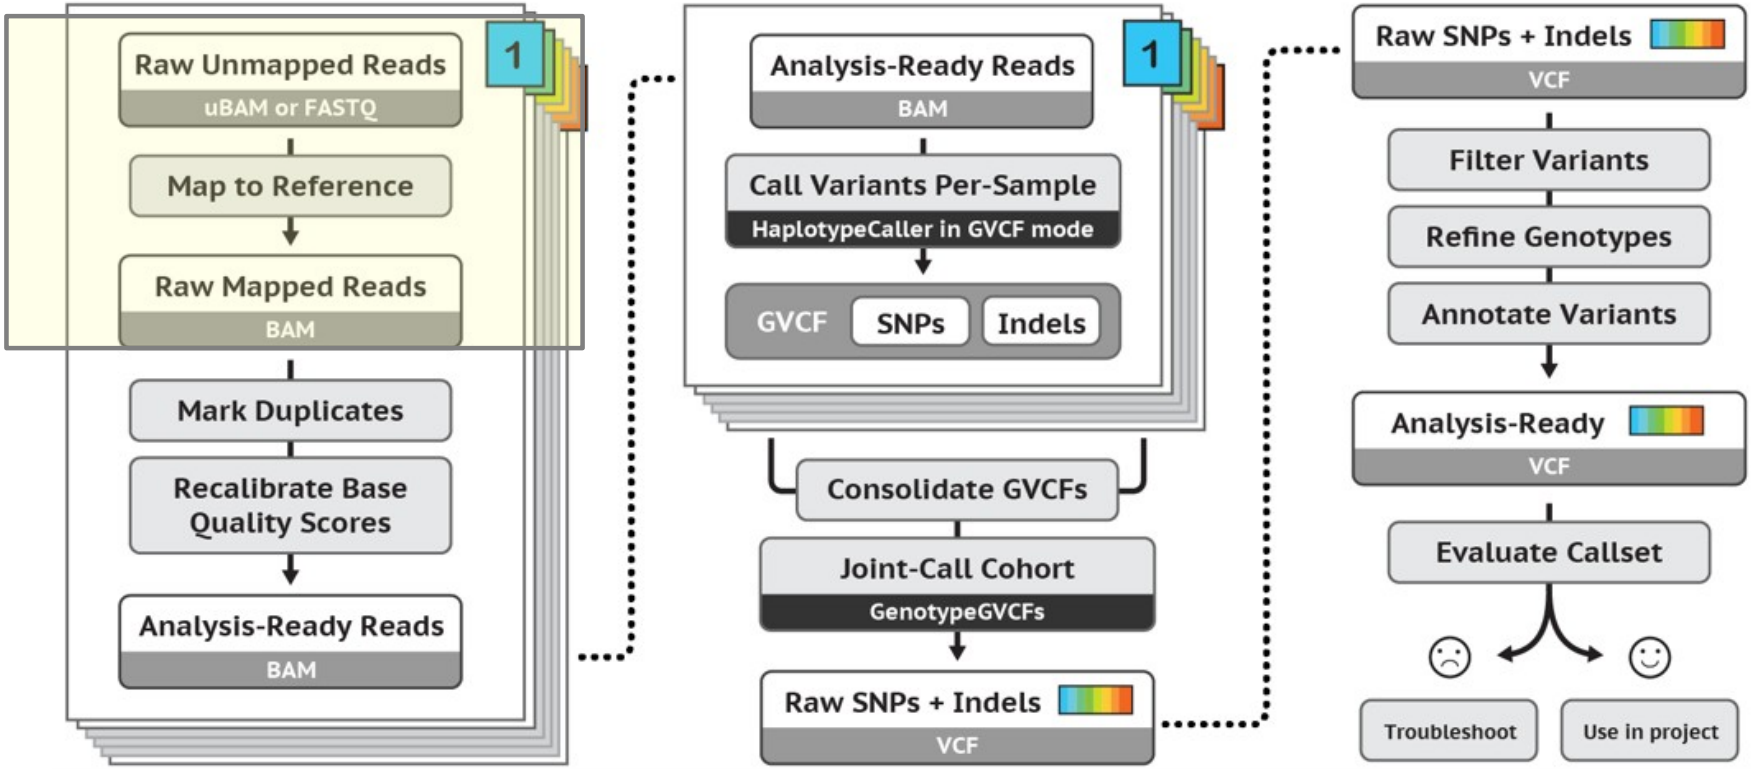

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

Alineamiento

Existen numerosas herramientas de alineamiento (i.e. *mapeo*) de secuencias de ADN (también ARN) basadas en principios diferentes.

Los programas más conocidos (**BWA** y **Bowtie)** usan un método que se denomina 'suffix-prefix tree' que consiste en identificar primero los encajes (i.e. *matches*) exactos de secuencias para luego construir a partir de éstos los encajes inexactos.

Otros programas está basados en otra metodología que se llama 'hash table'. También hay métodos híbridos.

Otros ejemplos de programas que se usan habitualmente son:

DRAGMAP, Minimap2, bwa2, etc...

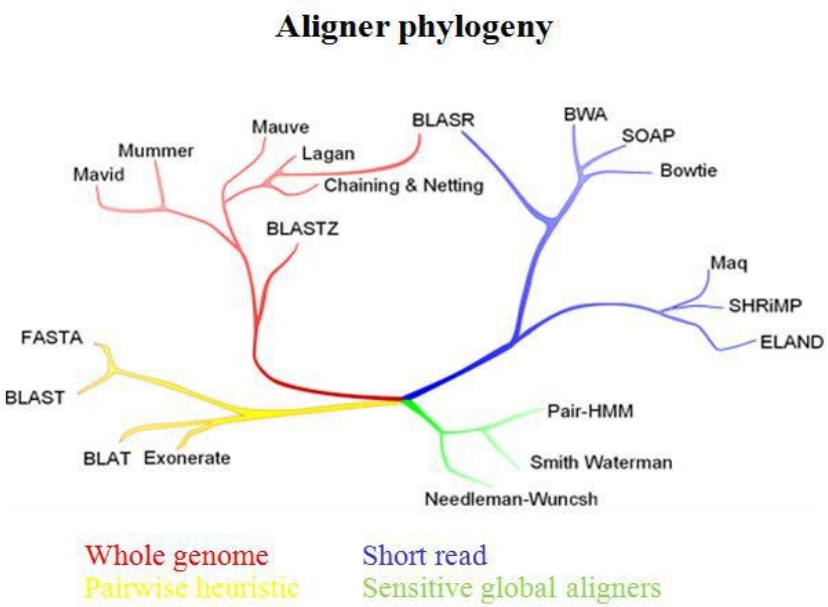

Forma en la que se relacionan las distintas herramientas en función del método en el que se basan

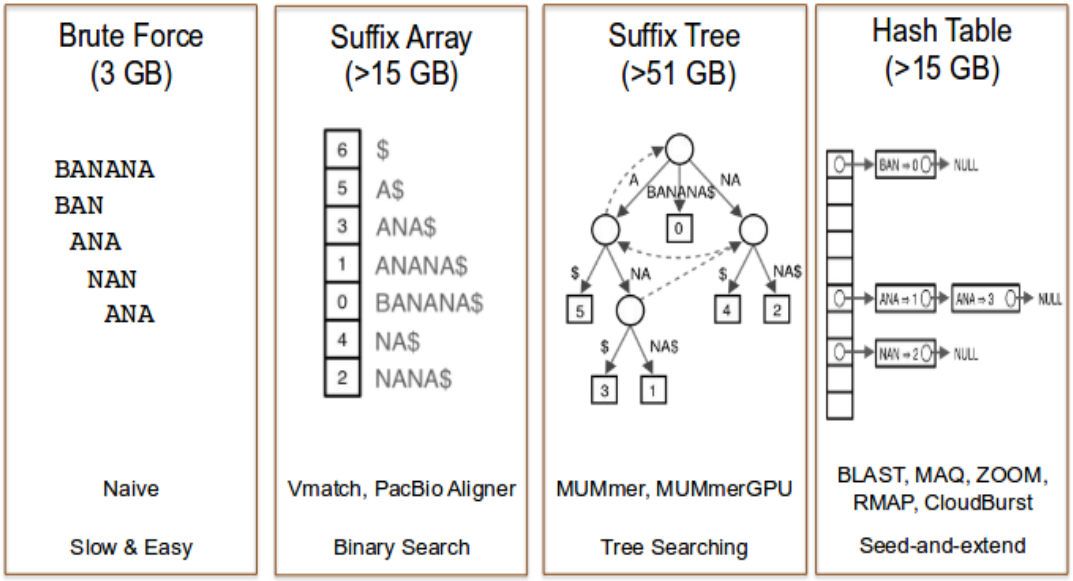

Michael Schatz - CSH

Alineamiento: fichero bam (y sam)

Los programas de alineamiento generan un fichero de extensión sam

Un fichero sam es muy ineficiente porque es 'editable' y ocupa mucho espacio

Habitualmente, se transforma el fichero sam en bam mediante uno de estos programa:

Using samtools

```
samtools view -Sb sample1.sam > sample1.bam
samtool sort sample1.bam -o sample1.sorted.bam
samtools index sample1.sorted.bam
```

Using PICARD

```
java -jar SortSam.jar INPUT=sampl1.sam \
OUTPUT=sample1.sorted.bamSORT_ORDER=coordinate

java -jar BuildBamIndex.jar INPUT=
```

El formato del fichero bam es igual que sam pero está codificado en binario y comprimido

Para ver la estructura del fichero bam, recomendamos revisar:
http://samtools.github.io/hts-specs/SAMv1.pdf

Aún así, el formato bam es ineficiente y ocupa mucho espacio en disco. Existen alternativas con formatos más compactos que permitan almacenar la información en menos espacio: CRAM

Post-procesado del alineamiento

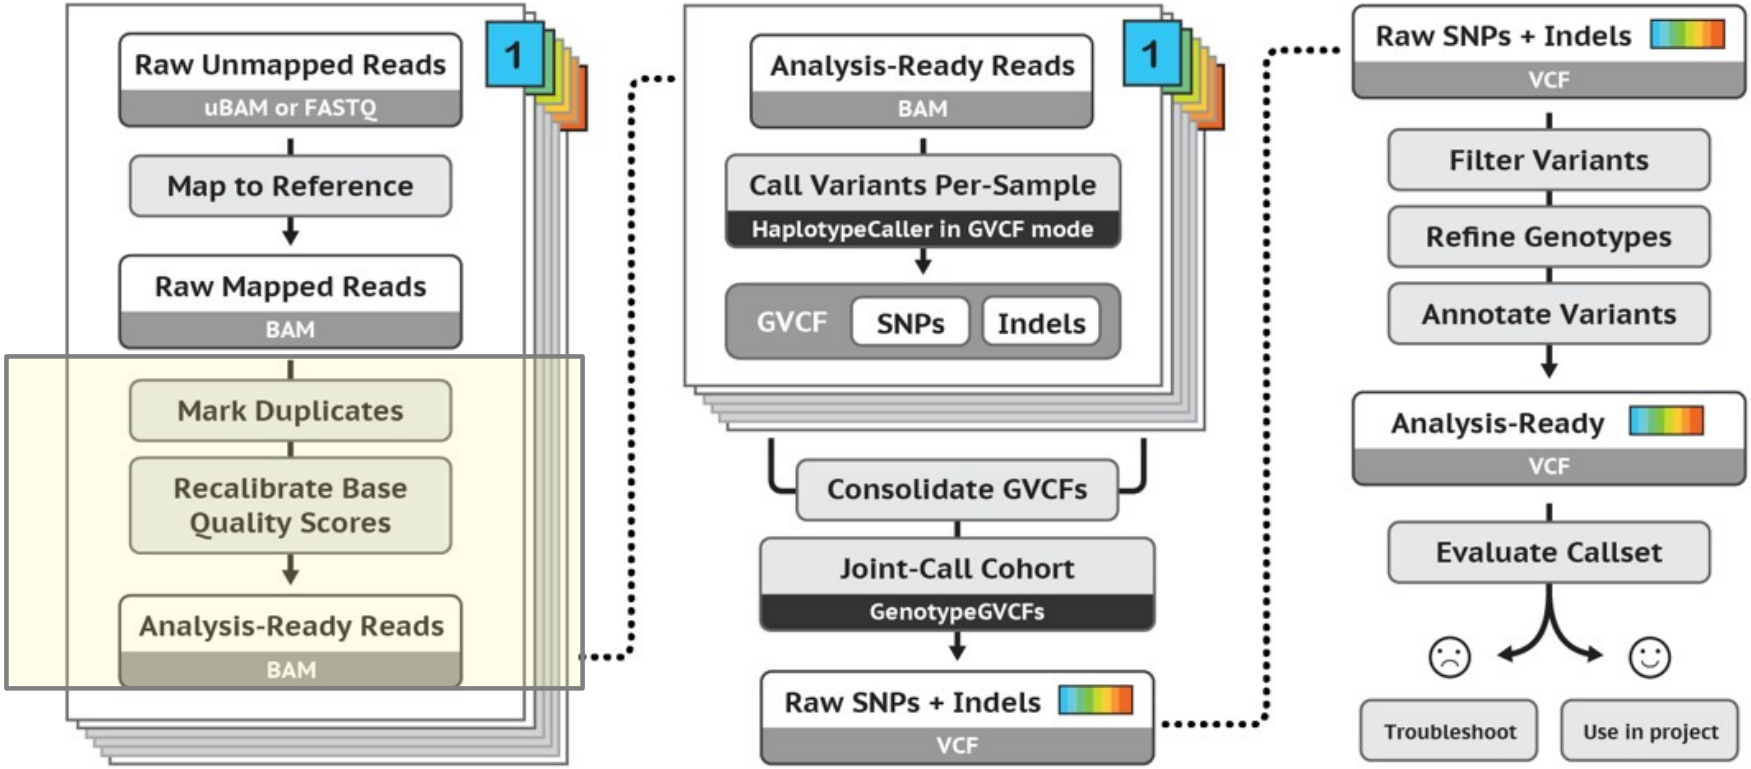

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

Filtrado de duplicados

Ocurren fundamentalmente en plataformas Illumina y se producen o bien cuando dos clusters solapan ('duplicados ópticos') o porque en la preamplificación de la librería, se han generado duplicados por PCR ('duplicados de librería').

Es recomendable eliminar los duplicados para mejorar el proceso de detección de variantes, puesto que genera falsas variantes o falsos negativos.

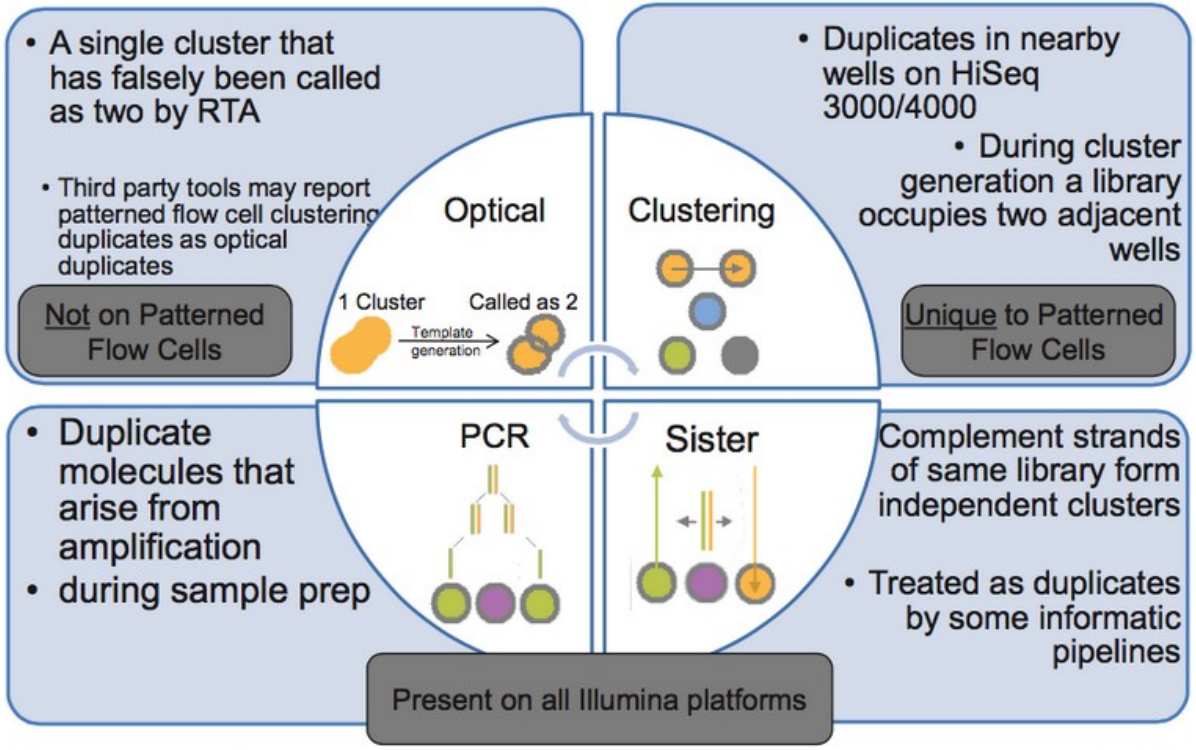

Filtrado de duplicados (II)

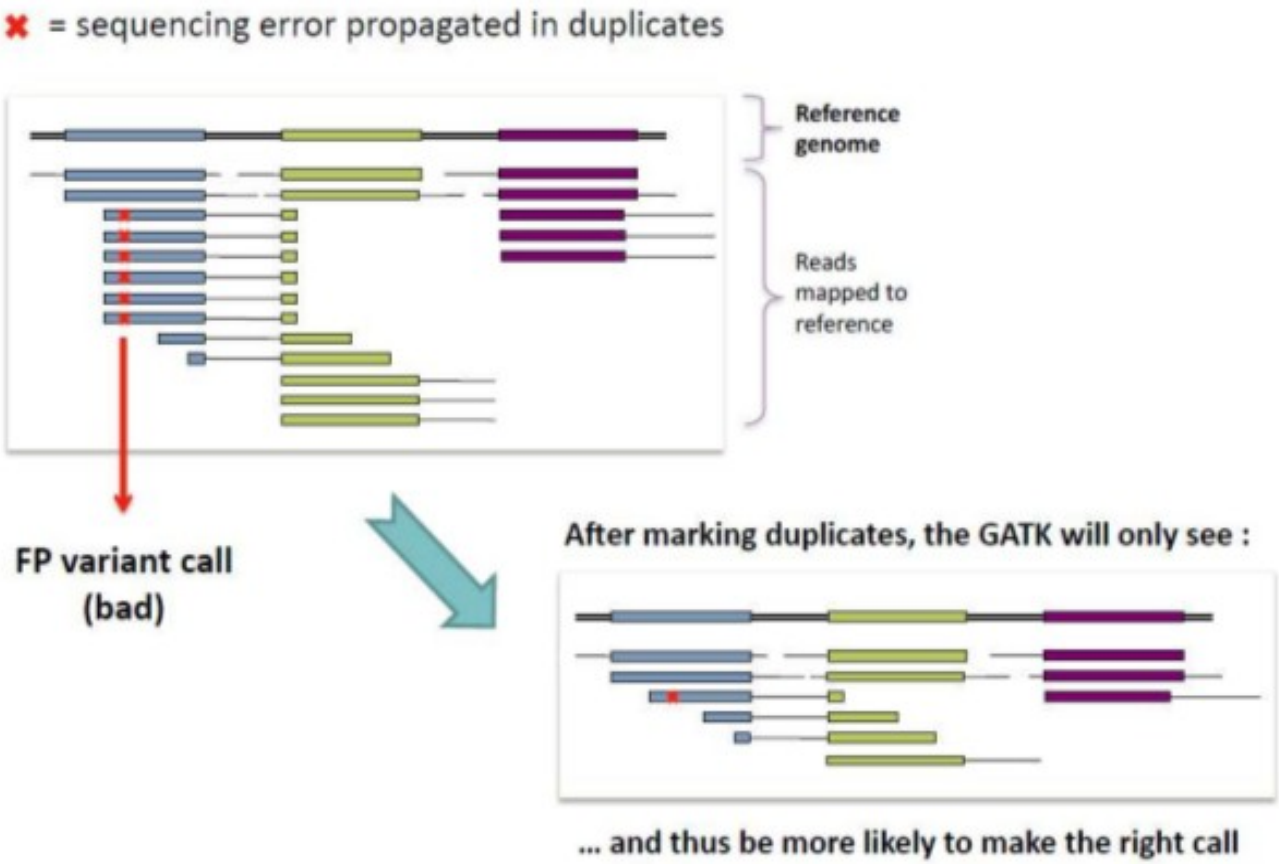

Picard MarkDuplicates
http://broadinstitute.github.io/picard/

samtools markdup
http://samtools.sourceforge.net

Realineamiento y recalibrado

Realineamiento: consiste en 'revisar' localmente las secuencias alineadas y reajustar dichos alineamientos para que el **haplotipo local** sea concordante

Es muy costoso computacionalmente

No es necesario cuando la detección de variantes revisa el haplotipo local de forma implícita (p. ej. HaplotypeCaller o FreeBayes)

En el caso de realinear las lecturas, hay que recalcular posteriormente la calidad de los nucleótidos (recalibrado)

Habitualmente, en regiones con indels en los extremos de las lecturas:

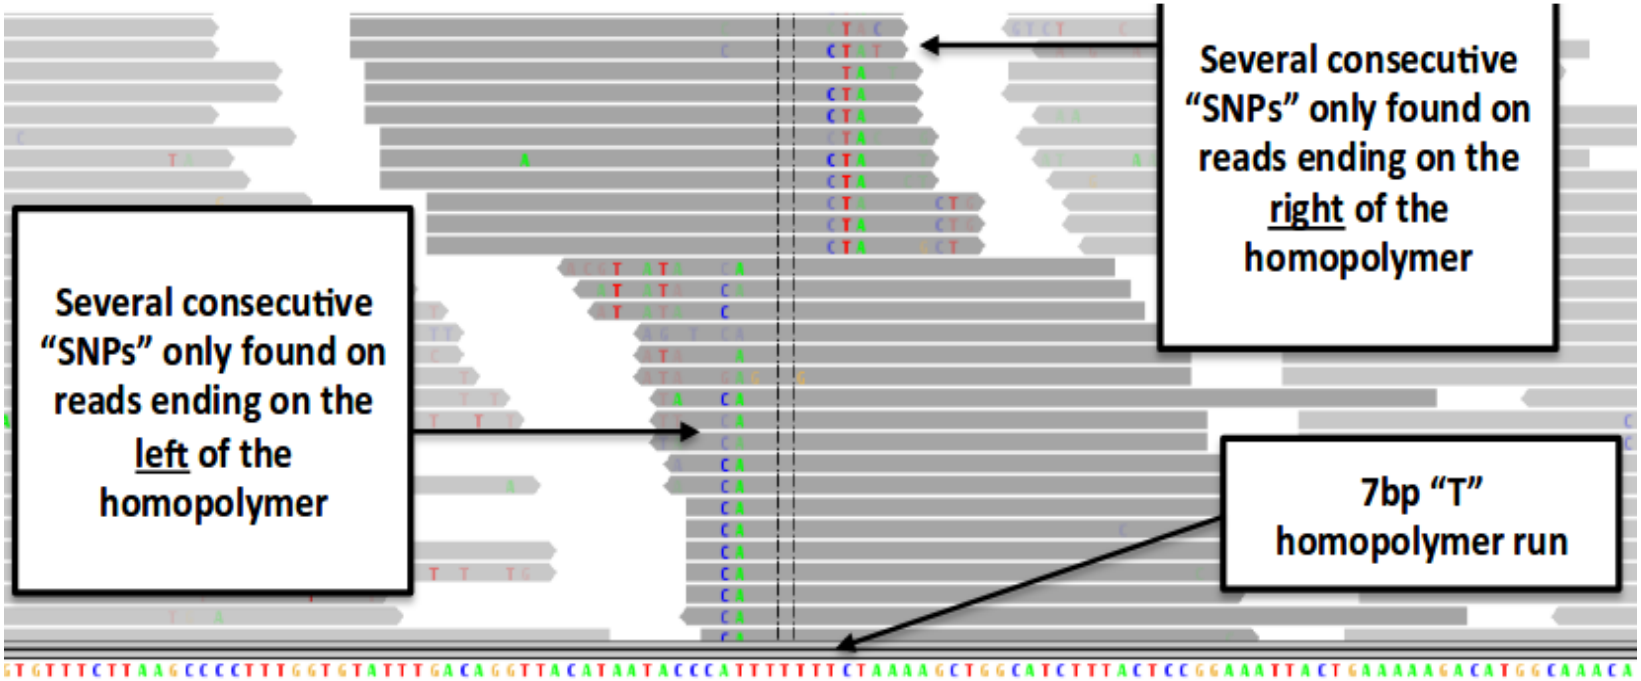

https://gatkforums.broadinstitute.org/gatk/discussion/7156/howto-perform-local-realignment-around-indels

Realineamiento y recalibrado

Después del realineamiento:

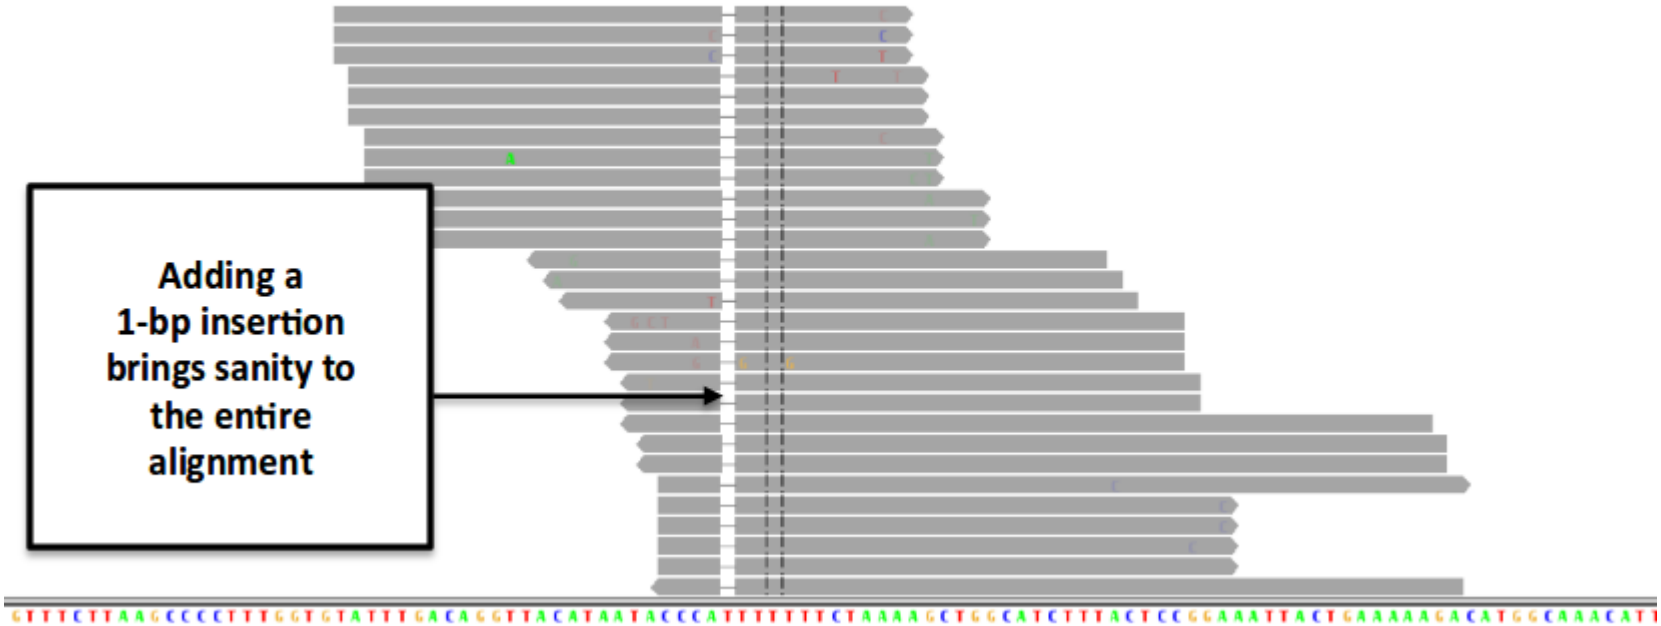

Modelo de INDELS conocidos (p.ej. 1000 Genomas)

Análisis de linkage con score LOD

Ambigüedad en los INDELS

Cada programa de alineamiento tiene su particularidad (pros/contras)

```
AAGCTAGACTAGGAAGCT
AAGCTA--CTAG----CT
     (2 gap opens, 0 mismatch)

AAGCTAGACTAGGAAGCT
AAGCTA------CTAGCT
    (1 gap open, 2 mismatches)
```

Las pequeñas deleciones / inserciones son difíciles de modelizar. Hace falta programas especializados y revisión en profundidad de cada **solución conjunta de alineamiento + variant calling**

Cada solución de análisis se debe calibrar contra un gold standard o muestra de referencia (NA12878):
http://jimb.stanford.edu/giab/
https://www.nature.com/articles/sdata201625

Dream challenge para mutationes somáticas:
http://dreamchallenges.org/project/icgc-tcga-dream-somatic-mutation-calling-challenge/

VariantCalling

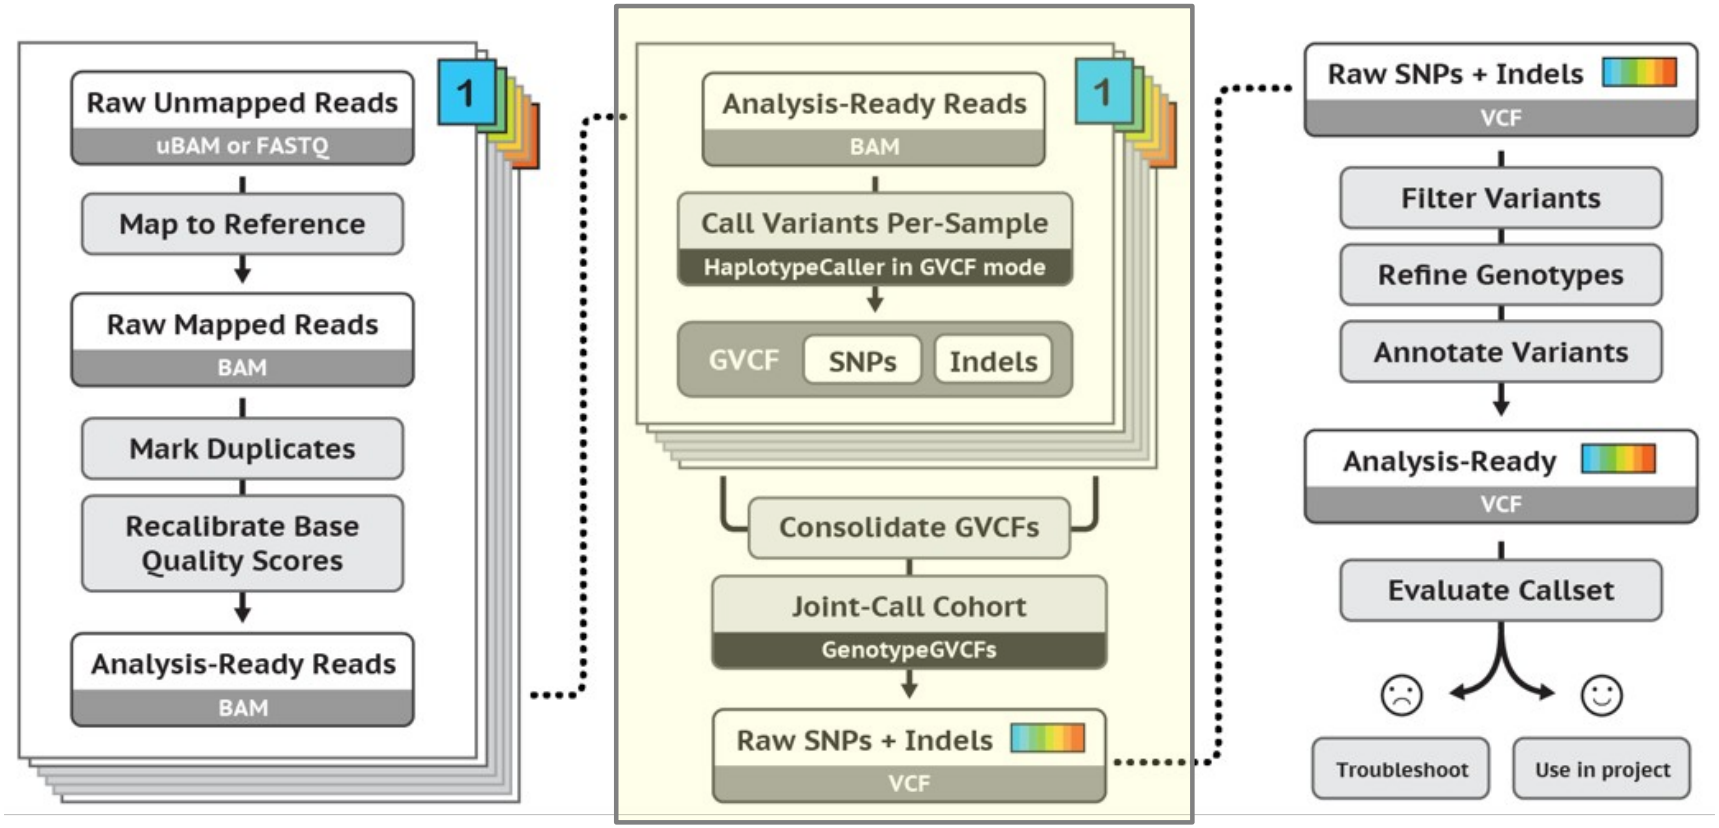

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

Variant Calling

- El objetivo es determinar lo que estadísticamente es diferente respecto a un genoma de referencia

- Los programas de detección de variantes (i.e. *variant calling*), están diseñados fundamentalmente para determinar SNVs e INDELs.

- Existen dos aproximaciones:

  → 'naïve': se cuentan las lecturas con un alelo alternativo y las lecturas del alelo de referencia. Se emite la variante si supera un umbral. Son aproximaciones antiguas

  → basados en el haplotipo: explora las diferentes posibilidades basados en la concordancia de los cambios de alrededor. Revisa si concuerda con haplotipos conocidos y emite una probabilidad asociada a los tres genotipos más comunes:

HOM_REF	**0/0**
HET	**0/1**
HOM_ALT	**1/1**

- Las variantes SNVs e INDELS de una o más muestras se describen en un fichero vcf con un formato bien definido

Formato vcf

Es un formato 'editable'. El formato está descrito en: https://samtools.github.io/hts-specs/VCFv4.2.pdf

Se compone de:

→ Una cabecera (líneas con '#') donde se definen los filtros y las variables que se van a utilizar

→ Un cuerpo donde se describen las variantes

```
##fileformat=VCFv4.2
##fileDate=20090805
##source=myImputationProgramV3.1
##reference=file:///seq/references/1000GenomesPilot-NCBI36.fasta
##contig=<ID=20,length=62435964,assembly=B36,md5=f126cdf8a6e0c7f379d618ff66beb2da,species="Homo sapiens",taxonomy=x>
##phasing=partial
##INFO=<ID=NS,Number=1,Type=Integer,Description="Number of Samples With Data">
##INFO=<ID=DP,Number=1,Type=Integer,Description="Total Depth">
##INFO=<ID=AF,Number=A,Type=Float,Description="Allele Frequency">
##INFO=<ID=AA,Number=1,Type=String,Description="Ancestral Allele">
##INFO=<ID=DB,Number=0,Type=Flag,Description="dbSNP membership, build 129">
##INFO=<ID=H2,Number=0,Type=Flag,Description="HapMap2 membership">
##FILTER=<ID=q10,Description="Quality below 10">
##FILTER=<ID=s50,Description="Less than 50% of samples have data">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read Depth">
##FORMAT=<ID=HQ,Number=2,Type=Integer,Description="Haplotype Quality">
#CHROM POS     ID        REF    ALT     QUAL FILTER INFO                              FORMAT      NA00001        NA00002        NA00003
20    14370   rs6054257 G      A       29   PASS   NS=3;DP=14;AF=0.5;DB;H2           GT:GQ:DP:HQ 0|0:48:1:51,51 1|0:48:8:51,51 1/1:43:5:.,.
20    17330   .         T      A       3    q10    NS=3;DP=11;AF=0.017               GT:GQ:DP:HQ 0|0:49:3:58,50 0|1:3:5:65,3   0/0:41:3
20    1110696 rs6040355 A      G,T     67   PASS   NS=2;DP=10;AF=0.333,0.667;AA=T;DB GT:GQ:DP:HQ 1|2:21:6:23,27 2|1:2:0:18,2   2/2:35:4
20    1230237 .         T      .       47   PASS   NS=3;DP=13;AA=T                   GT:GQ:DP:HQ 0|0:54:7:56,60 0|0:48:4:51,51 0/0:61:2
20    1234567 microsat1 GTC    G,GTCT  50   PASS   NS=3;DP=9;AA=G                    GT:GQ:DP    0/1:35:4       0/2:17:2       1/1:40:3
```

pos. genomica

alelos

Campo INFO: 'anotaciones'

Campo FORMAT: genotipos

Formato vcf (II)

Ejemplo de cuerpo: Aparecen los campos INFO, FORMAT, FILTER así como la variante

```
#CHROM    POS  ID    REF  ALT  QUAL FILTER    INFO FORMAT    Father_42166
chr1 69270     .     A    G    1138.92   PASS ST=transmitted;DS=V-FatherVS-MotherVS-ProbandVS   GT:GQ:AD:DP:AF 0/1:2382:1291,325:1616:0.2
chr1 69897     .     T    C    504.4     PASS ST=transmitted;DS=V-FatherVS-MotherVS-ProbandVS   GT:GQ:AD:DP:AF 0/1:1375:543,180:723:0.2
chr1 877831    rs6672356 T    C    1514.91   PASS ST=transmitted;DS=G-FatherGATK-MotherGATK-ProbandGATK  GT:GQ:AD:DP:AF 1/1:27:0,9:9:1.0
chr1 878314    rs142558220    G    C    1784.245  PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 0/1:515:52,59:111:0.5
chr1 878761    .     A    C    21.69     GTNoConst;LQ   ST=untransmitted;DS=V-FatherNoConsist-MotherNoConsist-ProbandNoConsist     GT:GQ:AD:DP:AF 0/1:55:12,7:19:0.4
chr1 879058    .     T    G    37.07     GTNoConst;LQ   ST=untransmitted;DS=V-FatherNoConsist-MotherNoConsist-ProbandNoConsist     GT:GQ:AD:DP:AF 0/0:74:36,10:46:0.2
chr1 879058    .     T    A    37.07     GTNoConst;LQ   ST=untransmitted;DS=V-FatherNoConsist-MotherNoConsist-ProbandNoConsist     GT:GQ:AD:DP:AF 0/1:74:36,10:46:0.2
chr1 881627    rs2272757 G    A    3697.26   PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 0/1:312:42,37:79:0.5
chr1 883625    rs4970378 A    G    5890.935  PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 1/1:1385:0,102:102:1.0
chr1 887801    rs3828047 A    G    1555.875  PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 1/1:587:1,46:47:1.0
chr1 888639    rs3748596 T    C    10906.215 PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 1/1:2781:0,203:203:1.0
chr1 888659    rs3748597 T    C    10272.02  PASS ST=transmitted;DS=A-Agreement GT:GQ:AD:DP:AF 1/1:2671:0,195:195:1.0
```

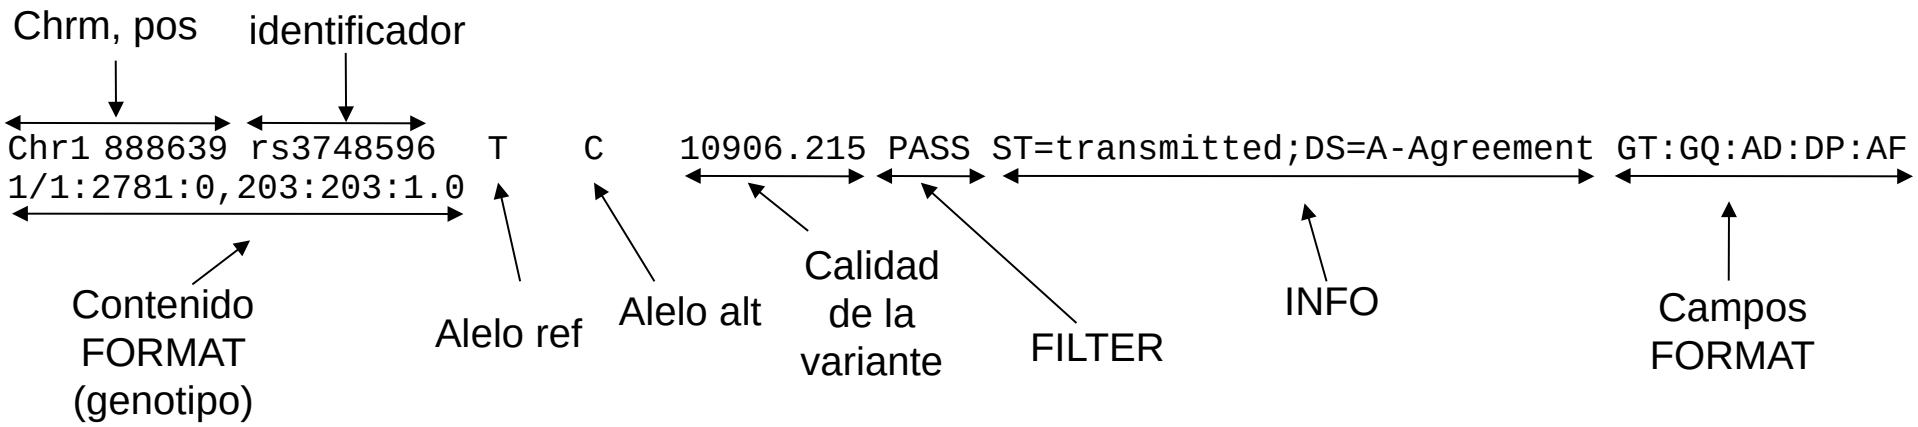

Ref,alt: alelos de referencia y alternativos (en hebra '+')
Identificador: ID de la variante si es conocido (p.ej dbSNP)
Calidad de la variante ('QUAL'): $-10*\log_{10}P$ donde P es la probabilidad de que la variante esté presente dados los datos
FILTER: Si la variante pasa el filtro está a 'PASS' en caso contrario, hay un filtro que tiene que estar definido en la cabecera

Formato vcf (III)

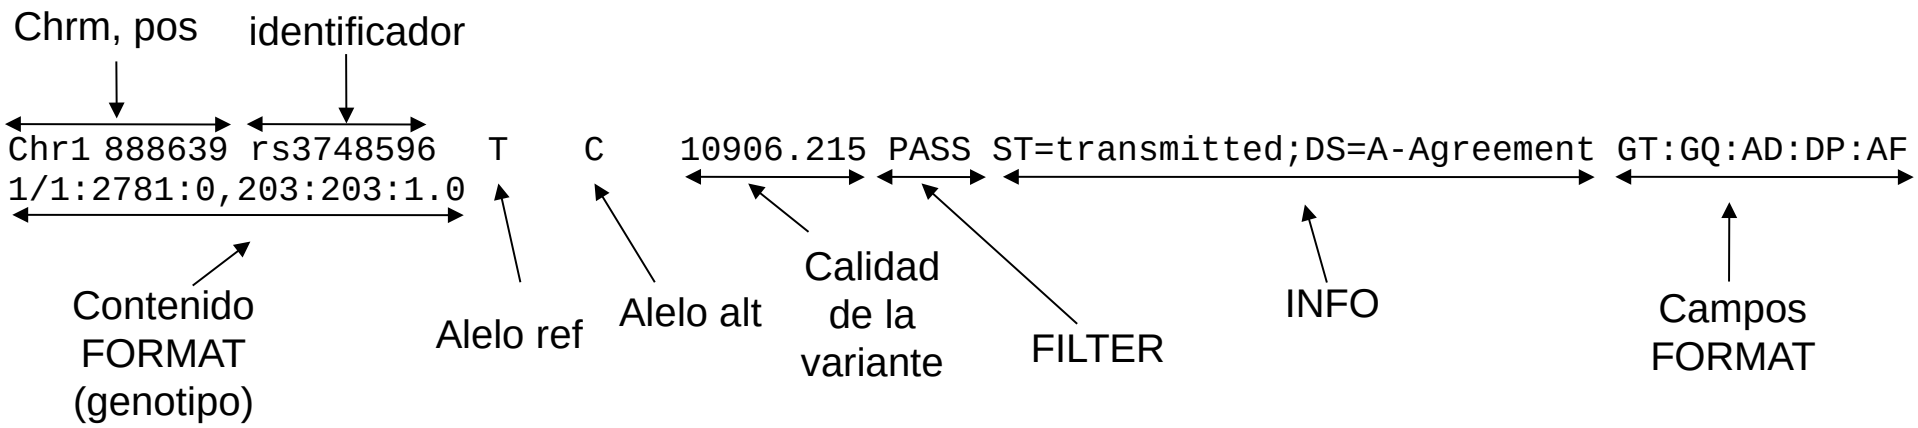

INFO: Es una columna que contiene datos adicionales de las variantes ('anotaciones')
FORMAT: Describe los campos que se van a incluir para detallar la información del genotipo

GT: Genotipo (0/0, 0/1, 1/1, 1/2 etc..)

GQ: Calidad del Genotipo. La forma de asignar esta calidad depende de la herramienta. Indica cómo de exacto es la determinación de ese genotipo (no de que la variante exista o no)

AD: Profundidad de lecturas de cada alelo que ha usado la herramienta para emitir la variante

DP: Profundidad de lecturas total del sitio (puede ser mayor que la suma de AD)

PL: *Verosimilitud de cada genotipo*

Herramientas de variant calling

Existen múltiples herramientas. Es importante tener claro de antemano qué problema se quiere resolver. Las herramientas y estrategias de análisis se pueden dividir en:

- Muestras individuales con variantes en línea germinal
  GATK HaplotypeCaller, DeepVariant, FreeBayes, VarScan, SAMtools, Platypus, VarDict
- Muestras individuales con sospecha de variante/s en mosaico
  DeepSomatic, Manta, Mutect ...
- Muestras con relación familiar (Padre/Madre/Probando) y sospecha de variante de novo
  DeepTrio, VarScan, GATK, Triodenovo
- Muestras pareadas de tejido afecto/tejido control
  MuTect, VarDict, FreeBayes, VarScan

http://bcb.io → Blog muy intersante dónde se establecen comparativas y buenas prácticas

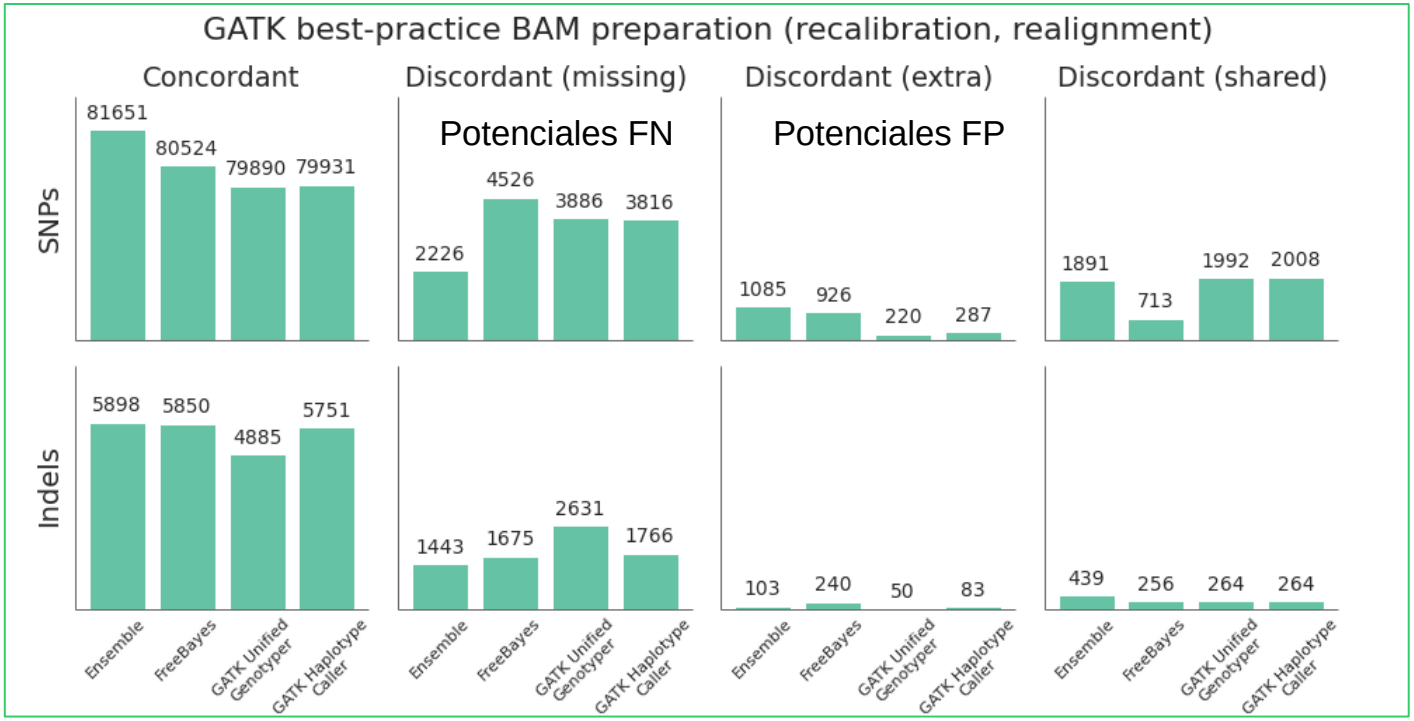

VariantCalling

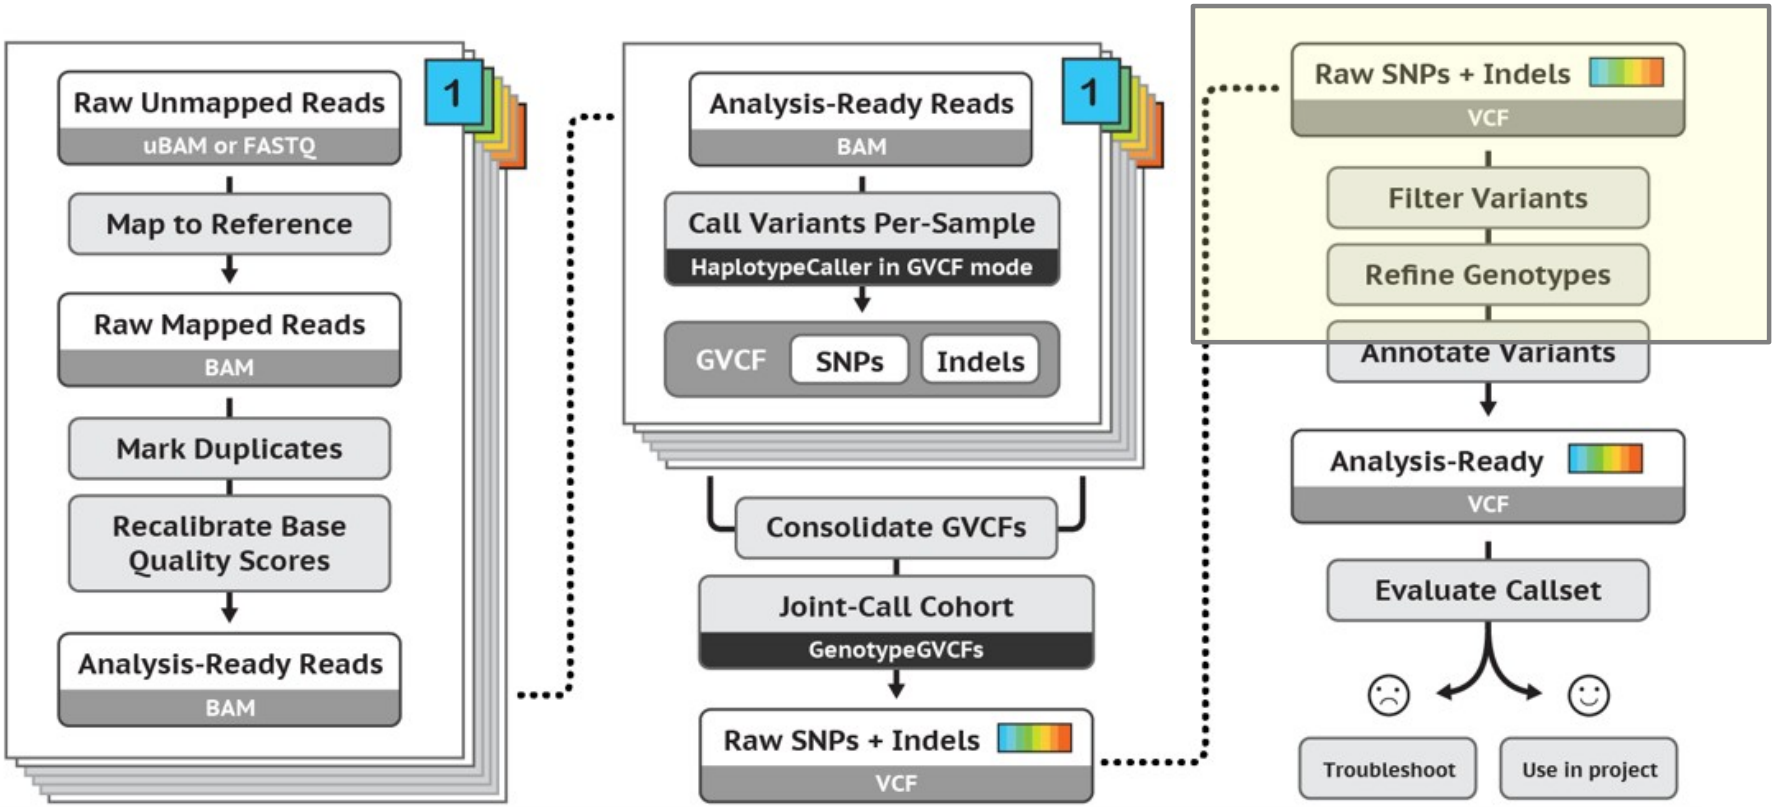

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

Normalización de variantes y filtrado

Ejemplo de una variante en diferentes formatos (*):

```
Variant:   Reference Sequence    GGGCACACACAGGG
           Alternate Sequence    GGGCACACAGGG

                 Genome Reference     |  Variant Call Format
                                      |
                 GGGCACACACAGGG       |  POS  REF     ALT
(A)  REF              CAC             |  6    CAC     C
     ALT              C               |
(B)  REF            GCACA             |  3    GCACA   GCA
     ALT            GCA               |
(C)  REF           GGCA               |  2    GGCA    GG
     ALT           GG                 |
(D)  REF            GCA               |  3    GCA     G
     ALT            G                 |
```

Las variantes hay que representarlas en su mínimo formato, es decir, está representada en los menos nucleótidos posibles y sin que haya un alelo de longitud 0 y además está alineada a la izquierda

¿Por qué? Para representar la variante de forma única y para que se pueda comparar y superponer con otras variantes

Los INDELS es lo más complicado de comparar puesto que en regiones de baja complejidad, alineadores diferentes, sitúan los INDELS en posiciones diferentes

(*) "Unified representation of genetic variants"
Bioinformatics, Volume 31, Issue 13, 1 July 2015, Pages 2202–2204

Normalización de variantes y filtrado (II)

Para normalizar, se deben reajustar la posición de las variantes:

- Romper en primitivas: MNVs a SNVs
- Left align de las variantes
- Splitear variantes multialélicas

Algunos ejemplos de herramientas de normalización de variantes:

Bcftools norm:

- Herramienta más extendida para normalizar, más rápida
- Rompe las variantes multialélicas en primitivas
- No ajusta bien los genotipados multialélicos para heterozigotos:
    - GT=1/2 → 0/1 y 0/1

Vt:

- Computacionalmente más intenso
- Realiza el left-align
- Rompe las variantes multialélicas en primitivas
- Marca los genotipados de variantes heterozigotas multialélicas sin problema
    - GT=1/2 → ./1 y ./1

Normalización de variantes y filtrado (III)

Las variantes deben filtrarse una vez que se hayan determinado en la fase de variant calling

Después de la fase de variant calling, se debe hacer 'variant filtering'. Las variantes filtradas, habitualmente no se incluyen en la tabla de variantes final

Cada herramienta tiene sus criterios, pero en general el objetivo es señalar variantes que o bien son artefactos o bien se han determinado al límite de la técnica (esto no significa que no son reales)

Los filtrados más usados, son los que documenta GATK:
https://software.broadinstitute.org/gatk/documentation/article.php?id=2806

- QualByDepth (QD) 2.0

This is the variant confidence (from the `QUAL` field) divided by the unfiltered depth of non-reference samples.

- FisherStrand (FS) 60.0

Phred-scaled p-value using Fisher's Exact Test to detect strand bias (the variation being seen on only the forward or only the reverse strand) in the reads. More bias is indicative of false positive calls.

- RMSMappingQuality (MQ) 40.0

This is the Root Mean Square of the mapping quality of the reads across all samples.

- MappingQualityRankSumTest (MQRankSum) -12.5

This is the u-based z-approximation from the Mann-Whitney Rank Sum Test for mapping qualities (reads with ref bases vs. those with the alternate allele). Note that the mapping quality rank sum test can not be calculated for sites without a mixture of reads showing both the reference and alternate alleles, *i.e.* this will only be applied to heterozygous calls.

- ReadPosRankSumTest (ReadPosRankSum) -8.0

This is the u-based z-approximation from the Mann-Whitney Rank Sum Test for the distance from the end of the read for reads with the alternate allele. If the alternate allele is only seen near the ends of reads, this is indicative of error. Note that the read position rank sum test can not be calculated for sites without a mixture of reads showing both the reference and alternate alleles, *i.e.* this will only be applied to heterozygous calls.

- StrandOddsRatio (SOR) 3.0

The StrandOddsRatio annotation is one of several methods that aims to evaluate whether there is strand bias in the data. Higher values indicate more strand bias.

Ejemplo de Pipeline: SAREK
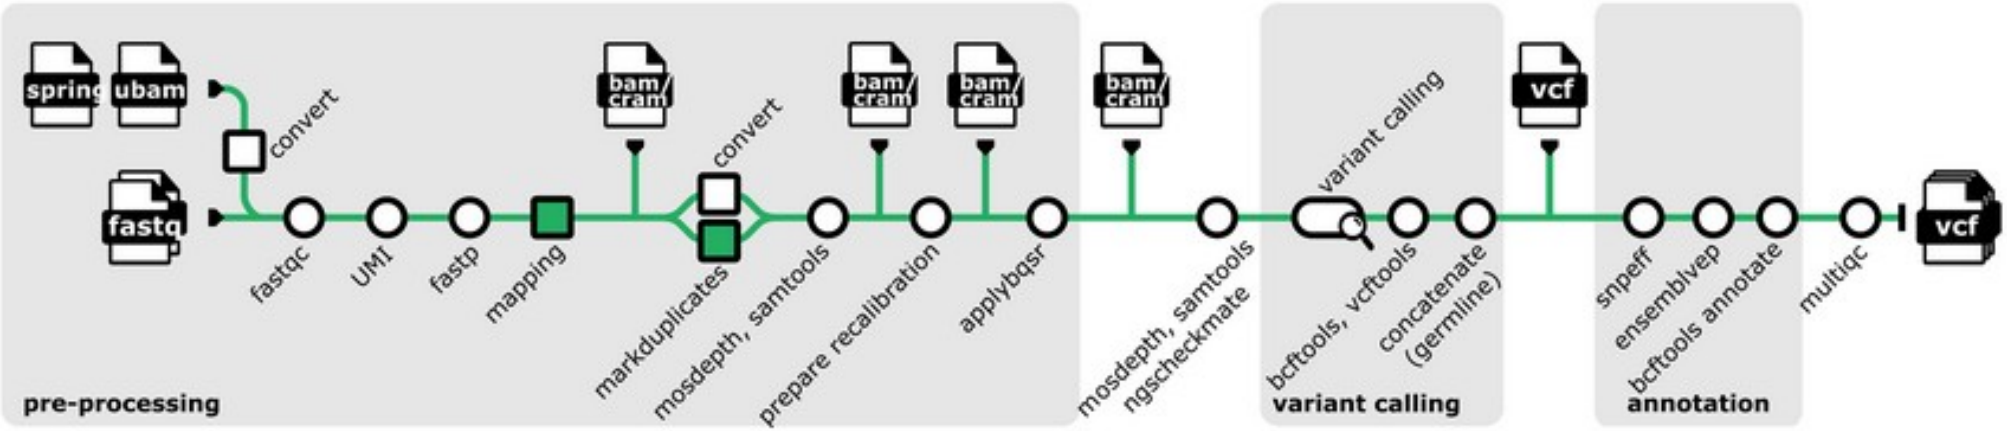
https://nf-co.re/sarek/3.5.1