Control de calidad en contexto clínico

Mario Solís López
01/04/2025

Control de calidad en contexto clínico

Sesión 5:

- Revisión calidad del alineamiento
- Revisión calidad del variant calling
- Rendimiento experimental
- Revisión en el contexto experimental
- Detección de anomalías

QC del alineamiento

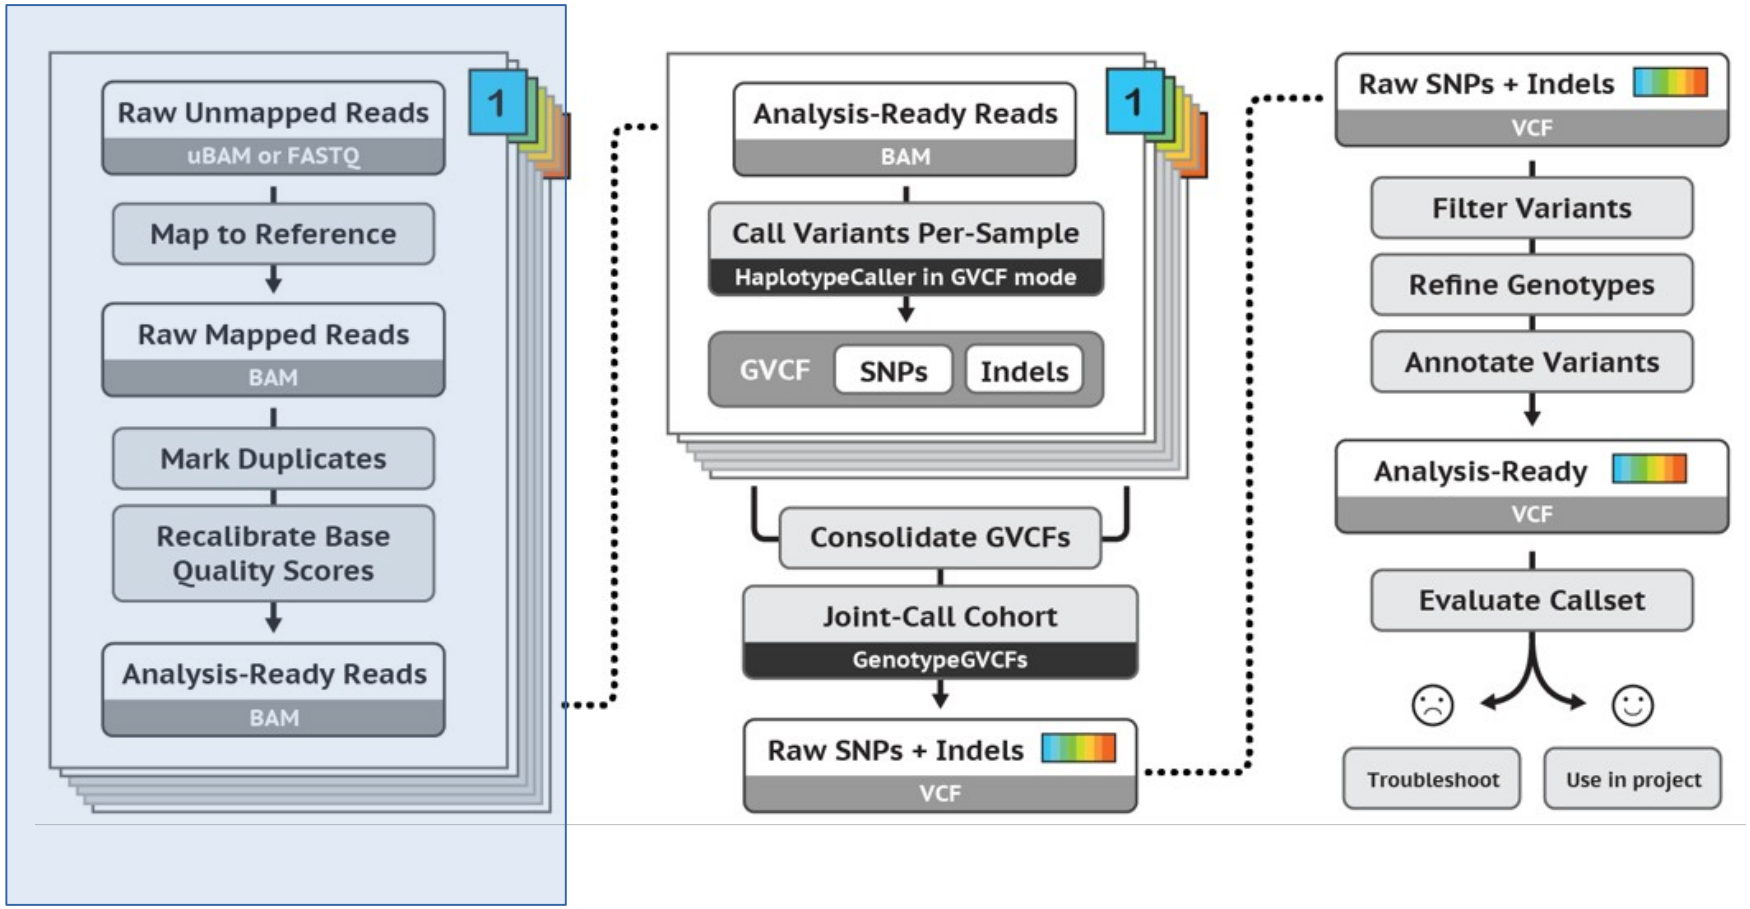

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

QC del alineamiento

- Tras alinear (siguiendo las buenas prácticas de GATK), se evalúan múltiples marcadores de calidad:
  - Número de lectura alineadas
  - Número de lecturas alineadas frente al genoma humano
  - Número de lecturas en la región de captura o de interés(i.e. *on-target*)

¡¡¡el alineamiento se hace sobre todo el genoma!!!!

  - Número de lecturas duplicadas
  - Número de lecturas con una calidad de mapeado de las lecturas (MAPQ) superior a un umbral (20)

- Porcentaje de todos estos números respecto al número de lecturas originales podemos obtener el rendimiento experimental
- La distribución de la calidad de lecturas alineadas y la proporción con una calidad mayor a **Q20**

QC del alineamiento

- Finalmente, a partir de los alineamientos, es posible calcular la **cobertura** de la muestra.

La cobertura es el marcador más importante en una muestra secuenciada por NGS

QC del alineamiento
Cobertura

- La **cobertura** se define como el número exacto de veces que una base de la referencia ha sido cubierta por una lectura de alta calidad en un experimento de secuenciación → '*depth of coverage*' (vertical)

- También se define como el porcentaje de bases de la región de interés que han sido secuenciadas un cierto número de veces → '*breadth of coverage' (horizontal)*

QC del alineamiento
Cobertura

Tiroglobulina (TG)
Exón 18

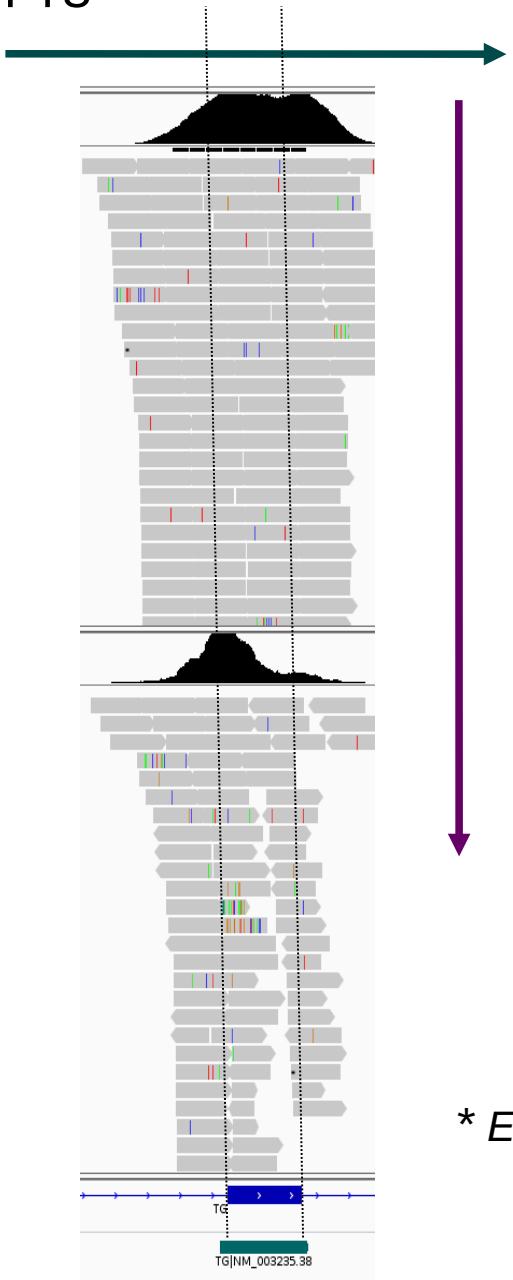

Cobertura 'horizontal':

% de la región de interés con lecturas 'suficientes' para determinar las variantes (%bp >= 20X)

Cobertura 'vertical':

(Profundidad de lecturas): Número de veces que se ha leído cada nucleótido en la región de interés por encima de un umbral de calidad

** En captura dirigida, la cobertura horizontal tiene un techo (98-99%)*

QC del alineamiento
Cobertura

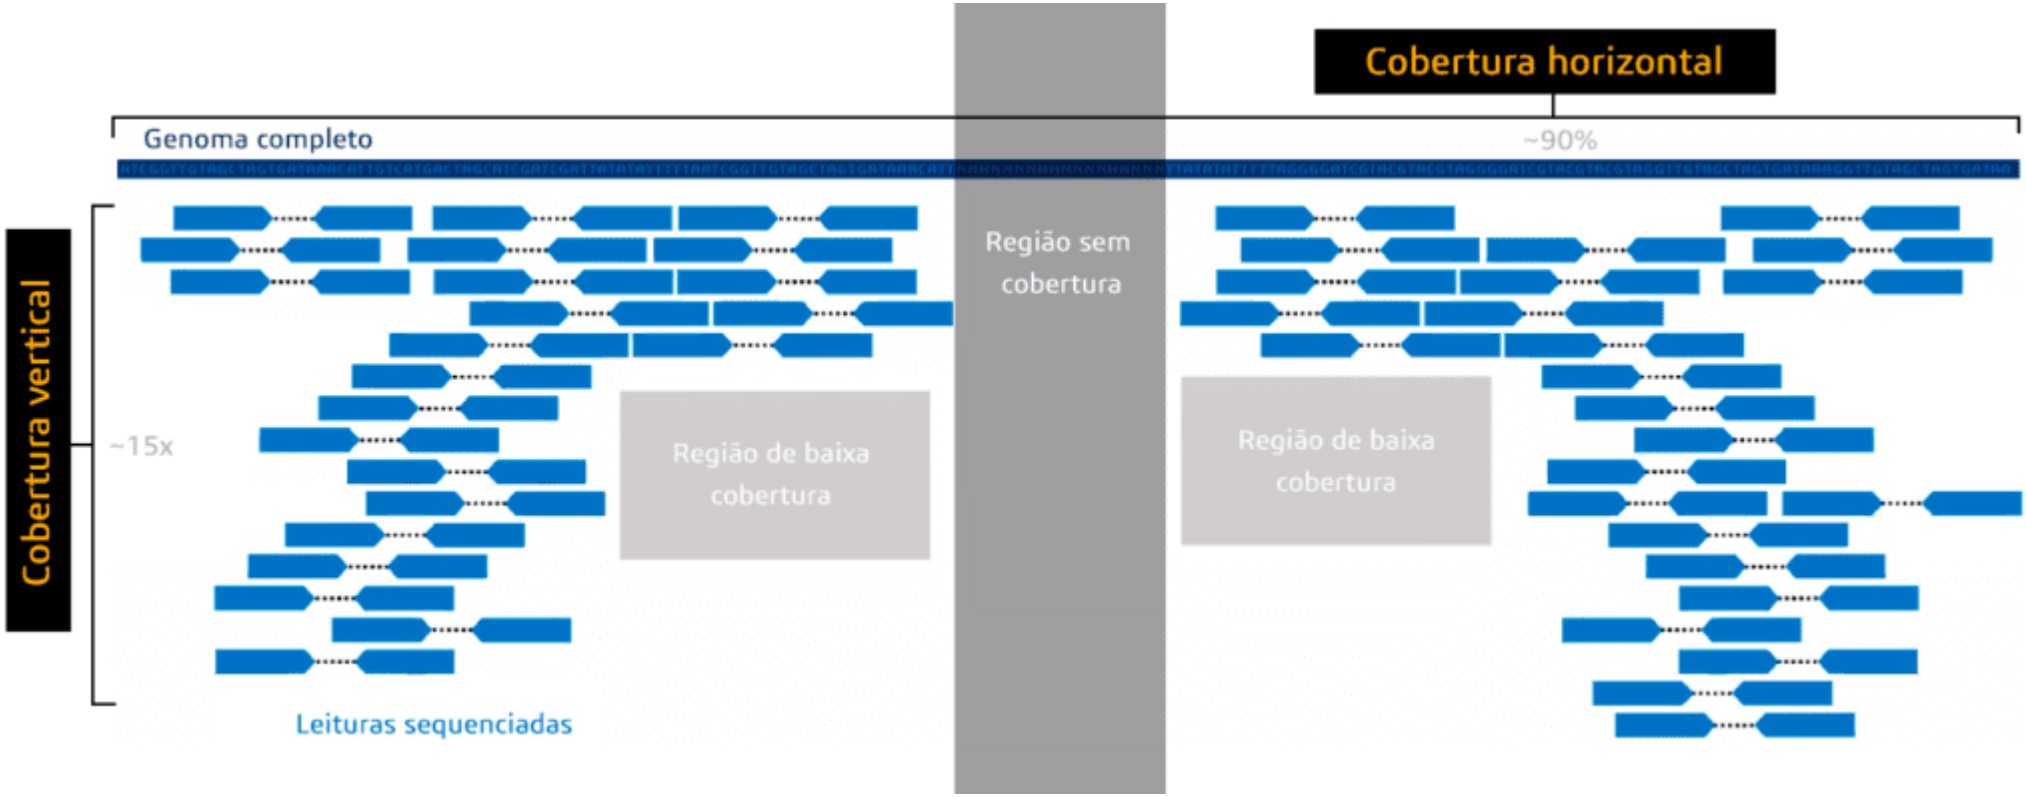

QC del alineamiento
Cobertura

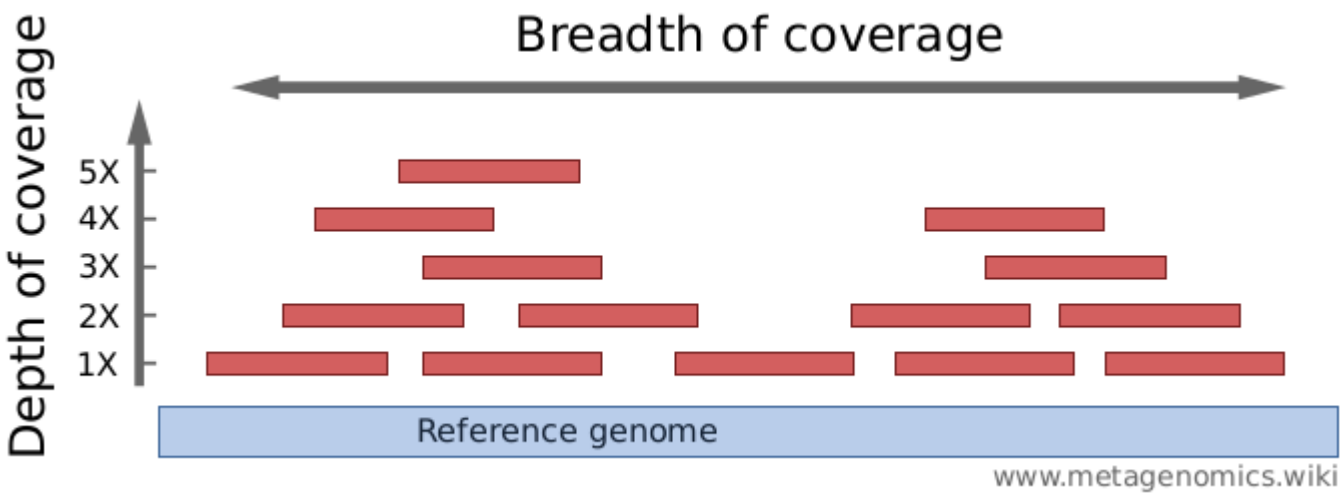

QC del alineamiento
Cobertura

- La **cobertura** se define como el número exacto de veces que una base de la referencia ha sido cubierta por una lectura de alta calidad en un experimento de secuenciación → '*depth of coverage*'

- También se define como el porcentaje de bases de la región de interés que han sido secuenciadas un cierto número de veces → '*breadth of coverage*'

- **<u>Ejemplo</u>: Secuenciación de un genoma con una cobertura de 30X y que el 95% de las bases de referencia tengan un mínimo de 10 lecturas.**

- **Para el diagnóstico clínico se requiere alta cobertura:**
  - **Entre 30X y 100X**
  - **80% de las bases de interés con un mínimo de 20X**

QC del alineamiento
Cobertura

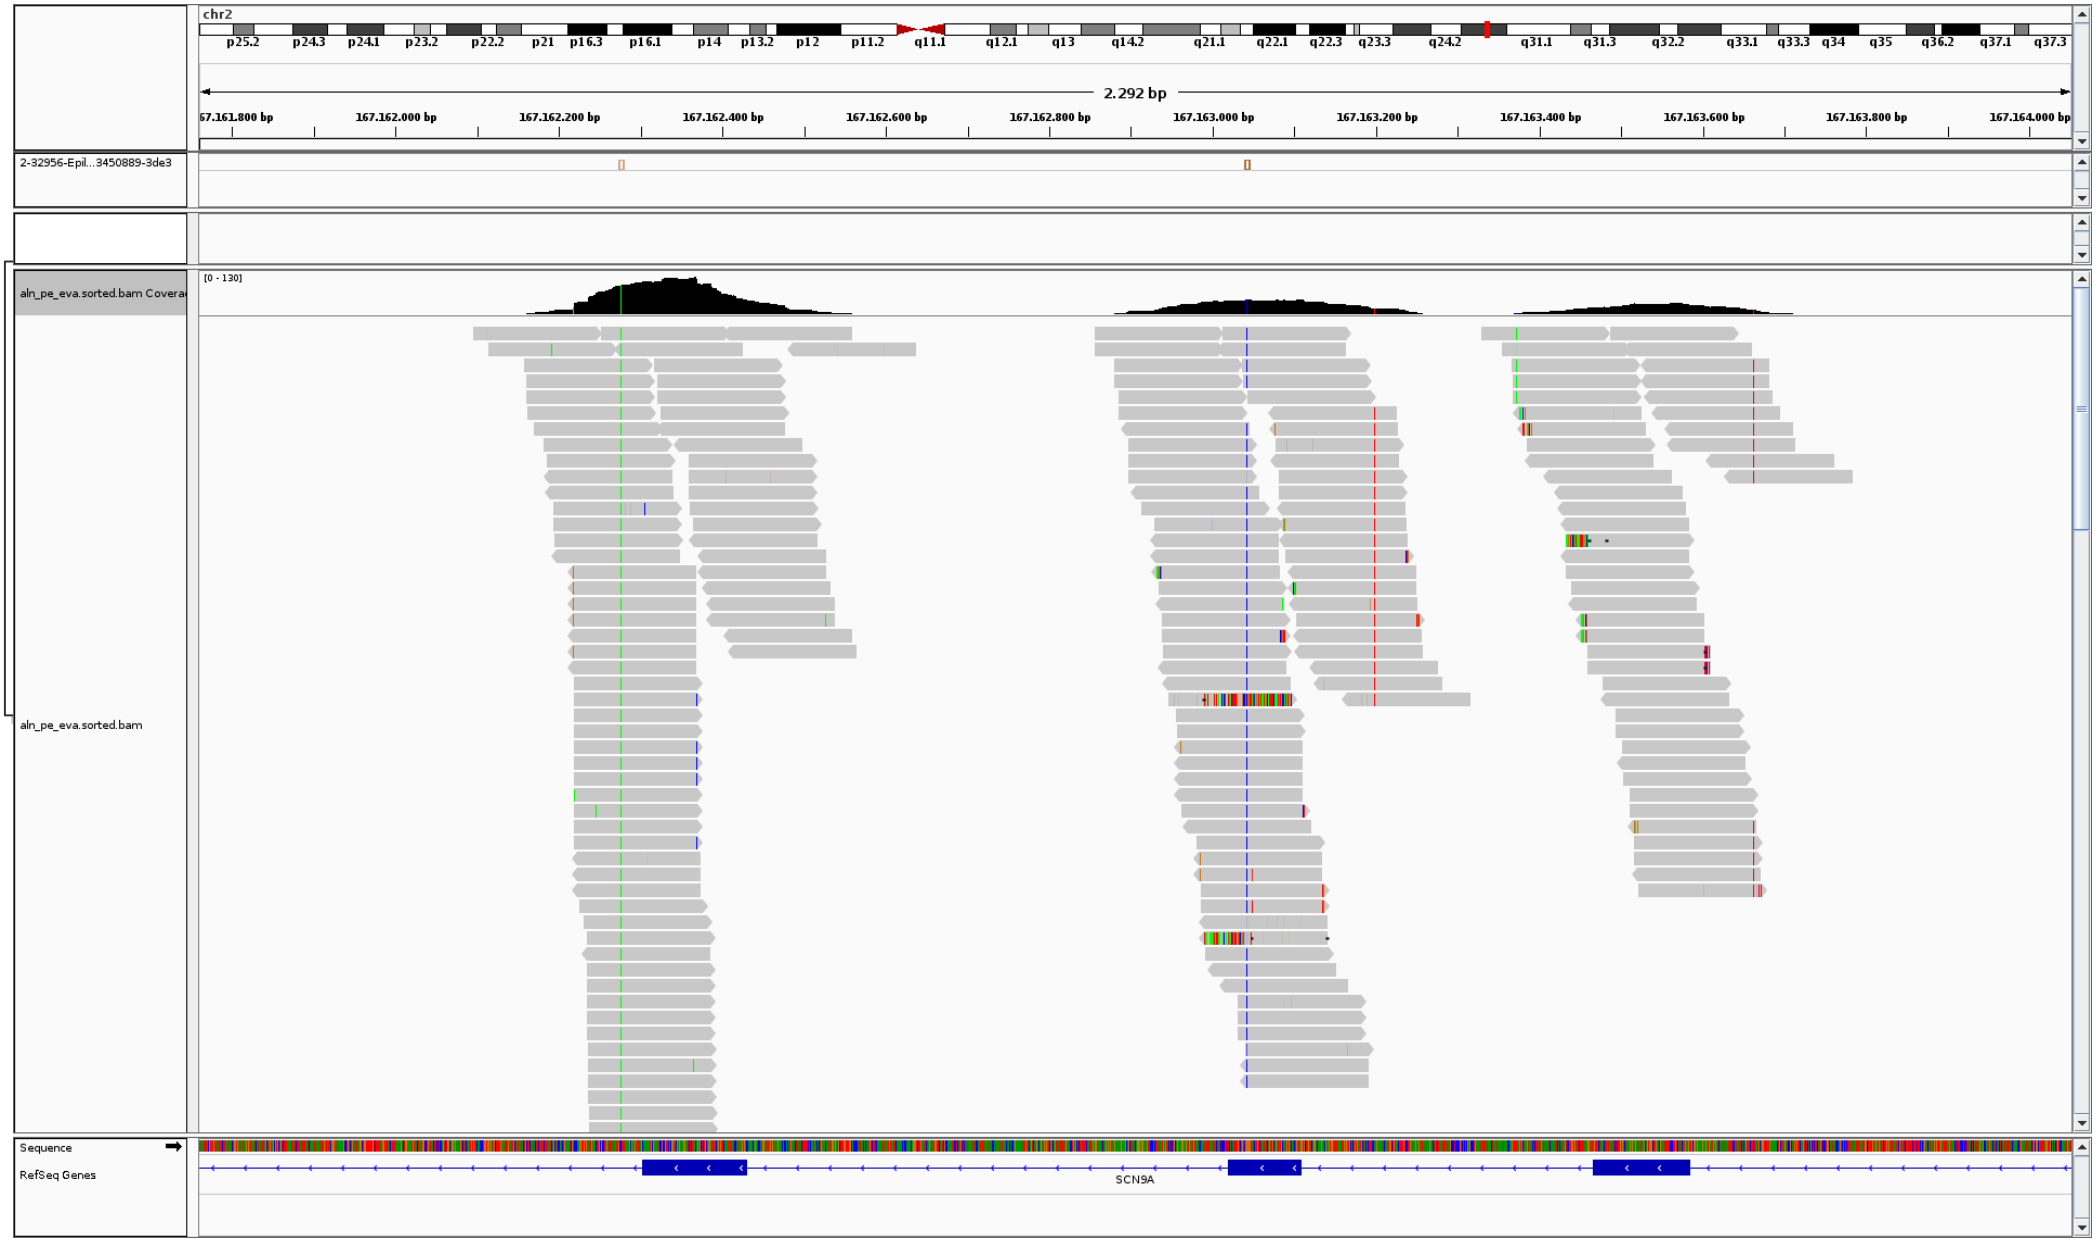

QC del alineamiento

- Este QC es **crítico** para el análisis.

- Si la calidad en el alineamiento es insuficiente, se debe decidir **re-secuenciar** la muestra.

- Importante en el contexto clínico:

  - Demostrar la calidad de cobertura en las distintas regiones de interés mediante un informe.

  - Si no se han determinado variantes → **necesario para justificar los negativos.**

Evaluación de la calidad

- En función de los marcadores de calidad anteriormente descritos, asignaremos 3 posibles estados a cada muestra:
  - OK : Si todas las regiones de interés se encuentran lo suficientemente cubiertas para un correcto análisis de variantes
  - FAIL : Si las regiones de interés no están lo suficientemente cubiertas
  - WARNING : Sólo ciertas regiones de interés están cubiertas
- Checklist:
  - Si la cobertura media no alcanza el 21X → FAIL
  - Si el porcentaje de pares de bases con una cobertura de 20X:
    - No alcanza el 60% → FAIL
    - No alcanza el 80% → WARNING

Caso práctico

- Un pool de 30 muestras secuenciado en NextSeq500

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X
S1	45,75	62,96
S2	103,94	72,46
S3	19,71	45,33
S4	107,07	92,83
S5	176,76	79,16
S6	193,14	95,49
S7	225,12	85,93
S8	262,1	95,85
S9	194,8	98,64
S10	101,8	83,29
S11	31,67	86,38
S12	248,38	98,57
S13	267,11	98,42
S14	248,85	94,99
S15	166,99	89,68
S16	333,65	98,69
S17	253,68	98,7
S18	282,2	98,68
S19	256,77	98,58
S20	1,64	0
S21	286,37	98,69
S22	127,52	82,39
S23	291,94	98,72
S24	26,79	41,01
S25	9,39	15,16
S26	29,07	67,98
S27	156,59	98,45
S28	279,66	98,68
S29	80,78	64,32
S30	238,19	98,1

Caso práctico

- Un pool de 30 muestras secuenciado en NextSeq500

FAIL!

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X
S1	45,75	62,96
S2	103,94	72,46
S3	19,71	45,33
S4	107,07	92,83
S5	176,76	79,16
S6	193,14	95,49
S7	225,12	85,93
S8	262,1	95,85
S9	194,8	98,64
S10	101,8	83,29
S11	31,67	86,38
S12	248,38	98,57
S13	267,11	98,42
S14	248,85	94,99
S15	166,99	89,68
S16	333,65	98,69
S17	253,68	98,7
S18	282,2	98,68
S19	256,77	98,58
S20	1,64	0
S21	286,37	98,69
S22	127,52	82,39
S23	291,94	98,72
S24	26,79	41,01
S25	9,39	15,16
S26	29,07	67,98
S27	156,59	98,45
S28	279,66	98,68
S29	80,78	64,32
S30	238,19	98,1

Caso práctico

- Un pool de 30 muestras secuenciado en NextSeq500

FAIL!

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X
S1	45,75	62,96
S2	103,94	72,46
S3	19,71	45,33
S4	107,07	92,83
S5	176,76	79,16
S6	193,14	95,49
S7	225,12	85,93
S8	262,1	95,85
S9	194,8	98,64
S10	101,8	83,29
S11	31,67	86,38
S12	248,38	98,57
S13	267,11	98,42
S14	248,85	94,99
S15	166,99	89,68
S16	333,65	98,69
S17	253,68	98,7
S18	282,2	98,68
S19	256,77	98,58
S20	1,64	0
S21	286,37	98,69
S22	127,52	82,39
S23	291,94	98,72
S24	26,79	41,01
S25	9,39	15,16
S26	29,07	67,98
S27	156,59	98,45
S28	279,66	98,68
S29	80,78	64,32
S30	238,19	98,1

Caso práctico

- Un pool de 30 muestras secuenciado en NextSeq500

WARNING

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X
S1	45,75	62,96
S2	103,94	72,46
S3	19,71	45,33
S4	107,07	92,83
S5	176,76	79,16
S6	193,14	95,49
S7	225,12	85,93
S8	262,1	95,85
S9	194,8	98,64
S10	101,8	83,29
S11	31,67	86,38
S12	248,38	98,57
S13	267,11	98,42
S14	248,85	94,99
S15	166,99	89,68
S16	333,65	98,69
S17	253,68	98,7
S18	282,2	98,68
S19	256,77	98,58
S20	1,64	0
S21	286,37	98,69
S22	127,52	82,39
S23	291,94	98,72
S24	26,79	41,01
S25	9,39	15,16
S26	29,07	67,98
S27	156,59	98,45
S28	279,66	98,68
S29	80,78	64,32
S30	238,19	98,1

QC del alineamiento

- Gran diversidad de herramientas:
  - Samtools (http://www.htslib.org/)
  - sambamba
  - mosdepth
  - Bedtools (http://bedtools.readthedocs.io/en/latest/)
  - Picard Tools (http://broadinstitute.github.io/picard/index.html)

QC del alineamiento

- Gran diversidad de herramientas:
  - **Samtools** (http://www.htslib.org/)
  - sambamba
  - **mosdepth**
  - **Bedtools**
  - Picard Tools (http://broadinstitute.github.io/picard/index.html)

QC del alineamiento

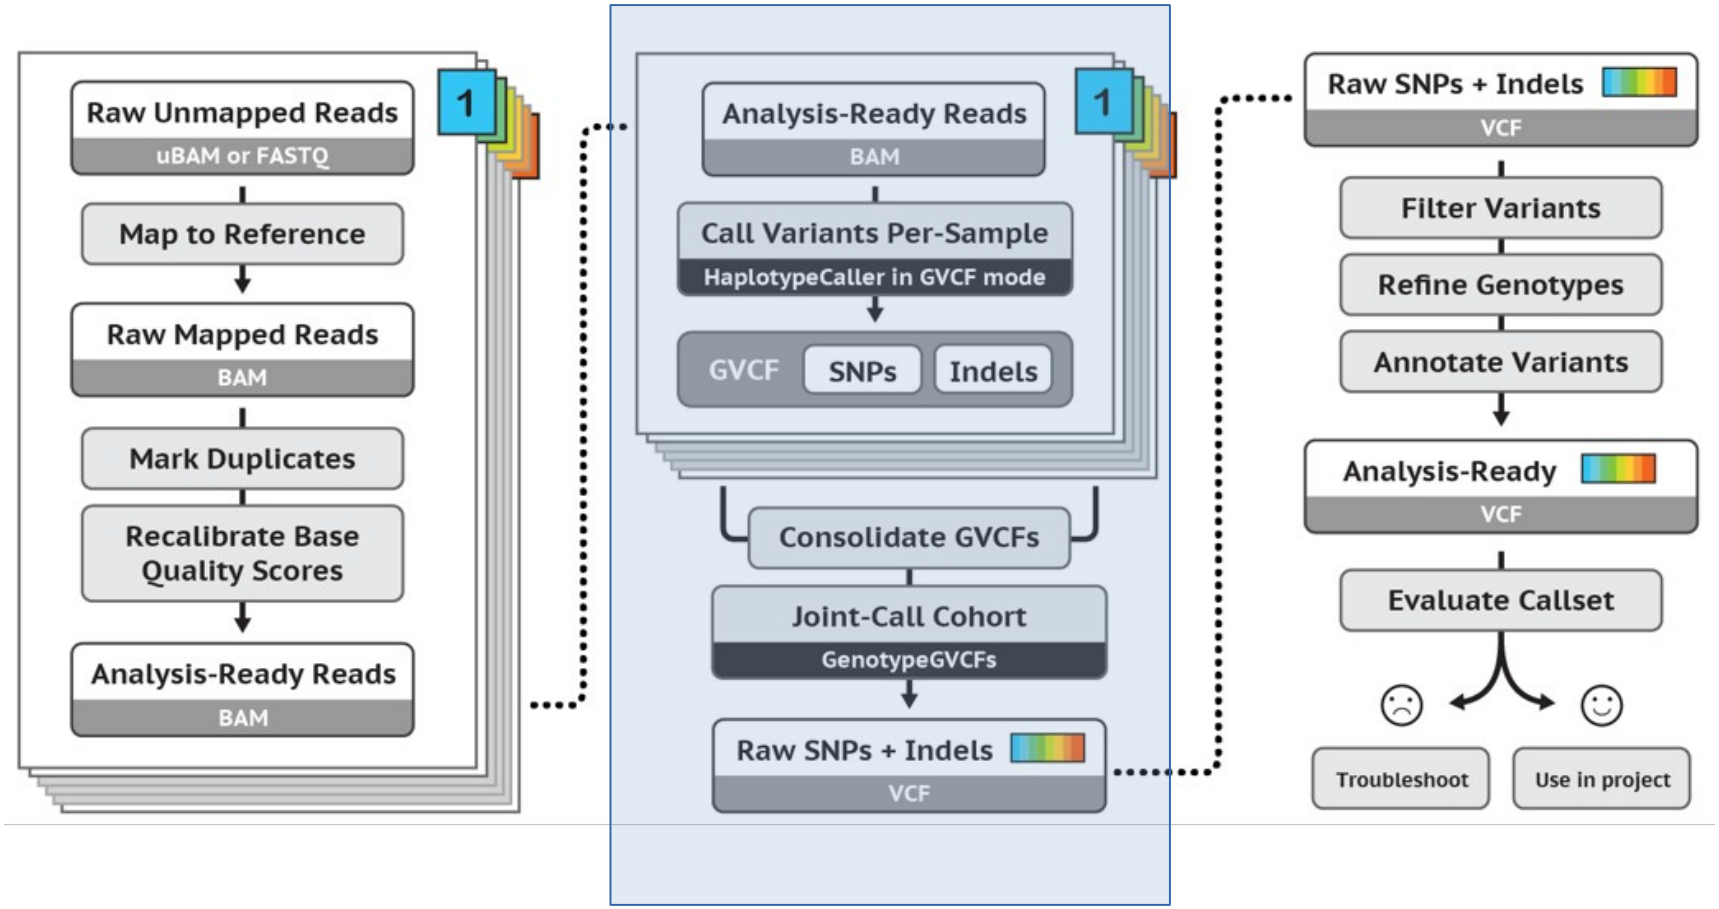

Best Practices for SNP and Indel discovery in germline DNA - leveraging groundbreaking methods for combined power and scalability.

QC del Variant Calling

- Un VCF generado por un variant caller presenta múltiples marcadores de calidad para cada variante determinada.

- En una llamada de una variante, encontraremos:
  - QUAL : Probabilidad (en la escala ‘Phred’) de que exista un polimorfismo.
  - AD : Profundidad sin filtrar en la posición, para cada alelo.
  - DP : Profundidad filtrada en la posición.
  - PL : ‘Probabilidades‘ normalizadas (en la escala ‘Phred’) de los genotipos → El PL del genotipo asignado es 0.
  - GQ : Confianza en la escala ‘Phred’, de que el genotipo determinado es el correcto → derivado del campo PL; máximo valor es 99.

QC del Variant Calling

- Para valorar la calidad de un VCF, se exploran las **distribuciones** de los parámetros anteriormente descritos.

- Se puede evaluar:

  - El porcentaje de variantes con un GQ inferior a 99.

  - El porcentaje de variantes con un QUAL inferior a 50.

  - El ratio de la frecuencia alélica de las variantes heterozigotas.

QC del Variant Calling

- Herramientas para evaluar VCFs:
  - *RTG Tools* (https://github.com/RealTimeGenomics/rtg-tools)
  - *VCFtools* (https://vcftools.github.io/index.html)

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

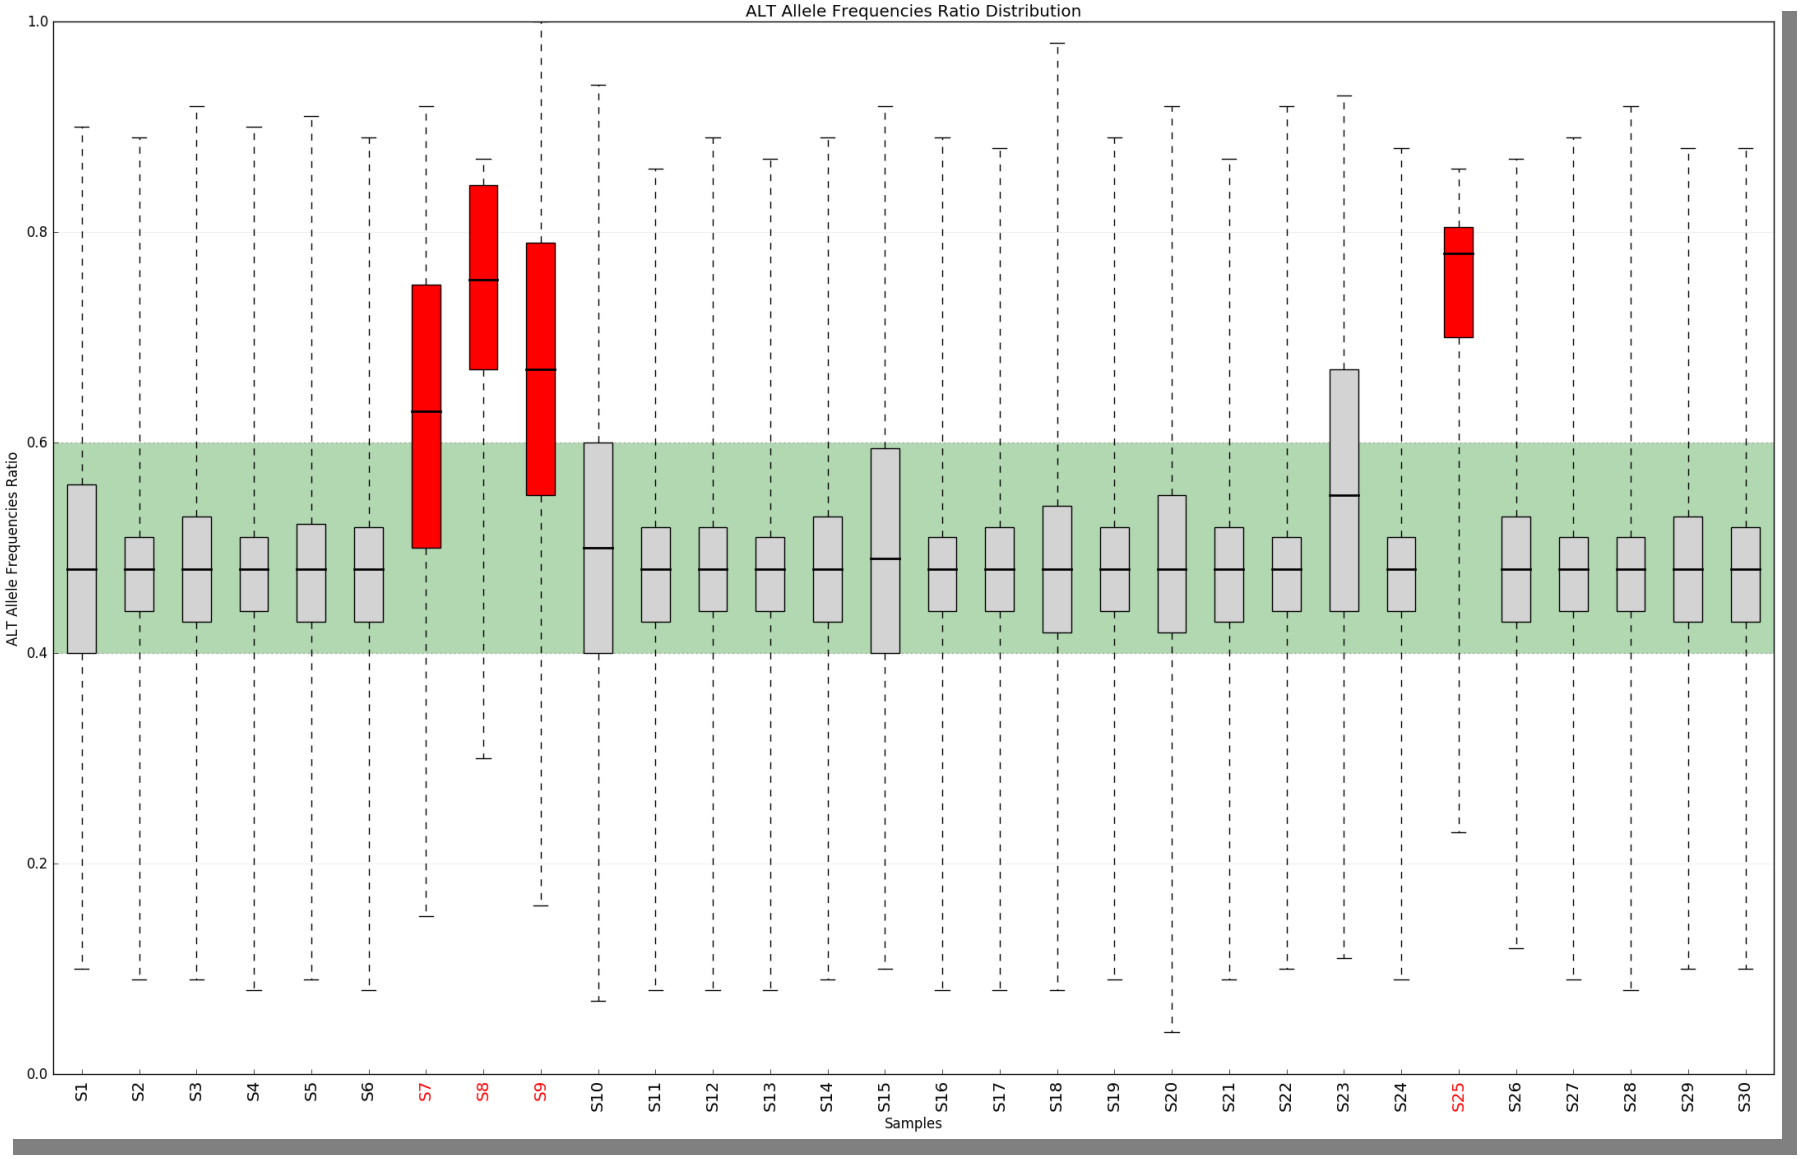

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

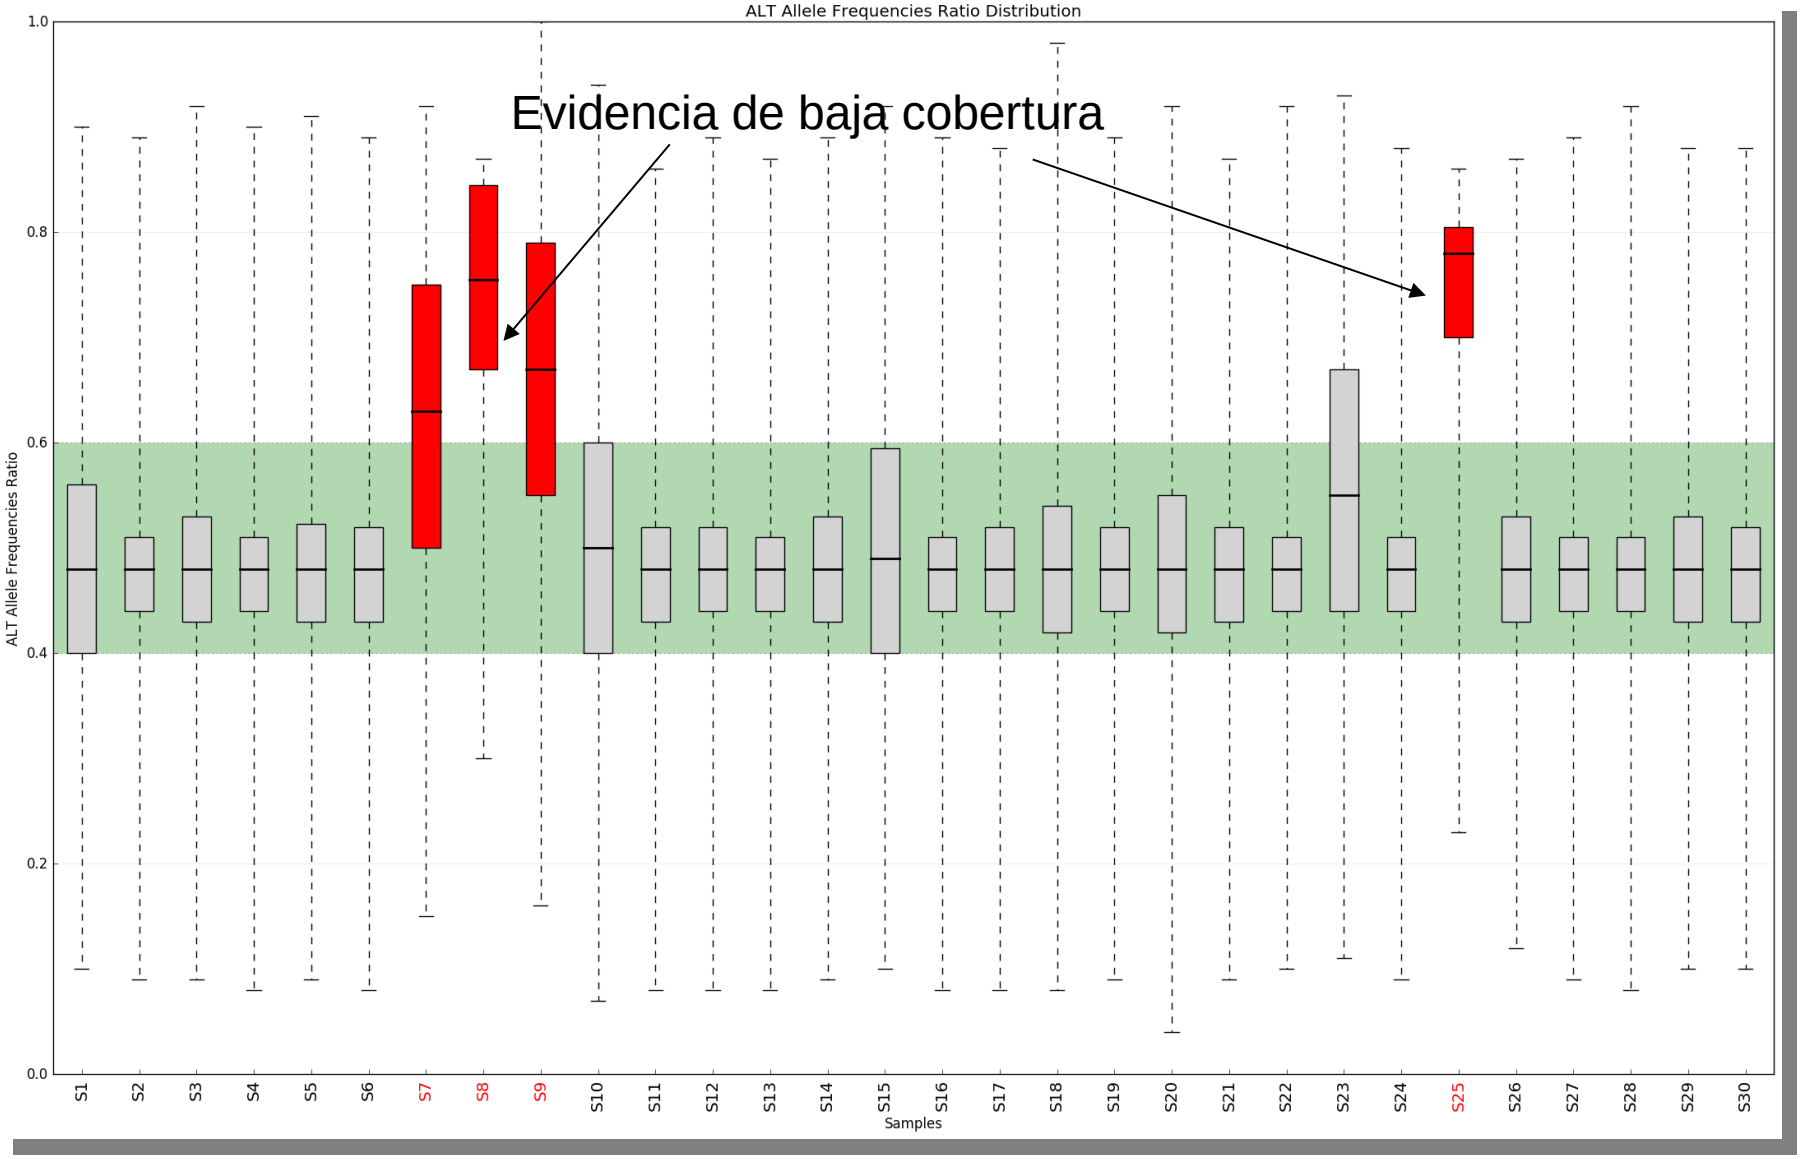

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

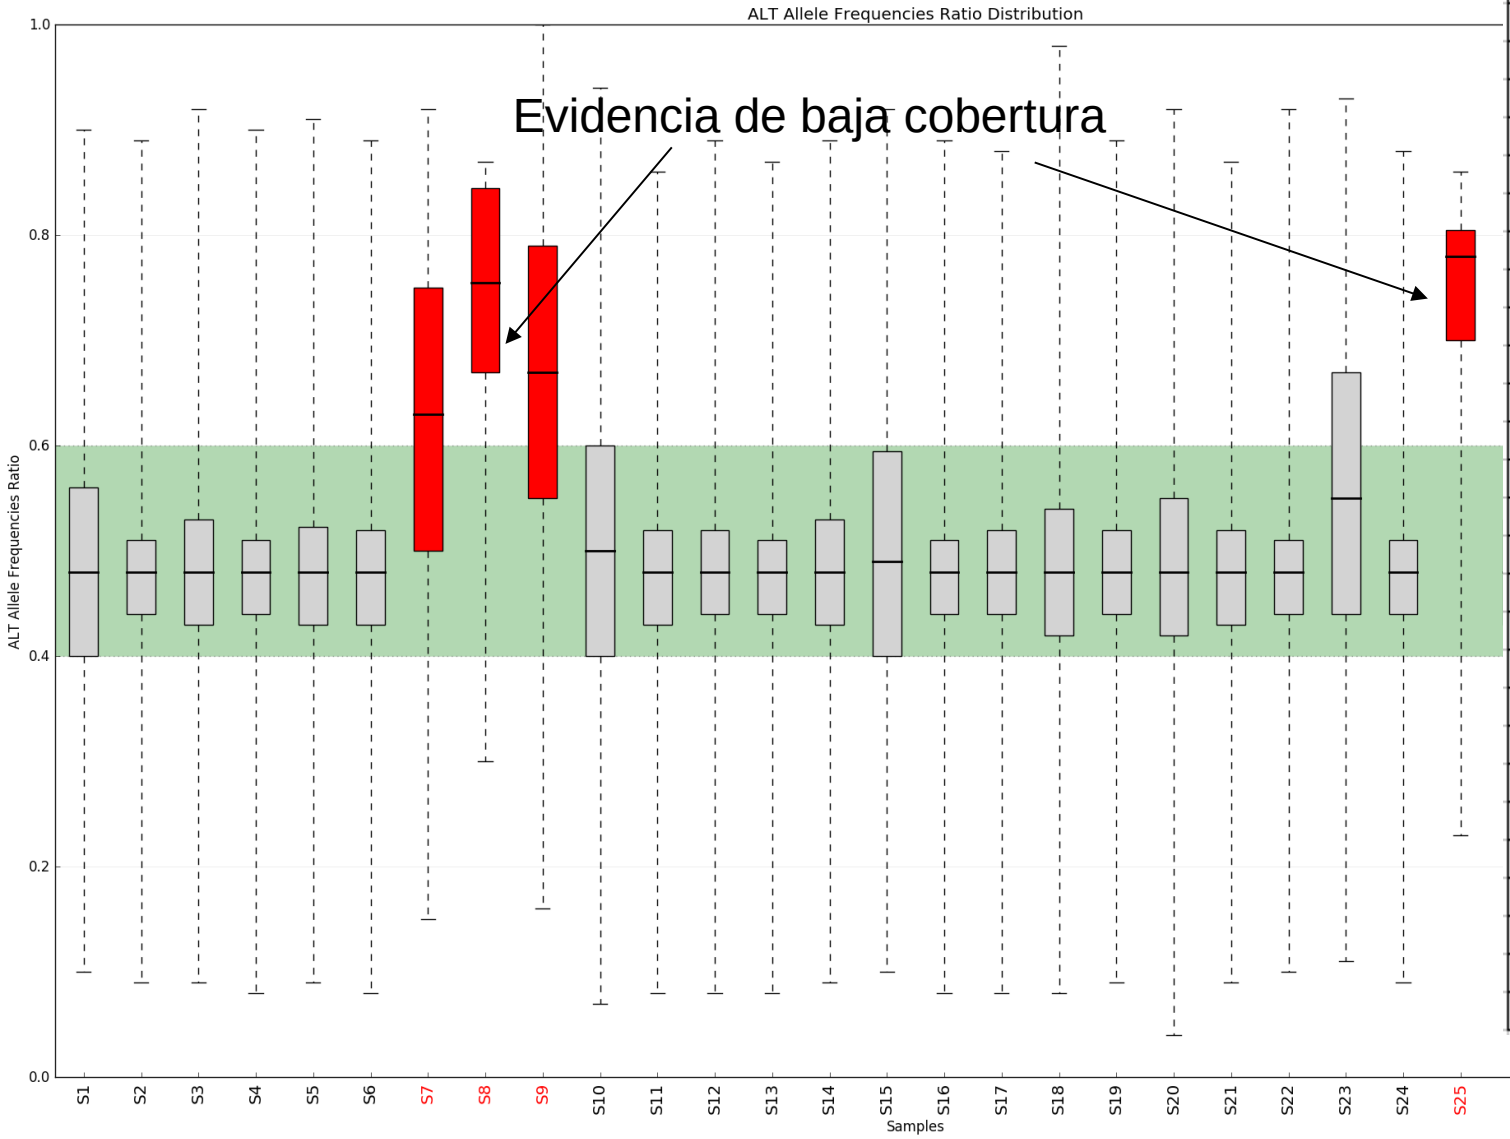

SAMPLE ID	%bp > 20X
S1	91,00%
S2	98,00%
S3	97,00%
S4	98,00%
S5	98,00%
S6	98,00%
S7	13,00%
S8	0,00%
S9	6,00%
S10	88,00%
S11	98,00%
S12	98,00%
S13	98,00%
S14	98,00%
S15	84,00%
S16	98,00%
S17	98,00%
S18	96,00%
S19	98,00%
S20	97,00%
S21	97,00%
S22	98,00%
S23	43,00%
S24	98,00%
S25	0,00%
S26	98,00%
S27	98,00%
S28	98,00%
S29	98,00%
S30	97,00%

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

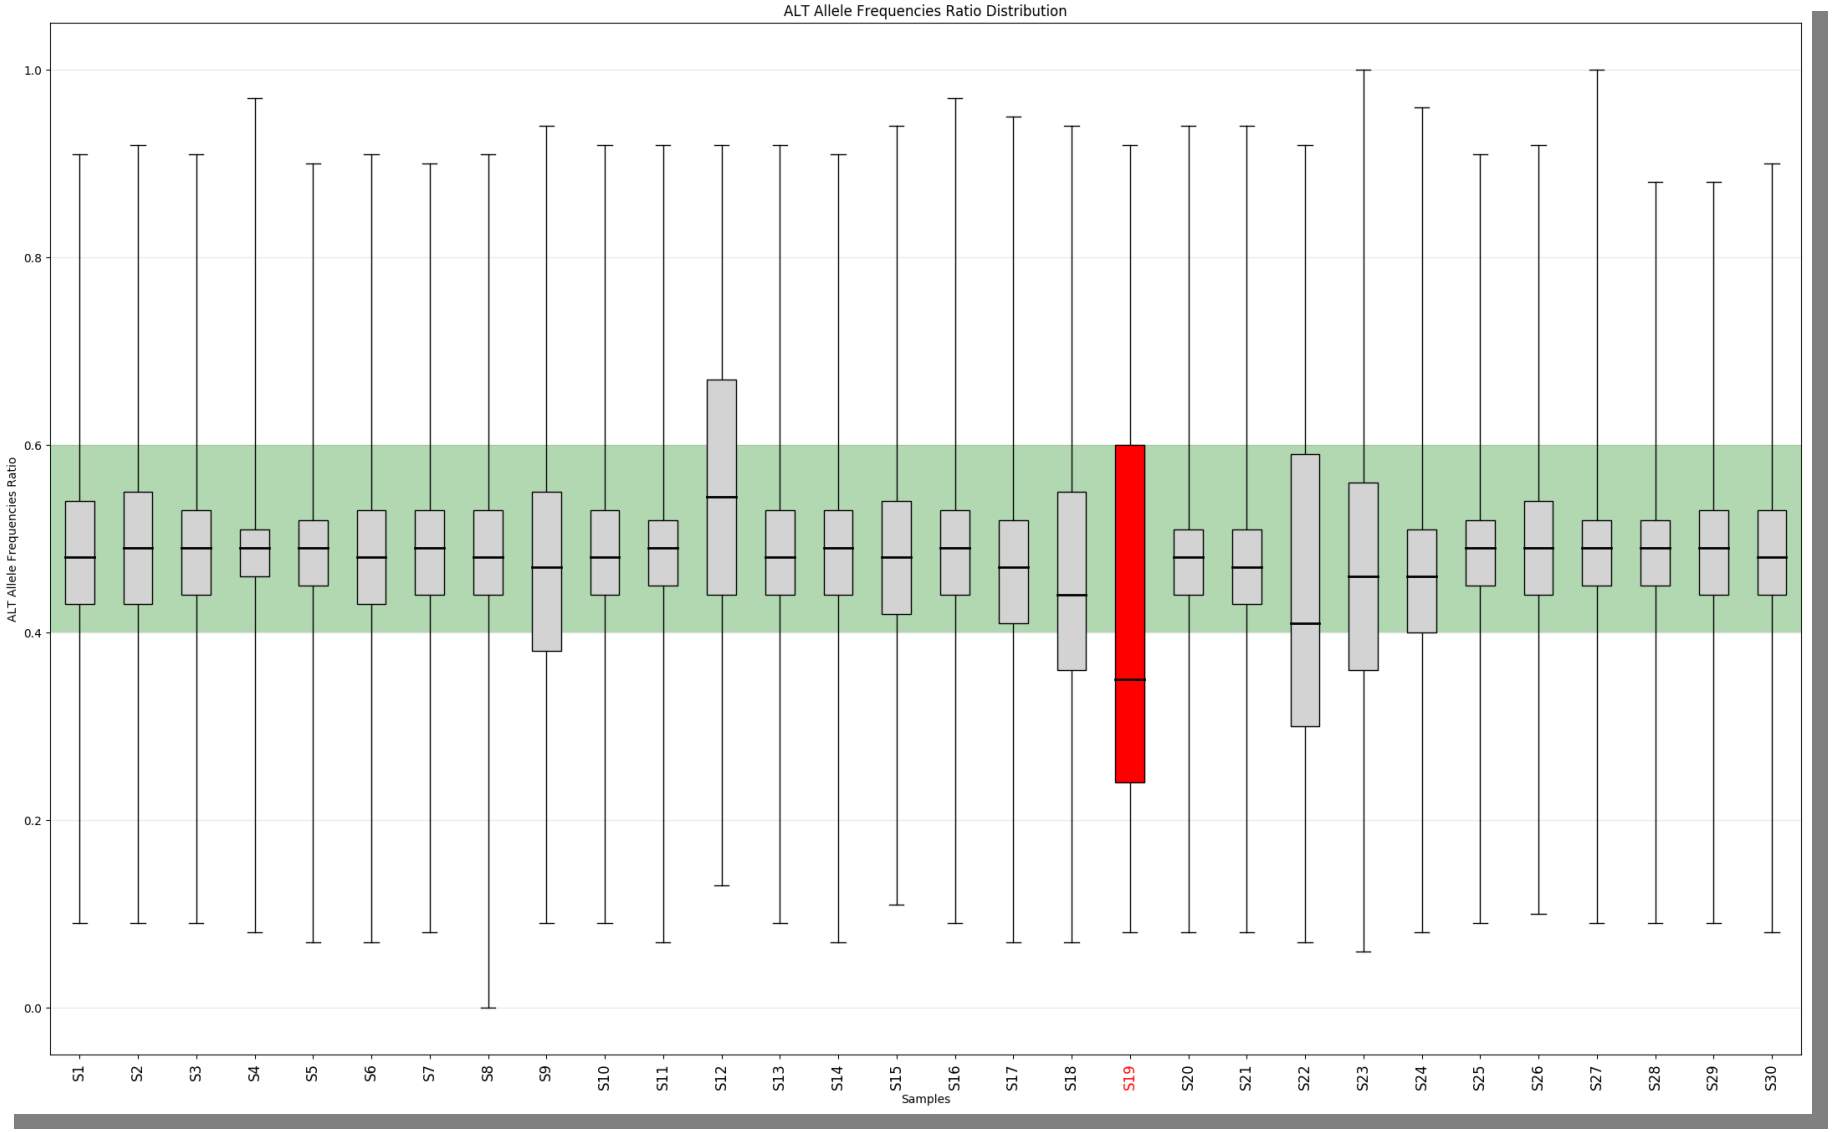

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

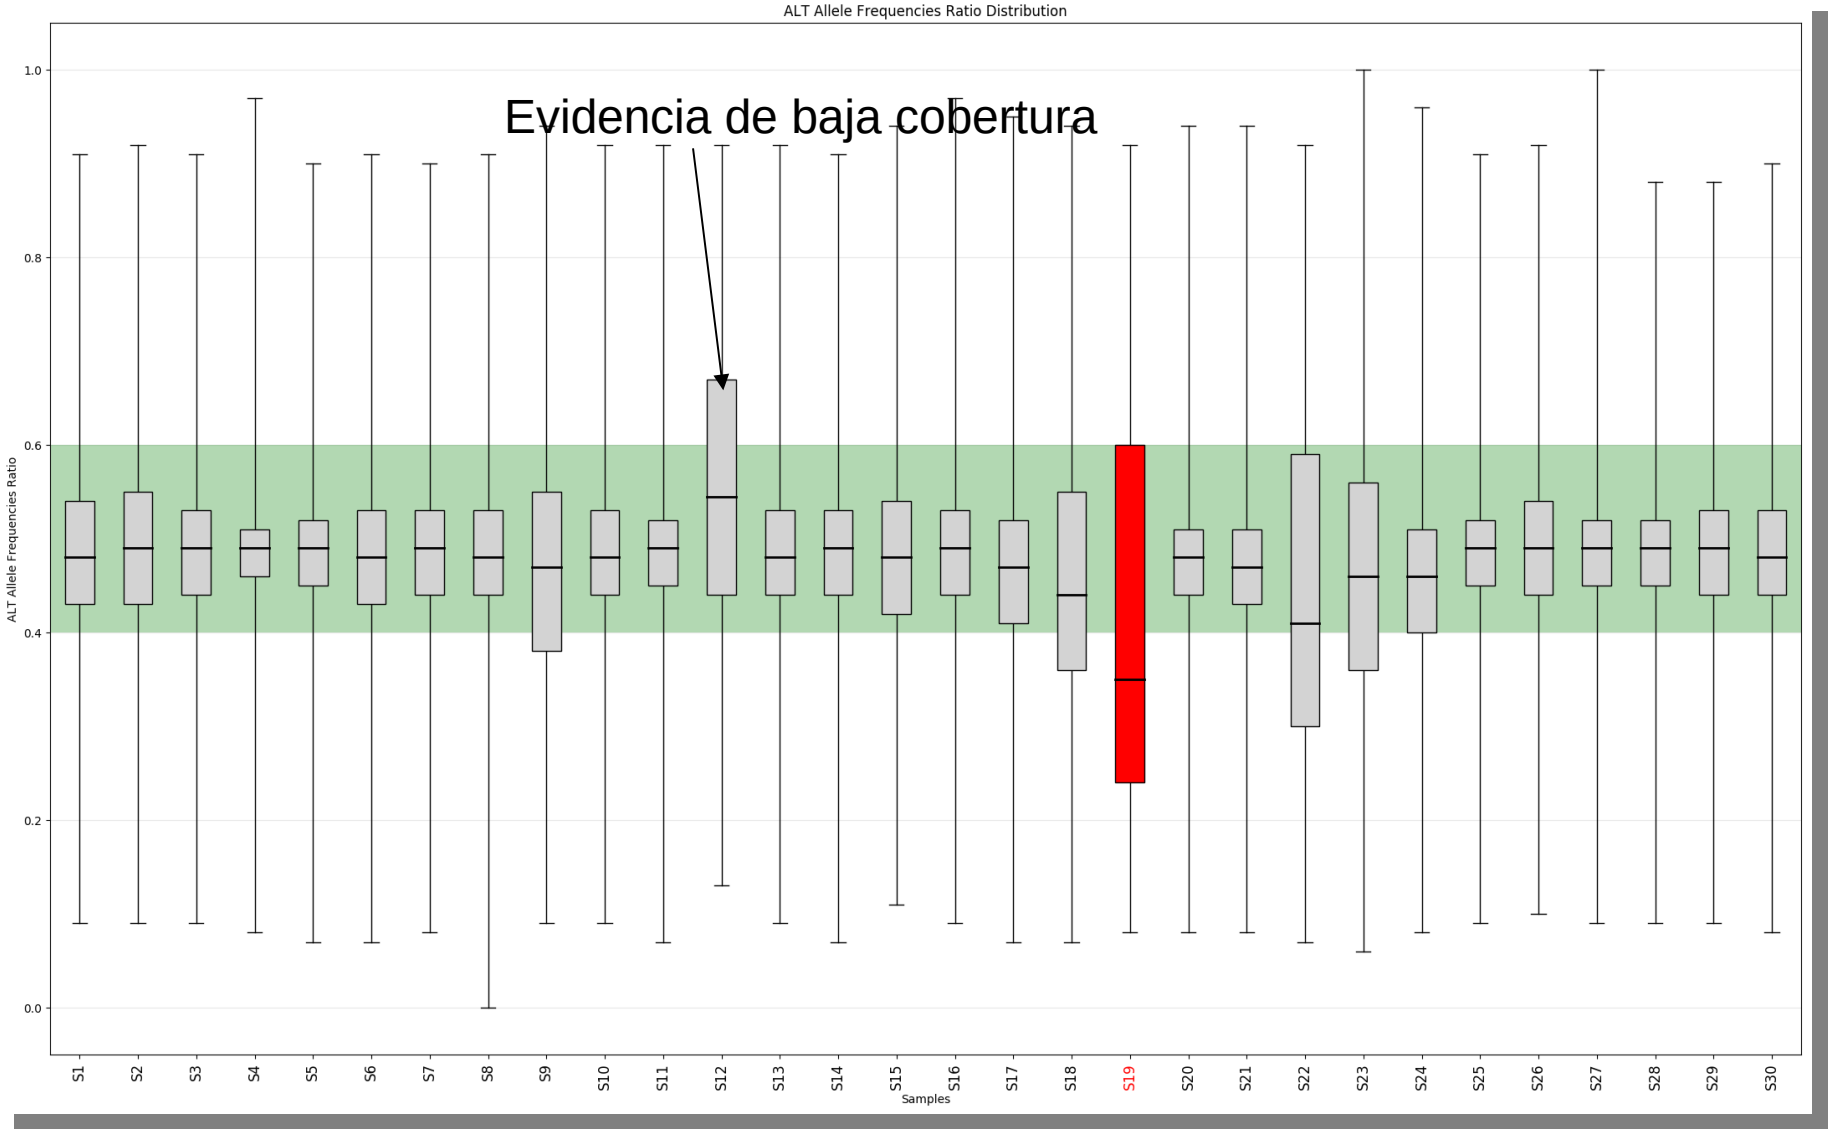

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

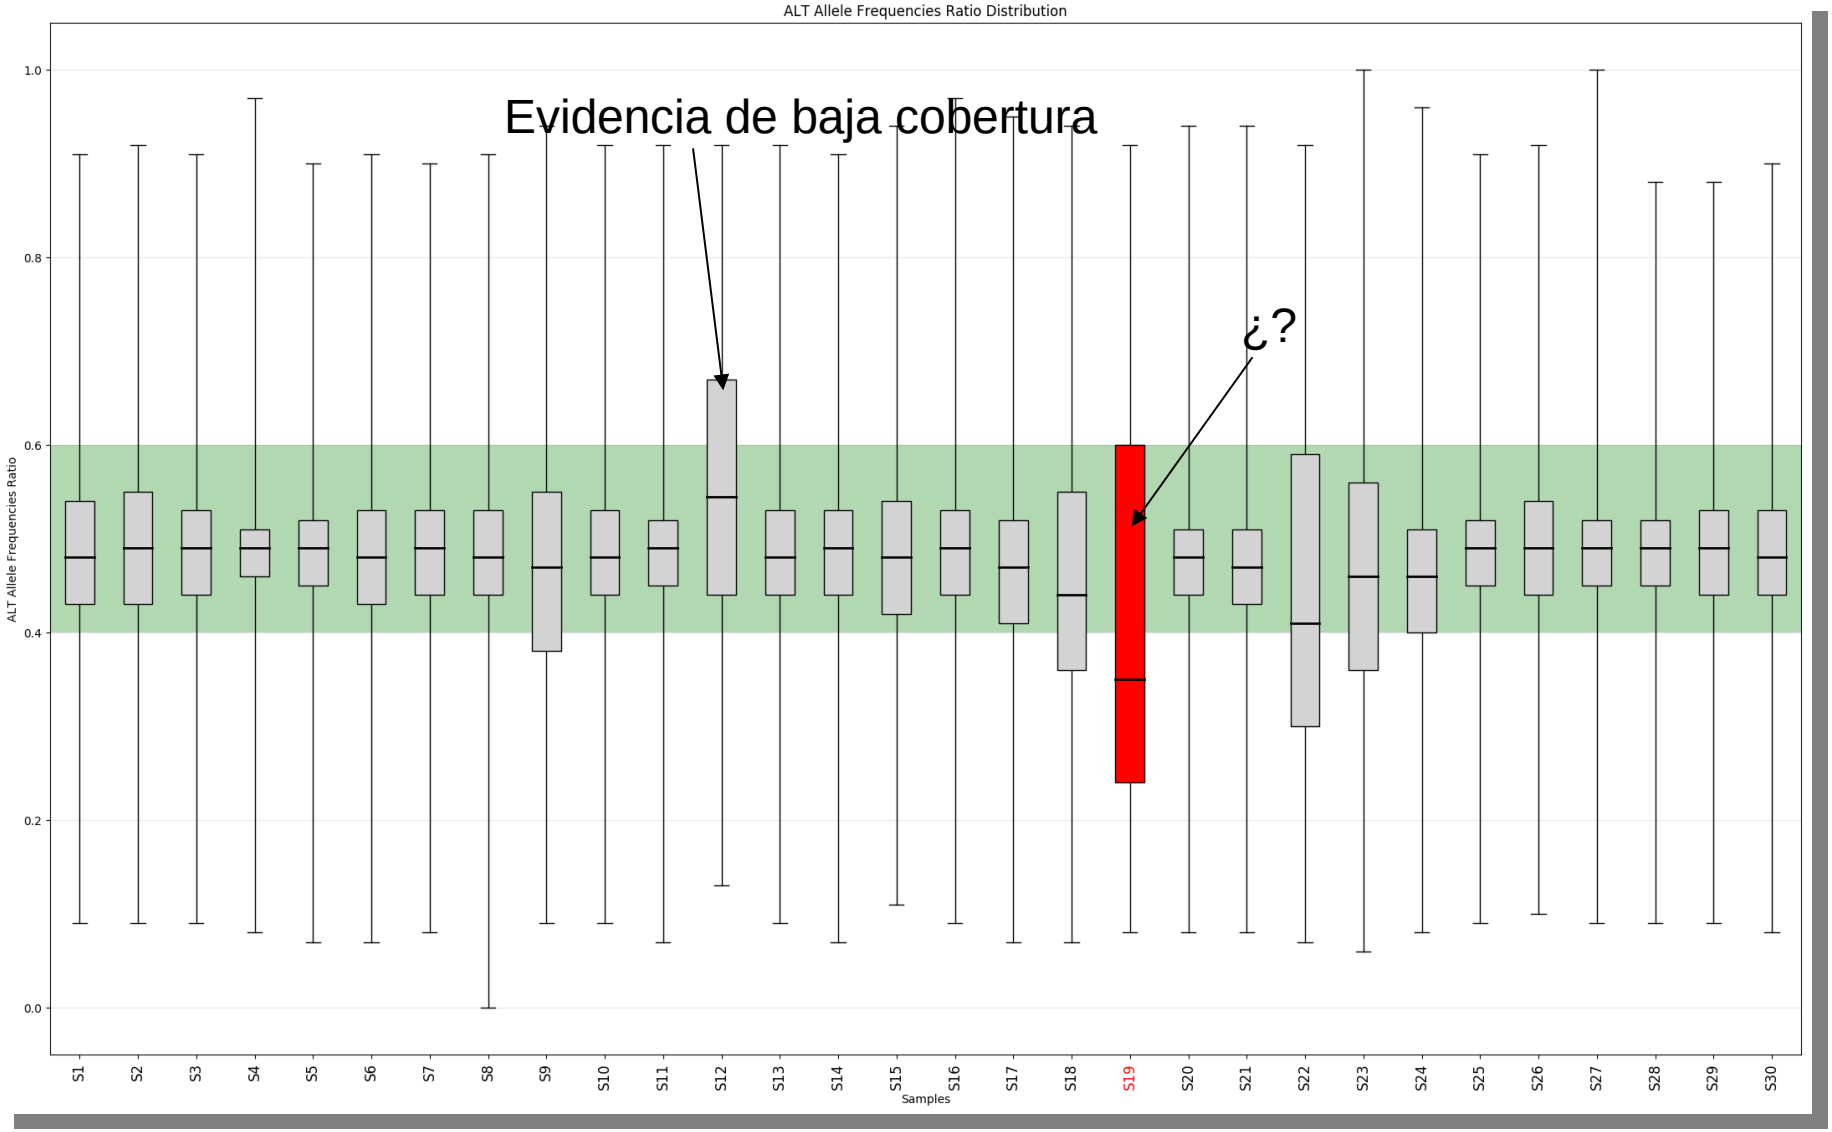

Casos prácticos

- Ratio de la frecuencia alélica de las variantes heterozigotas.

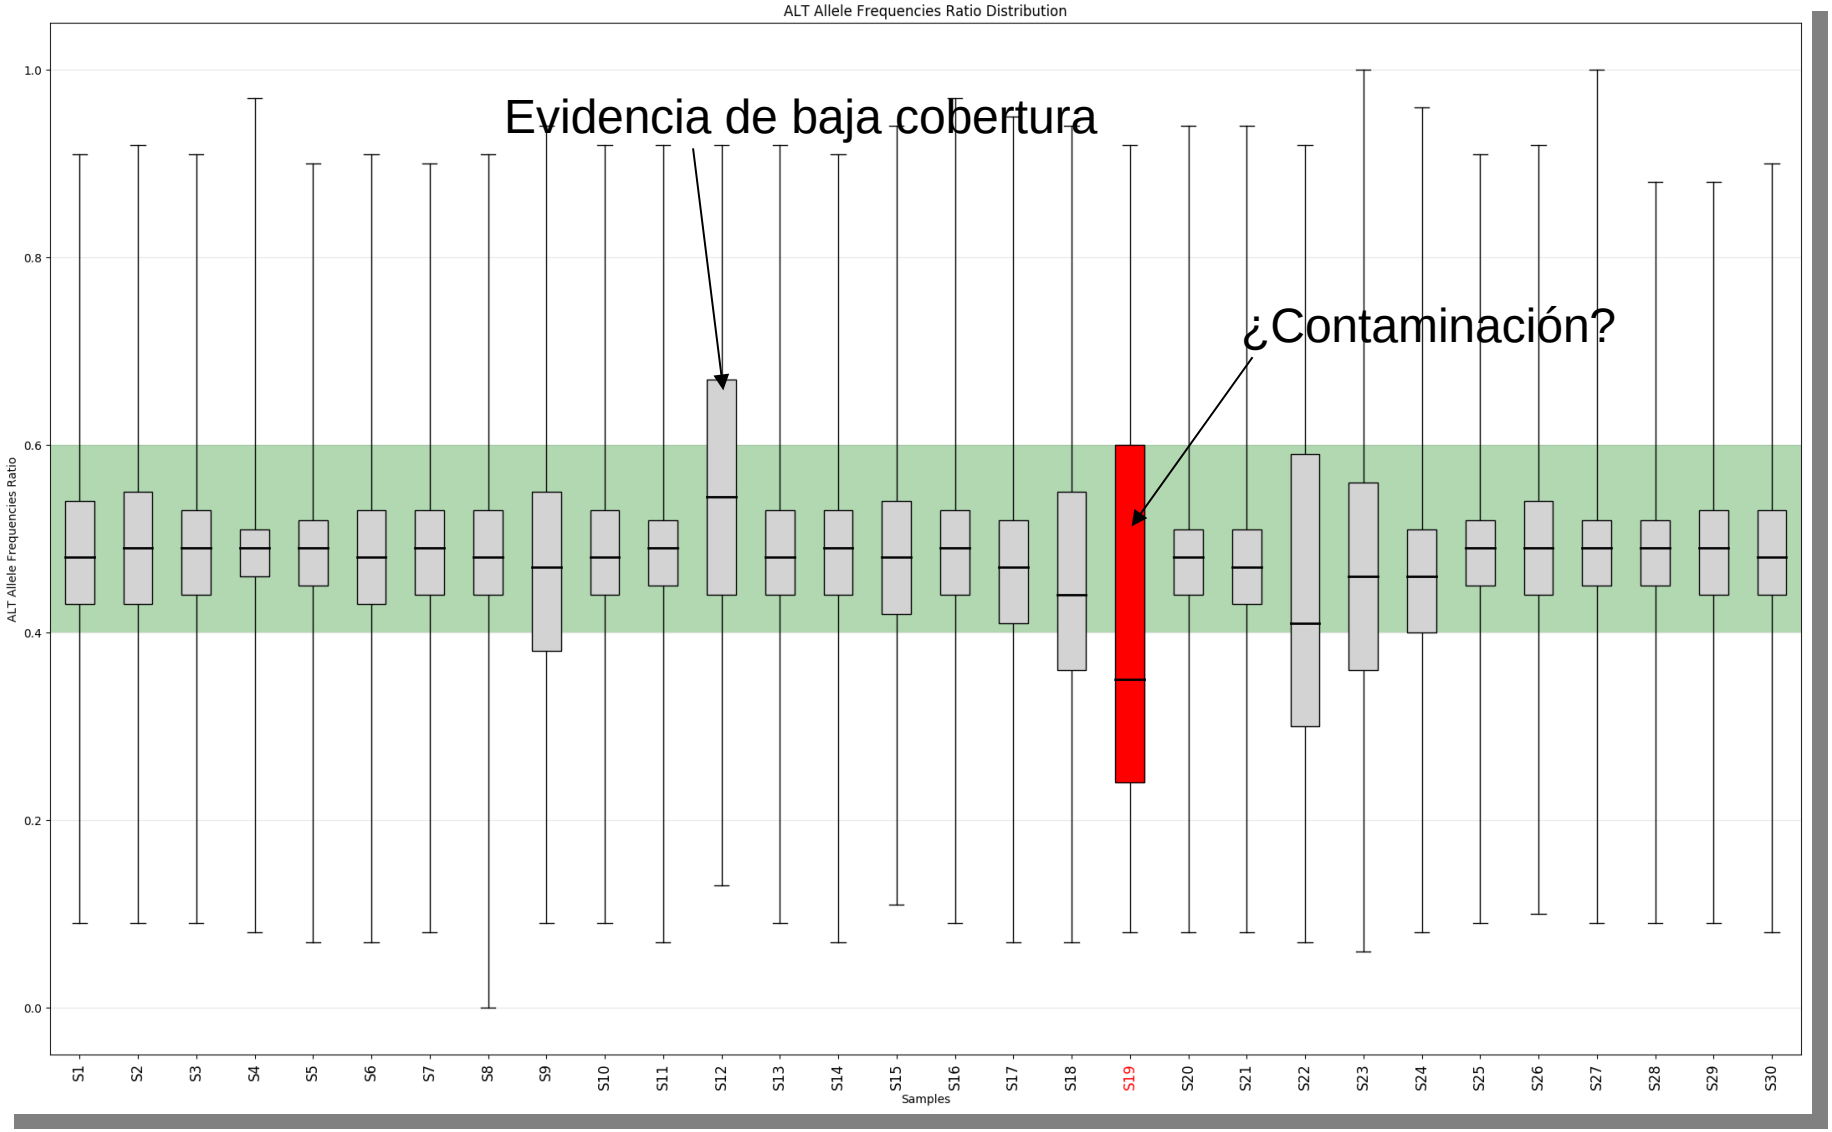

Detección de anomalías

- Una muestra ha superado todos los controles de calidad explicados previamente:
  - Se ha secuenciado sin problemas.
  - Se ha alineado correctamente, consiguiendo una elevada cobertura en las regiones de interés.
  - Se han determinado múltiples variantes con buena calidad.
  - Pero…
  - **¿Este análisis corresponde realmente a la muestra con la que está etiquetada?**

Detección de anomalías

- La secuenciación de unas muestras de DNA requiere una gran cantidad de pasos que involucran a muchas personas y laboratorios.

- Muchas **manipulaciones** de muchas muestras a la vez.

- Cada paso es una nueva oportunidad para que ocurran diversos fenómenos:

  - Equivocaciones en el **etiquetado**: relaciones entre muestras, sexo cromosómico...

  - **Intercambios** de muestras.

  - **Contaminaciones.**

Detección de anomalías

- Estos errores destruyen el **poder de diagnóstico** de las muestras:
  - Intercambio de muestras → Un hijo afecto es intercambiado por su padre sano.
  - Incorrecto etiquetado de un conjunto de muestras procedentes de familiares.
  - Muestras duplicadas → proyectos grandes que han reclutado al mismo sujeto múltiples veces.
  - Contaminaciones de muestras.
- Todos estos problemas pueden no detectarse sin una **revisión cuidadosa** de las muestras secuenciadas y analizadas.

Detección de anomalías

- ¿Cómo evitar estas anomalías?
  - Estricto control del etiquetado de las muestras.
  - Cuidadoso trabajo en el laboratorio.
  - Mantenimiento de bases de datos con la información de los pacientes y sus familiares.
- No siempre es posible evitar que ocurran estos problemas.
- ¿Cómo detectar estas anomalías?
  - Evaluación del sexo cromosómico.
  - Contrastar las relaciones (duplicados, familia) etiquetadas con las observadas.
  - Determinación de posibles contaminaciones.
  - Considerar que todo puede ocurrir simultáneamente.

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S1 → Etiquetado XY, detectado XX

- La dosis de cromosoma X se corresponde a valores esperados para una copia de X.
- Existe cobertura en el cromosoma Y, aunque baja

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S1 → Etiquetado XY, detectado XX

- La dosis de cromosoma X se corresponde a valores esperados para una copia de X.
- Existe cobertura en el cromosoma Y, aunque baja

→ La cobertura para la muestra es muy baja → el chrY no ha amplificado suficiente
→ La muestra está bien etiquetada → es XY

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S2 → Etiquetado XX, detectado XY

- La dosis de cromosoma X se corresponde a valores esperados para una copia de X.
- Existe una elevada cobertura en el cromosoma Y

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S2 → Etiquetado XX, detectado XY

- La dosis de cromosoma X se corresponde a valores esperados para una copia de X.
- Existe una elevada cobertura en el cromosoma Y

→ El género de la muestra estaba mal etiquetado
→ La muestra es XY

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S3 → Etiquetado XY, detectado XX

- La dosis de cromosoma X se corresponde a valores esperados para dos copias X.
- No hay cobertura en el cromosoma Y

Detección de anomalías
Caso práctico

- Sexo cromosómico no coincidente

SAMPLE ID	MEAN AVERAGE COVERAGE	%BP >= 20X	INPUT GENDER	DETECTED GENDER	DOSAGE X	DOSAGE Y
S1	91,71	39,6	H	M	0.6 vs. [0,1,2]	['10.76', '1.59', '1.97', '1.59', '3.30']
S2	420,3	94,76	M	H	0.5 vs. [0,1,2]	['369.25', '21.11', '129.13', '57.51', '171.11', '111.87', '70.04', '1.10']
S3	264,41	97,26	H	M	1 vs. [0,1,2]	[0]

S3 → Etiquetado XY, detectado XX

- La dosis de cromosoma X se corresponde a valores esperados para dos copias X.
- No hay cobertura en el cromosoma Y

→ El género de la muestra estaba mal etiquetado
→ La muestra es XX

Detección de anomalías
Caso práctico

- Casos en los que se observa un sexo cromosómico no coincidente.
  - Suele ser una equivocación al etiquetar la muestra
  - Ejemplo: intercambiar el padre de un probando por la madre
  - Sin embargo... → **¡Posible intercambio de muestra!**

Detección de anomalías

- Para comprobar relaciones familiares:
  - *VCFtools* (https://vcftools.github.io/index.html)
  - *PLINK* (https://www.cog-genomics.org/plink2)
  - *KING* (http://people.virginia.edu/~wc9c/KING/)
  - *Peddy* (https://github.com/brentp/peddy)

Detección de anomalías
Caso práctico

- Relaciones no etiquetadas
  - La mayor parte de las veces ocurren debido a errores en el etiquetado.
  - Sin embargo... :
    - **¡Posible intercambio de muestra!** → Si la muestra con la que se ha intercambiado está en el mismo pool de secuenciación, puede resolverse 'fácilmente'
    - **¡Posible contaminación entre muestras!** → El peor de los casos... la muestra debe ser descartada para el análisis de variantes

Detección de anomalías
Caso práctico

- Contaminación
  - Ratio de la frecuencia alélica de las variantes heterozigotas.

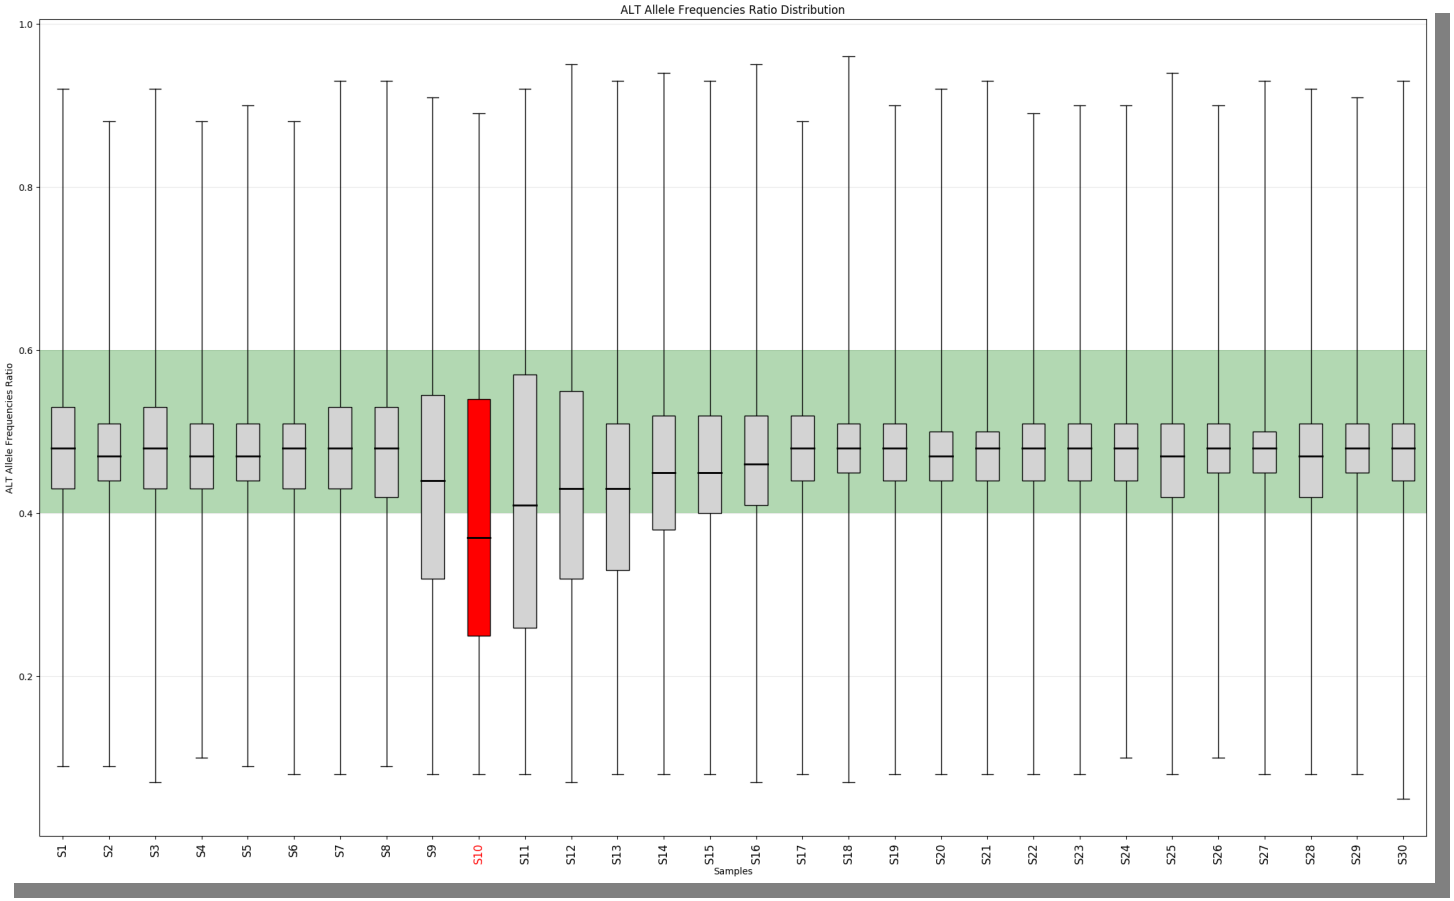

Detección de anomalías
Caso práctico

- Contaminación
  - Ratio de la frecuencia alélica de las variantes heterozigotas.

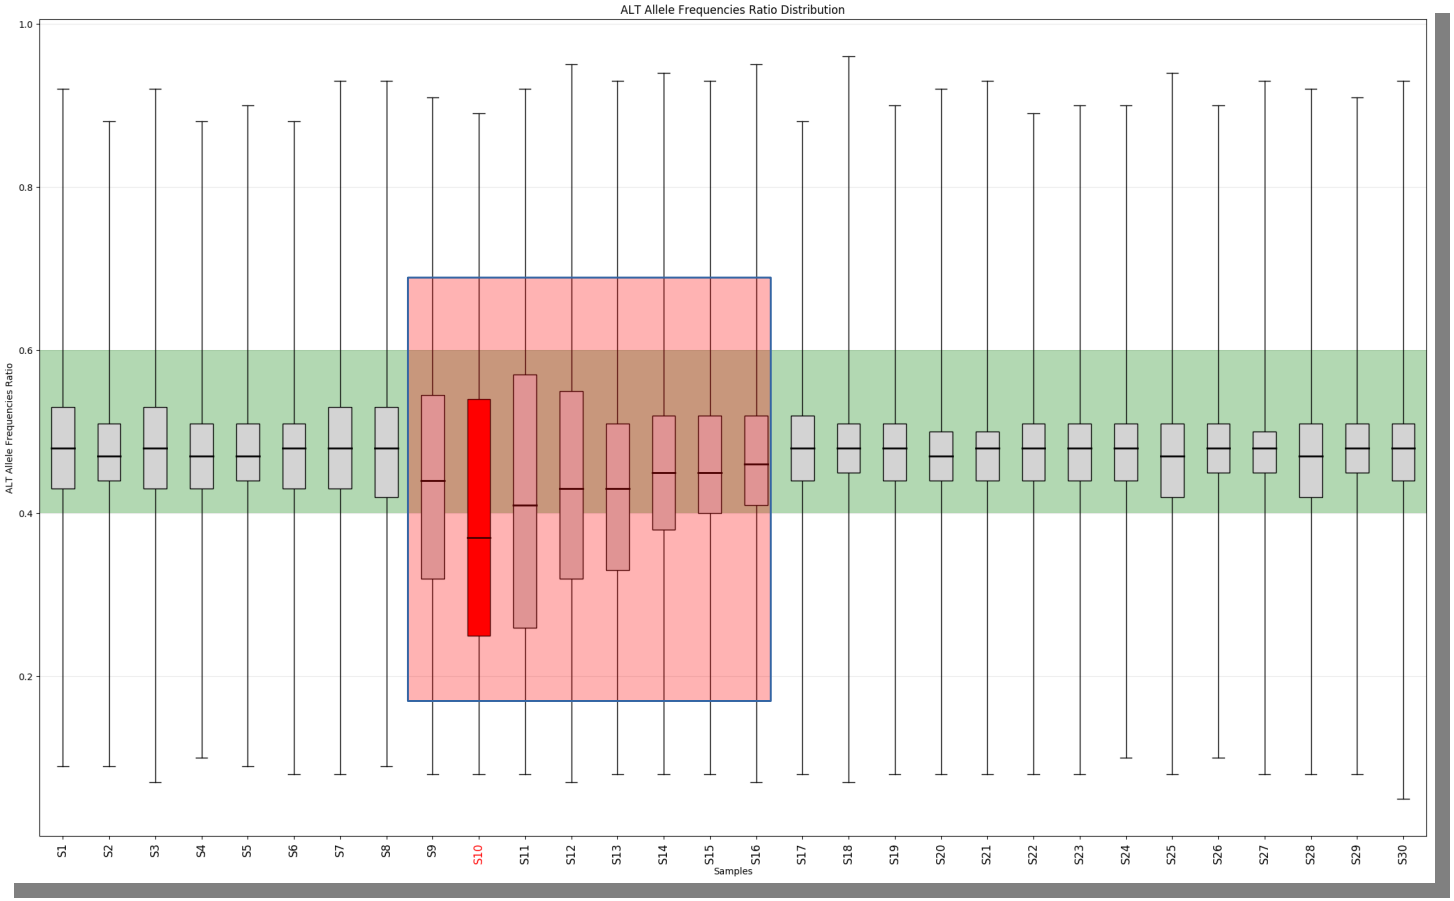

Detección de anomalías
Caso práctico

- Contaminación
  - Ratio de la frecuencia alélica de las variantes heterozigotas.

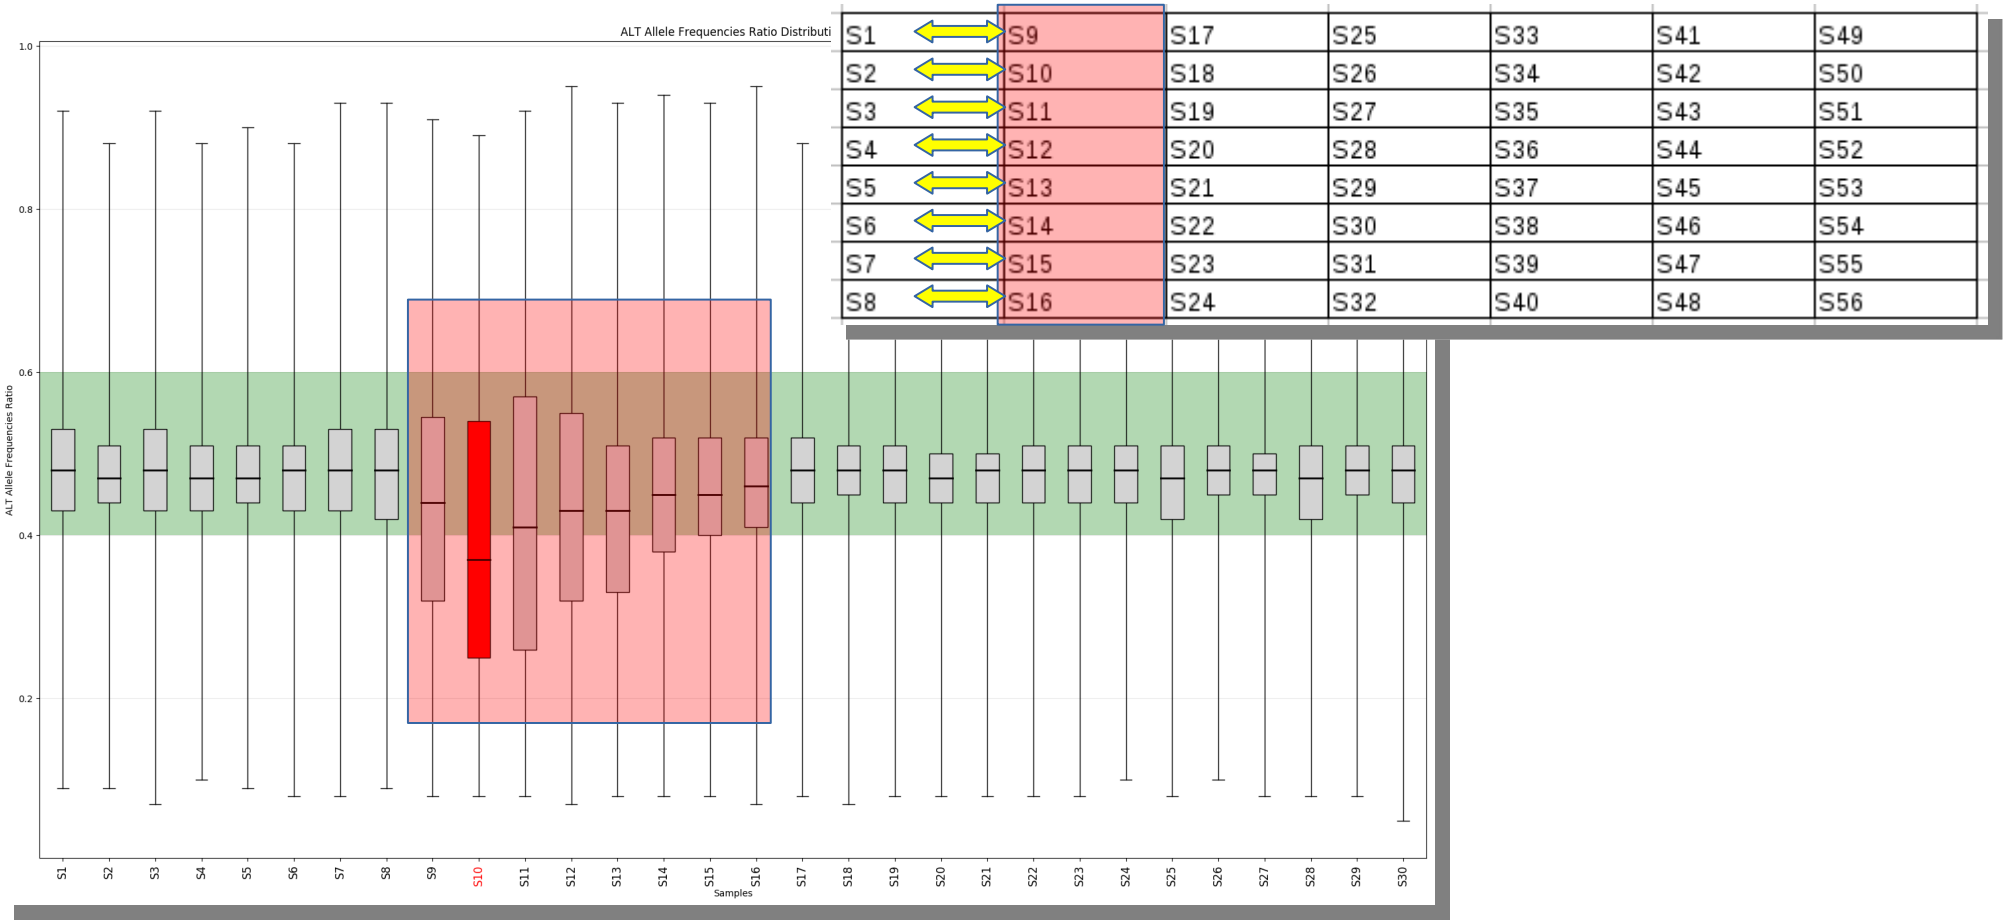

Take-home message

- El control de calidad debe:
  - Ser estricto → evitar costes
  - Estar embebido en el proceso de análisis → evitar sesgos
  - Ser vital para el diagnóstico clínico → posibilidad de cribar genes
  - Evitar confusiones en los etiquetados de muestras